

# Tuần 1 - Tổng hợp kiến thức Buổi học số 1 và 2

Time-Series Team

Ngày 17 tháng 7 năm 2025

Buổi học số 1 (Thứ 3, 1/07/2025) và buổi học số 2 (Thứ 4, 2/07/2025) có nhiều nội dung tương đồng và kế thừa nhau nên nhóm mình sẽ tổng hợp lại thành 8 nội dung chính:

- *Phần 1: Motivation: Tại sao cần NumPy?*
- *Phần 2: Giới thiệu NumPy*
- *Phần 3: CRUD trên Array*
- *Phần 4: Array Transformations*
- *Phần 5: View vs Copy – Hiểu đúng để tránh bug*
- *Phần 6: Vectorization & Broadcasting*
- *Phần 7: AI Applications*
- *Phần 8: Mở rộng*

## Phần 1: Motivation: Tại sao cần NumPy?

### 1. Đặt vấn đề: List có đủ tốt?

Trong Module 1, khi bắt đầu học Python, chúng ta đã làm quen với cấu trúc dữ liệu **List** – một trong những kiểu dữ liệu cơ bản và linh hoạt nhất. Với khả năng chứa bất kỳ kiểu phần tử nào (số, chuỗi, danh sách lồng...), cùng các thao tác thêm, xóa, duyệt, lọc khá dễ dàng, **List đặc biệt hữu ích cho các bài toán xử lý dữ liệu đơn giản, quy mô nhỏ.**

Ví dụ: xử lý chuỗi, duyệt danh sách điểm thi, lọc dữ liệu từ file, hay thậm chí là thao tác sơ bộ với dữ liệu từ csv – tất cả đều có thể xử lý gọn gàng bằng List:

```
1 scores = [7, 8.5, 9, 6.5, 10]
2 # Filter scores >= 8
3 high_scores = [s for s in scores if s >= 8]
4 print(high_scores) # [8.5, 9, 10]
```

Tuy nhiên, khi xét một bài toán khác:

Ta có một dãy số  $[1, 2, 3, 4]$  và muốn tính kết quả  $\text{output} = x^2 + 1$  cho từng phần tử. **Với List**, cách viết thường thấy sẽ là:

```
1 x = [1, 2, 3, 4]
2 y = [xi**2 + 1 for xi in x]
3 print(y) # [2, 5, 10, 17]
```

Cách viết này tuy vẫn gọn, nhưng:

- Vẫn cần **duyệt từng phần tử thủ công** (list comprehension).
- Khi mở rộng lên 2D/3D, hoặc hàng triệu phần tử – **hiệu suất giảm mạnh**.

### List bắt đầu bộc lộ giới hạn khi nào?

Khi bài toán bắt đầu bước vào vùng:

- **Tính toán số học quy mô lớn** (hàng triệu phần tử).
- **Mảng nhiều chiều** (ảnh, video, dữ liệu tensor).
- **Cần hiệu suất cao** (AI, khoa học dữ liệu, thống kê).

Lúc này, List nhanh chóng bộc lộ các nhược điểm nghiêm trọng:

- **Không hỗ trợ vector hóa (no vectorization)**  
Giả sử muốn tính toán:  $\text{output} = \text{input}^2 + 1$  với  $\text{input} = [1, 2, 3, 4]$ .

Nếu chúng ta muốn thử:

```
1 input = [1, 2, 3, 4]
2 output = input**2 + 1 # Error: unsupported operand
```

Python sẽ báo lỗi vì List **không hỗ trợ toán học dạng vector**.

Mà với list thuần, ta phải dùng **List comprehension** để xử lý từng phần tử:

```
1 input = [1, 2, 3, 4]
2 output = [x**2 + 1 for x in input] # use for => loop
```

⇒ Không ngắn gọn, khó mở rộng, và **không tận dụng được khả năng tối ưu phần cứng**.

- **Dữ liệu không đồng nhất (heterogeneous types)**

Python List cho phép chứa mọi loại dữ liệu:



Điều này đồng nghĩa:

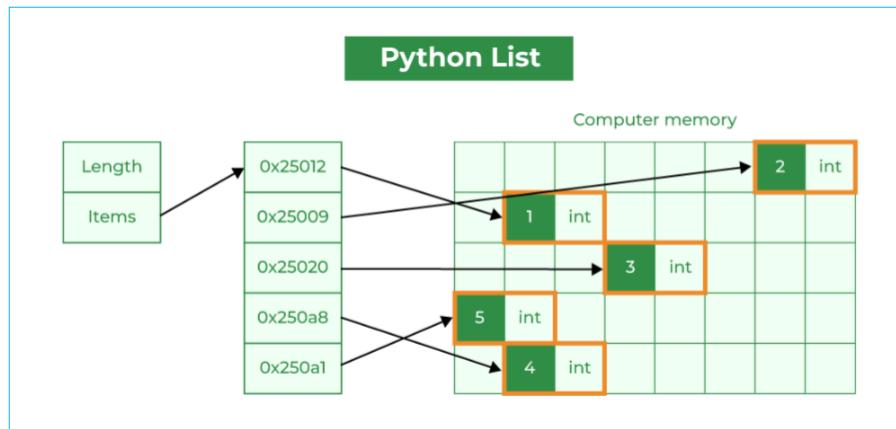
- Không thể tối ưu truy xuất dữ liệu.
- Mỗi phần tử là một object độc lập ⇒ **tốn bộ nhớ hơn rất nhiều**.

- **Bộ nhớ phân mảnh (non-contiguous memory)**

Các phần tử trong List được lưu ở các vị trí rời rạc trong bộ nhớ:

- Một int có thể nằm ở địa chỉ A.
- Một float tiếp theo ở địa chỉ B hoàn toàn khác.

Khi xử lý hàng triệu phần tử, việc **bộ nhớ không liên tục** khiến **CPU cache không thể tối ưu hóa** ⇒ tốc độ chậm.



Hình 1: Minh họa sự phân mảnh trong bộ nhớ của 1 List gồm các phần tử kiểu int

- **Không có reshape, broadcasting**

- Không thể dễ dàng thay đổi chiều dữ liệu hay thực hiện phép toán giữa mảng khác shape.

Và đó là lúc chúng ta cần đến **NumPy** – một thư viện giúp Python **chuyển mình từ ngôn ngữ “general purpose” thành công cụ mạnh cho khoa học dữ liệu và AI**.

## 2. NumPy Array: Giải pháp tối ưu

NumPy ra đời để khắc phục các hạn chế trên bằng cách cung cấp **mảng đa chiều hiệu suất cao – ndarray**. Dưới đây là vài ưu điểm then chốt:

- **Dữ liệu đồng nhất (homogeneous)**

NumPy yêu cầu tất cả phần tử phải có cùng kiểu dữ liệu (`int32`, `float64`, ...).  
⇒ Dễ tối ưu hóa và thao tác toán học.

- **Bộ nhớ liên tục (contiguous)**

Dữ liệu được lưu liên tiếp trong vùng nhớ. Điều này giúp:

- Tận dụng tốt CPU cache.
- Tốc độ tính toán nhanh hơn nhiều lần so với List.

- **Vector hóa và broadcasting**

Các phép toán hoạt động trực tiếp trên toàn bộ array – không cần vòng lặp, cụ thể:  
Cụ thể với NumPy, ví dụ trên trở nên gọn và mạnh mẽ hơn rất nhiều:

```
1 import numpy as np
2
3 x = np.array([1, 2, 3, 4])
4 y = x**2 + 1
5 print(y) # [ 2  5 10 17 ]
```

Điều kỳ diệu là:

- Cú pháp ngắn hơn.
- Nhờ tận dụng cấu trúc bộ nhớ liên tục như C và gọi các thư viện tính toán cấp thấp, giúp thao tác trên array được vector hóa và **chạy nhanh gấp nhiều lần** so với List thuần.
- Có khả năng mở rộng tốt cho array 2D, 3D, n-D  
⇒ Cực kỳ hữu dụng cho nhiều tác vụ trong thực tế như: AI, xử lý ảnh, thống kê, vật lý, kỹ thuật...

## 3. “Implement View” vs “Execution View”

Trở lại vấn đề quenn thuộc: Cho  $L = [1, 2, 3, 4]$ , yêu cầu tính  $L^2 + 1$ .

**Với List:**

```
1 result = [x**2 + 1 for x in L]
```

⇒ Thao tác từng phần tử – “*Implement View*”: phải viết cách làm cụ thể.

**Với NumPy:**

```
1 arr = np.array([1, 2, 3, 4])
2 result = arr**2 + 1
```

⇒ Thao tác toàn mảng – “*Execution View*”: chỉ cần nói “muốn gì” – NumPy tự xử lý.

## 4. Benchmark: So sánh hiệu suất giữa list và ndarray

### Benchmark là gì?

Benchmark (tạm dịch: “kiểm chuẩn tốc độ”) là quá trình đo và so sánh hiệu suất thực thi của các đoạn chương trình, thường dùng để:

- So sánh 2 hoặc nhiều cách giải cùng một bài toán.
- Đánh giá chi phí về thời gian, bộ nhớ hoặc hiệu suất.
- Chọn phương pháp tối ưu cho bài toán thực tế.

Trong ngữ cảnh này, ta sẽ benchmark tốc độ giữa:

- Python `list` – với vòng lặp (list comprehension).
- NumPy `ndarray` – với phép toán vector hóa.

### Bài toán benchmark

Ta sẽ thực hiện bài toán đơn giản: tính bình phương của một triệu số nguyên từ 0 đến 999 999. Tuy đơn giản, nhưng bài toán này rất phù hợp để thấy sự khác biệt lớn về hiệu suất khi dữ liệu đủ lớn.

```

1 import numpy as np
2 import time
3
4 # Tạo một danh sách hàng
5 L = list(range(1_000_000))      # List
6 A = np.array(L)                  # ndarray NumPy
7
8 # Benchmark với List
9 start = time.time()
10 L_result = [x**2 for x in L]
11 list_time = time.time() - start
12 print("List time:", list_time)
13
14 # Benchmark với NumPy
15 start = time.time()
16 A_result = A**2
17 numpy_time = time.time() - start
18 print("NumPy time:", numpy_time)
19
20 # Kết quả
21 print("Speedup:", list_time / numpy_time)

```

===== Output =====

```

List time: 0.3032 s
NumPy time: 0.0155 s
Speedup: 19.55x

```

### Phân tích kết quả

- Thời gian xử lý với `list` là hơn 0.3 giây — do phải lặp qua từng phần tử và tính toán từng `x**2` trong Python.
- Với NumPy, chỉ mất khoảng 0.015 giây — nhanh hơn **gần 20 lần**.

- Nguyên nhân chính:
  - ndarray lưu trữ dữ liệu **liên tục trong bộ nhớ**, giúp CPU cache xử lý hiệu quả hơn nhiều.
  - Các phép toán như **A\*\*2** được gọi trực tiếp vào các hàm viết bằng **C/Fortran** tối ưu hóa (tận dụng SIMD, vectorization, multi-thread).
  - Không cần vòng lặp Python (rất chậm so với vòng lặp cấp thấp).

#### Lưu ý:

- Với bài toán lớn (tính toán ma trận, xử lý ảnh, ML), mức chênh lệch có thể lên tới **hàng trăm lần**.
- Benchmark là minh chứng rõ ràng cho lý do vì sao NumPy trở thành thư viện nền tảng cho khoa học dữ liệu, ML, AI, xử lý ảnh/video...

## 5. Khi nào nên dùng NumPy?

Bảng dưới đây so sánh giữa Python list và NumPy ndarray trên nhiều khía cạnh quan trọng:

Tính năng	Python list	NumPy ndarray
Kiểu dữ liệu	Linh hoạt (không đồng nhất)	Đồng nhất (fixed dtype)
Cấu trúc bộ nhớ	Phân mảnh (non-contiguous)	Liên tục (contiguous)
Toán học vector	Không hỗ trợ trực tiếp	Hỗ trợ mạnh mẽ
Vectorization	Không có	Có
Broadcasting	Không có	Có
Tốc độ thực thi	Thấp	Rất cao
Khả năng tối ưu phần cứng	Không có	Có (C-level, đa luồng)
Thao tác reshape, indexing nâng cao	Rất hạn chế	Đầy đủ

#### Kết luận:

- Khi làm việc với dữ liệu khoa học, xử lý ảnh, âm thanh, video, dữ liệu lớn hoặc huấn luyện mô hình AI/ML, thì **NumPy là sự lựa chọn bắt buộc**.
- ndarray không chỉ giúp code ngắn gọn, dễ đọc hơn mà còn tăng hiệu suất lên hàng chục lần.
- Nhiều thư viện quan trọng như Pandas, scikit-learn, TensorFlow đều dựa trên nền tảng NumPy.

## Phần 2: Giới thiệu NumPy

### 1. Làm quen với ndarray

Từ những phân tích ở phần trước, ta thấy rõ rằng Python `list` không phù hợp với các bài toán cần hiệu suất cao, vector hóa hay xử lý mảng nhiều chiều. NumPy cung cấp kiểu dữ liệu `ndarray` để giải quyết vấn đề này.

#### Tạo ndarray từ list Python:

```

1 import numpy as np
2
3 L = [1, 2, 3, 4, 5]
4 A = np.array(L)
5 print(type(L), type(A))
6 # <class 'list'> <class 'numpy.ndarray'>

```

Sau khi khởi tạo, `A` trở thành một mảng có thể tham gia các phép toán như `A + 1`, `A ** 2` một cách tự nhiên.

#### So sánh nhanh giữa list và ndarray:

	Python list	NumPy ndarray
Kiểu phần tử	Hỗn hợp	Đồng nhất (dtype)
Toán học mảng	Không hỗ trợ trực tiếp	Vectorized ( <code>A + 1</code> , <code>A**2</code> )
Bộ nhớ	Phân mảnh	Liên tục (contiguous)
Hiệu suất	Thấp	Cao (C-level, SIMD)

**Ghi chú:** Với `list`, mỗi phần tử là một object độc lập trong bộ nhớ — Python phải lưu địa chỉ từng phần tử rời rạc. Còn với `ndarray`, toàn bộ dữ liệu được lưu liên tiếp trong RAM dưới cùng một kiểu dữ liệu (`int32`, `float64`, ...), giúp tận dụng CPU cache và thư viện C phía sau NumPy để xử lý cực nhanh.

Việc chuyển đổi sang `ndarray` không chỉ là “ép kiểu” mà là bước mở cửa vào thế giới của vectorization, broadcasting, và tính toán số học ở quy mô lớn.

⇒ Từ đây, ta sẽ tiếp tục khám phá cách NumPy mở rộng khái niệm vector một chiều thành các **mảng đa chiều** có cấu trúc linh hoạt hơn rất nhiều.

### 2. Từ vector đến mảng đa chiều (ndarray)

Trong Toán học, **vector** là một dãy số có thứ tự  $\mathbf{v} = (v_0, v_1, \dots, v_{n-1})$  — tức là một chiều dữ liệu. Khi xử lý dữ liệu trong thực tế (ảnh, video, tín hiệu), chúng ta thường gặp không chỉ vector, mà là các cấu trúc **đa chiều** hơn rất nhiều.

NumPy mở rộng khái niệm vector thành `ndarray` — một kiểu dữ liệu có thể biểu diễn **mọi chiều không gian**:

- **1D** (vector):  $v_i$
- **2D** (ma trận):  $A_{i,j}$
- **3D** (tensor):  $B_{i,j,k}$
- **4D+** (video, batch, mô hình vật lý):  $T_{b,c,h,w}$

Minh họa các chiều mảng trong NumPy:

```

1 import numpy as np
2
3 v = np.array([1,2,3])
4 print(f"v.ndim D: shape = {v.shape}")
5 M = np.array([[1, 2, 3], [4, 5, 6]])
6 print(f"M.ndim D: shape = {M.shape}")
7 T = np.zeros((3,3,2))
8 print(f"T.ndim D: shape = {T.shape}")

```

===== Output =====

```

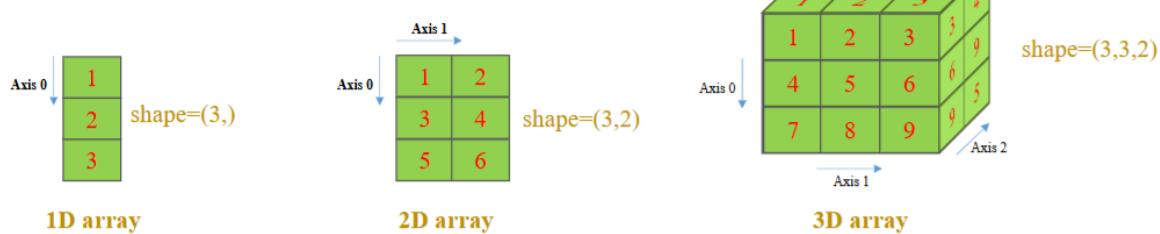
1D: shape = (3,)
2D: shape = (2, 3)
3D: shape = (3, 3, 2)

```

Mỗi chiều trong mảng được gọi là một **trục** (axis). Ví dụ, với mảng có shape (2, 3, 4):

- Trục 0 (axis 0): có 2 phần tử — tương ứng 2 “khối”.
- Trục 1 (axis 1): mỗi khối có 3 hàng.
- Trục 2 (axis 2): mỗi hàng có 4 cột.

### ❖ Numpy arrays are multi-dimensional arrays



Hình 1: Minh họa kích thước và chiều axis

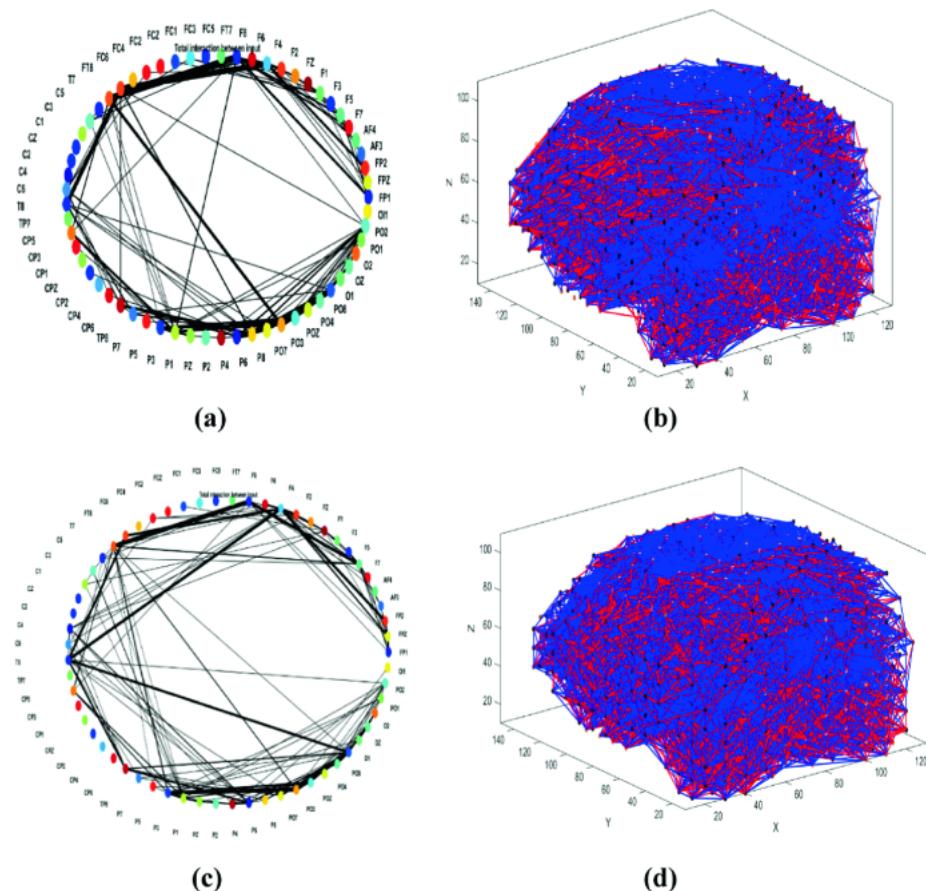
Một số ví dụ thực tế:

- Ảnh xám (2D): kích thước ( $H, W$ )
- Ảnh RGB (3D): kích thước ( $3, H, W$ ) hoặc ( $H, W, 3$ ) tùy thư viện
- Video (4D): ( $T, 3, H, W$ ) — số frame, kênh màu, chiều cao, chiều rộng
- Dữ liệu batch (5D): ( $B, T, C, H, W$ ) — batch size, thời gian, kênh, hình

Một số lĩnh vực ứng dụng theo chiều dữ liệu:

- **1D:** chuỗi thời gian, âm thanh, văn bản token hóa.

- **2D**: ảnh xám, dữ liệu dạng bảng, ma trận.
  - **3D**: ảnh màu RGB, dữ liệu ảnh y tế (CT/MRI).
  - **4D trở lên**: video, batch training trong deep learning, mô hình mô phỏng vật lý (fluid, khí động lực...).



Hình 2: Mô tả mang kết nối não trong không gian 2D và 3D

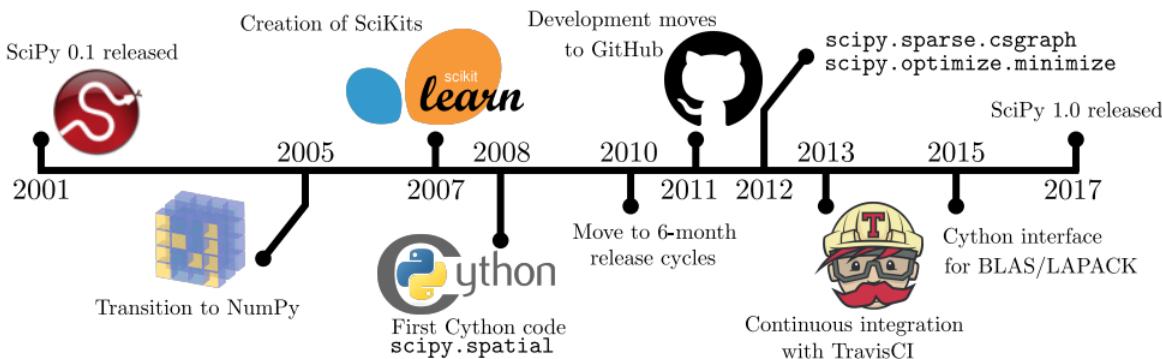
Mảng nhiều chiều chính là trung tâm của mọi tính toán khoa học bằng NumPy. Hiểu rõ cách NumPy tổ chức và xử lý `ndarray` là nền tảng để bước vào vectorization, broadcasting, hoặc deep learning sau này.

### 3. NumPy là gì? Lịch sử và vai trò

**NumPy** (viết tắt của “Numerical Python”) là một thư viện mã nguồn mở nổi bật trong hệ sinh thái Python, cung cấp một kiểu dữ liệu mảng đa chiều hiệu suất cao gọi là `ndarray`, cùng với hàng trăm hàm toán học có thể hoạt động trực tiếp trên toàn mảng.

### Lịch sử ra đời của NumPy:

- Trước năm 2005, cộng đồng Python khoa học bị chia rẽ giữa hai thư viện: Numeric (ra đời năm 1995, nhanh nhưng hạn chế) và numarray (linh hoạt hơn nhưng chậm).
- Năm 2005, Travis Oliphant — một giáo sư ngành điện tử và kỹ thuật y sinh — đã đứng ra hợp nhất hai thư viện này thành NumPy, bằng cách mở rộng Numeric và tích hợp ý tưởng từ numarray.
- Việc chuyển đổi toàn bộ hệ sinh thái sang NumPy bắt đầu từ năm 2005, và NumPy 1.0 chính thức được phát hành vào năm 2006.
- SciPy — một thư viện cấp cao hơn ra đời từ 2001 — ban đầu được xây dựng trên Numeric, sau đó chuyển sang dùng NumPy làm nền tảng chính.
- Từ năm 2010 trở đi, hệ sinh thái SciPy/NumPy ngày càng ổn định: chuyển lên GitHub (2011), tích hợp TravisCI (2013), và đến năm 2017 phát hành SciPy 1.0.
- Cả NumPy và SciPy đều là phần cốt lõi của hệ sinh thái Python khoa học, được phát triển cộng đồng và bảo trợ bởi tổ chức phi lợi nhuận NumFOCUS.



Hình 3: Timeline phát triển của thư viện SciPy, thể hiện rõ sự phụ thuộc vào NumPy

### Vai trò cốt lõi của NumPy:

- Cung cấp kiểu dữ liệu `ndarray` — mảng đa chiều đồng nhất, hỗ trợ slice, reshape, broadcasting...
- Tích hợp hàng trăm hàm toán học vector hóa (vectorized operations), tận dụng:
  - C-level speed (viết bằng C, Fortran)
  - SIMD instructions (tăng tốc qua phần cứng)
  - Hỗ trợ đa luồng (multi-threaded operations)
- Là nền tảng cho các thư viện nổi tiếng như:
  - Pandas – xử lý dữ liệu dạng bảng (DataFrame)
  - SciPy – thuật toán khoa học (linear algebra, signal...)
  - scikit-learn – học máy cổ điển

- TensorFlow, PyTorch – cảm hứng từ cú pháp và broadcasting của NumPy

**So sánh triết lý thiết kế:**

	Python gốc (List)	NumPy (ndarray)
Tối ưu cho	Tính linh hoạt, dễ dùng	Tính toán hiệu suất cao
Kiểu dữ liệu	Đa kiểu (heterogeneous)	Đồng nhất (homogeneous)
Tính toán	Duyệt thủ công, vòng lặp	Vector hóa toàn mảng
Backend thực thi	Thuần Python	C/Fortran + SIMD + cache
Broadcasting	Không hỗ trợ	Có
Reshape/Index nâng cao	Hạn chế	Đầy đủ

NumPy không thay thế Python, mà là phần mở rộng giúp Python trở thành một ngôn ngữ mạnh mẽ cho khoa học dữ liệu, thống kê, AI, xử lý tín hiệu và mô phỏng vật lý.

Từ các phép toán đơn giản như cộng mảng, đến các bài toán deep learning phức tạp — mọi thứ đều khởi đầu từ một ndarray.

## 4. Định nghĩa ndarray và các thuộc tính cơ bản

Trong NumPy, mọi mảng đều thuộc kiểu dữ liệu `numpy.ndarray` — một cấu trúc chuyên biệt để lưu trữ dữ liệu số học theo dạng mảng nhiều chiều (vector, ma trận, tensor...).

**Đặc điểm chính của ndarray:**

- **Đồng nhất (homogeneous):** tất cả phần tử có cùng kiểu dữ liệu (`dtype`), ví dụ `int32`, `float64`...
- **Liên tục trong bộ nhớ (contiguous memory):** các phần tử được lưu liền mạch, giúp truy xuất nhanh hơn và dễ tối ưu hóa bằng C/Fortran.
- **Hỗ trợ đa chiều (multidimensional):** có thể là 1D, 2D, 3D, thậm chí nD.

Một số thuộc tính cơ bản:

- `arr.shape` – kích thước từng chiều (tuple).
- `arr.ndim` – số chiều (int).
- `arr.dtype` – kiểu dữ liệu phần tử.
- `arr.itemsize` – số byte mỗi phần tử.
- `arr.size` – tổng số phần tử trong array.
- `arr.nbytes` – tổng dung lượng bộ nhớ = `itemsize × size`.

### Ví dụ: mảng 3 chiều

```

1 import numpy as np
2
3 X = np.zeros((3, 3, 2))
4 print("shape   :", X.shape)
5 print("ndim   :", X.ndim)
6 print("dtype   :", X.dtype)
7 print("itemsize :", X.itemsize)
8 print("size    :", X.size)
9 print(" nbytes :", X.nbytes)

```

```

=====
Output =====
shape      : (3, 3, 2)
ndim       : 3
dtype      : float64
itemsize   : 8
size       : 18
 nbytes   : 144

```

### Ví dụ trực quan hơn với mảng 2D:

```

1 A = np.array([[1, 2, 3],
2               [4, 5, 6]])
3 print("shape   :", A.shape)
4 print("ndim   :", A.ndim)
5 print("size    :", A.size)
6 print("dtype   :", A.dtype)

```

```

=====
Output =====
shape      : (2, 3)
ndim       : 2
size       : 6
dtype      : int64

```

#### Ghi chú:

- list của Python không có bất kỳ thuộc tính nào ở trên, do đó ta không thể gọi `shape`, `dtype`, hay `size` trên list.
- Vì vậy, khi xử lý dữ liệu số học, đặc biệt với mảng nhiều chiều hoặc kích thước lớn, dùng `ndarray` là bắt buộc nếu muốn tối ưu hiệu suất.

#### Tổng kết: bảng thuộc tính của `ndarray`

Thuộc tính	Kiểu dữ liệu	Ý nghĩa
<code>.shape</code>	<code>tuple</code>	Kích thước từng chiều
<code>.ndim</code>	<code>int</code>	Số chiều
<code>.dtype</code>	<code>dtype</code>	Kiểu dữ liệu phần tử
<code>.itemsize</code>	<code>int</code>	Byte trên mỗi phần tử
<code>.size</code>	<code>int</code>	Tổng số phần tử
<code>. nbytes</code>	<code>int</code>	Tổng số byte trong mảng

## 5. Cài đặt và import

```

1 # pip
2 pip install numpy
3
4 # conda
5 conda install numpy

```

```

1 import numpy as np

```

Alias `np` là chuẩn quốc tế để gọi mọi hàm và lớp trong NumPy.

## Phần 3: CRUD trên Array

### 1. Create – Khởi tạo ndarray trong NumPy

Khi làm việc với dữ liệu số học, ta thường cần khởi tạo các mảng số (arrays) ban đầu để thao tác, xử lý hoặc tính toán. NumPy cung cấp một tập hợp phong phú các hàm khởi tạo ndarray với cú pháp đơn giản nhưng mạnh mẽ. Việc này giúp loại bỏ vòng lặp tay, tăng tốc độ và tăng tính rõ ràng cho code.

#### 1.1. Chuyển đổi từ list sang NumPy array

```

1 import numpy as np
2
3 lst = [1, 2, 3, 4]
4 arr = np.array(lst) # ndarray 1D

```

`np.array(...)` là cách đơn giản nhất để chuyển Python list hoặc tuple thành NumPy array.

#### 1.2. Một số hàm tạo mảng phổ biến

##### Các hàm khởi tạo cơ bản:

- `np.zeros(shape)` – tạo mảng toàn số 0.
- `np.ones(shape)` – tạo mảng toàn số 1.
- `np.full(shape, value)` – tạo mảng với tất cả phần tử bằng `value`.
- `np.empty(shape)` – cấp phát mảng nhưng không khởi tạo giá trị (có thể chứa "rác").
- `np.eye(N)` – ma trận đơn vị (1 trên đường chéo).
- `np.identity(N)` – tương tự `eye`, dùng cho square matrix.

##### Code minh họa:

```

1 import numpy as np
2
3 arr1 = np.zeros((2, 3))
4 print("np.zeros((2, 3)): \n", arr1)
5 arr2 = np.ones((3,))
6 print("np.ones((3,)): \n", arr2)
7 arr3 = np.full((2, 2), 7)
8 print("np.full((2, 2), 7): \n", arr3)
9 arr4 = np.empty((2, 2))
10 print("np.empty((2, 2)): \n", arr4)
11 arr5 = np.eye(3) # 3x3 identity matrix
12 print("np.eye(3): \n", arr5)

=====
Output =====
np.zeros((2, 3)):
[[0. 0. 0.]
 [0. 0. 0.]]
np.ones((3,)): [1. 1. 1.]
np.full((2, 2), 7): [[7 7]
 [7 7]]
np.empty((2, 2)):
[[3.5e-323 3.5e-323]
 [3.5e-323 3.5e-323]]
np.eye(3):
[[1. 0. 0.]
 [0. 1. 0.]
 [0. 0. 1.]]

```

### 1.3. Sinh dãy số và ứng dụng trong làm mượt đồ thị

#### 1.3.1. Đặt vấn đề – `range()` và giới hạn của List

Đầu tiên, chúng ta hãy xét bài toán quen thuộc:

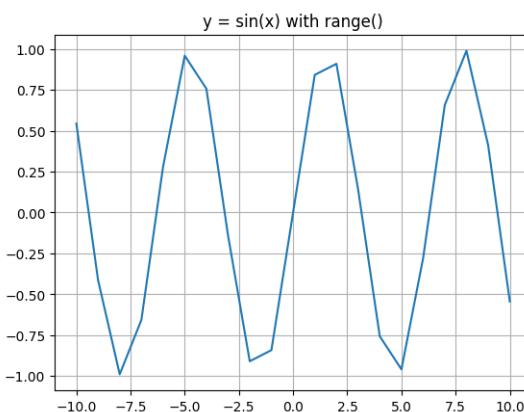
**Bài toán:** Vẽ đồ thị hàm số  $y = \sin(x)$  trên đoạn  $[-10, 10]$

Cách đơn giản nhất trong Python là dùng `range()` để sinh dãy x:

```

1 import matplotlib.pyplot as plt
2 import math as m    # use math.sin because range() generates integers
3
4 x = range(-10, 11, 1)      # Step = 1 (integer)
5 y = [m.sin(i) for i in x]
6
7 plt.plot(x, y)
8 plt.title("y = sin(x) with range()")
9 plt.grid(True)
10 plt.show()

```



**Kết quả:** Đồ thị bị "gãy khúc", rời rạc, không mượt. Đường cong dạng sóng  $\sin(x)$  gần như biến thành các đoạn thẳng zigzag, gây hiểu nhầm về bản chất hàm.

**Lý do:** `range()` chỉ sinh được các số nguyên.

Chúng ta không thể làm mịn đồ thị bằng cách giảm bước xuống 0.1:

```
1 range(-10, 10, 0.1)  # TypeError!
```

⇒ Đây là một trong những **hạn chế lớn của list + range()** khi xử lý dữ liệu số học và trực quan hóa.

Trong các bài toán thực tế, chúng ta rất cần một công cụ cho phép tạo ra dãy số **với bước nhỏ bất kỳ** (kể cả số thực) — để làm mượt đồ thị, phân tích sâu hơn. ⇒ Đó chính là lúc cần đến `np.arange()`

#### 1.3.2. Giới thiệu `np.arange()`

Như đã thấy, `range()` kết hợp với list không thể tạo ra các dãy số thực — điều này khiến việc trực quan hóa hàm liên tục trở nên thô cứng. ⇒ Chúng ta cần một công cụ mạnh hơn, đó là `np.arange()`.

**np.arange() là gì**

Là một hàm dùng để tạo một mảng chứa các số nguyên liên tiếp trong một khoảng xác định

**Cú pháp**

```
np.arange(start, stop, step)
```

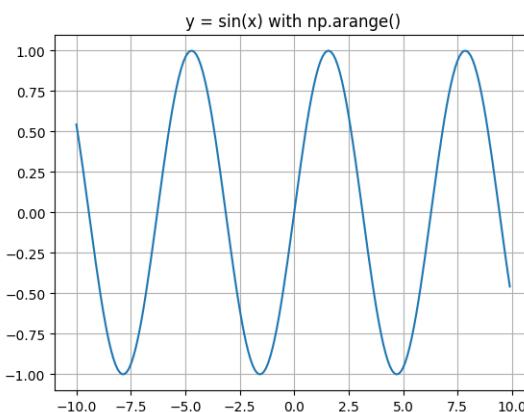
Trong đó:

- start: Giá trị bắt đầu của dãy số (giá trị này bao gồm trong mảng được tạo).
- stop: Giá trị kết thúc của dãy số (giá trị này không bao gồm trong mảng được tạo)
- step: Khoảng cách giữa các giá trị trong dãy số (mặc định là 1).

⇒ Tạo dãy số cách đều từ **start** đến nhỏ hơn **stop**, cách nhau **step** (có thể là số thực).

**Ví dụ:** Áp dụng lại bài toán ban đầu, nhưng lần này dùng NumPy:

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 x = np.arange(-10, 10, 0.1) # small step → 200 points
5 y = np.sin(x)               # This time use np.sin because x is an array
6
7 plt.plot(x, y)
8 plt.title("y = sin(x) with np.arange()")
9 plt.grid(True)
10 plt.show()
```



**Kết quả:** Đồ thị giờ đây trơn tru, mượt mà, thể hiện đúng hình dạng sóng  $\sin(x)$  — không còn zigzag hay gãy khúc như trước.

**Vì sao?** Vì ta đang dùng **ndarray** thay vì **list**, và đặc biệt:

- Có thể chọn bước nhỏ (**step = 0.1, 0.01, 0.001** tùy ý)
- Tận dụng được khả năng vector hóa của NumPy

**Ghi nhớ**

`np.arange()` không chỉ là bản mở rộng của `range()` — nó là một công cụ được thiết kế đặc biệt cho tính toán số học, xử lý dữ liệu hiệu suất cao, và trực quan hóa chuyên sâu.

Trong phần tiếp theo, ta sẽ phân tích kỹ hơn: **Tại sao việc làm mượt đồ thị lại quan trọng ?**

**1.3.3. Ứng dụng: Vì sao phải làm mượt đồ thị?**

Sau khi đã có công cụ mạnh như `np.arange()`, câu hỏi tiếp theo là:

**Làm mượt đồ thị có thật sự cần thiết, hay chỉ để... nhìn cho đẹp?**

Câu trả lời là: **Không chỉ để đẹp** — mà là để:

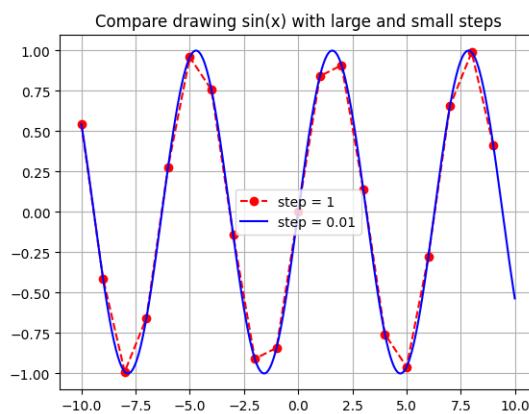
- Thấy được bản chất liên tục của hàm số hoặc dữ liệu.
- Tránh hiểu nhầm do lấy mẫu thưa (under-sampling).
- Phân tích, kiểm chứng mô hình AI chính xác hơn.
- Truyền đạt ý tưởng một cách rõ ràng và thuyết phục.

**Ví dụ:**

```

1 x1 = np.arange(-10, 10, 1)      # 21 points
2 x2 = np.arange(-10, 10, 0.01)    # 2000 points
3 y1 = np.sin(x1)
4 y2 = np.sin(x2)
5
6 plt.plot(x1, y1, 'ro--', label='step = 1')
7 plt.plot(x2, y2, 'b-', label='step = 0.01')
8 plt.title("Compare drawing sin(x) with large and small steps")
9 plt.legend()
10 plt.grid(True)
11 plt.show()

```



**Quan sát:** Khi bước là 1, sóng sin trông như răng cưa — gần như mất tính liên tục. Chỉ khi sampling dày (step nhỏ), đồ thị mới "trở về đúng bản chất".

## Từ gốc nhìn học thuật: Sampling density và Định lý Nyquist

Theo định lý Nyquist–Shannon trong xử lý tín hiệu:

### Định lý Nyquist

Một hàm số liên tục (band-limited signal) chỉ có thể được tái tạo chính xác nếu được lấy mẫu với tần số ít nhất gấp đôi tần số cao nhất của nó.

⇒ Nếu lấy quá ít điểm (sampling thưa), tín hiệu sẽ bị **aliasing** — tức là nhầm sai bản chất. Điều này cũng xảy ra khi chúng ta "plot sai" hàm số.

#### Ví dụ:

- Hàm sin có tính tuần hoàn — nếu vẽ thiếu điểm, ta không thấy sóng, chỉ thấy zigzag.
- Trong học máy, loss curve vẽ thưa có thể làm ta nghĩ mô hình dao động, trong khi thực ra nó đang học tốt.

## Trong AI/ML, đồ thị mượt = hiểu sâu mô hình

Làm mượt đồ thị không chỉ giúp trực quan hóa đẹp hơn — mà còn đóng vai trò then chốt trong việc:

- Phân tích hành vi học của mô hình.
- Phát hiện lỗi mô hình (bug, overfitting, underfitting).
- Đưa ra quyết định như tuning, early stopping, chọn threshold, v.v.

Dưới đây là các tình huống cụ thể mà một đồ thị mượt có thể thay đổi toàn bộ cách chúng ta đánh giá mô hình:

#### Ví dụ 1: Vẽ Loss Curve

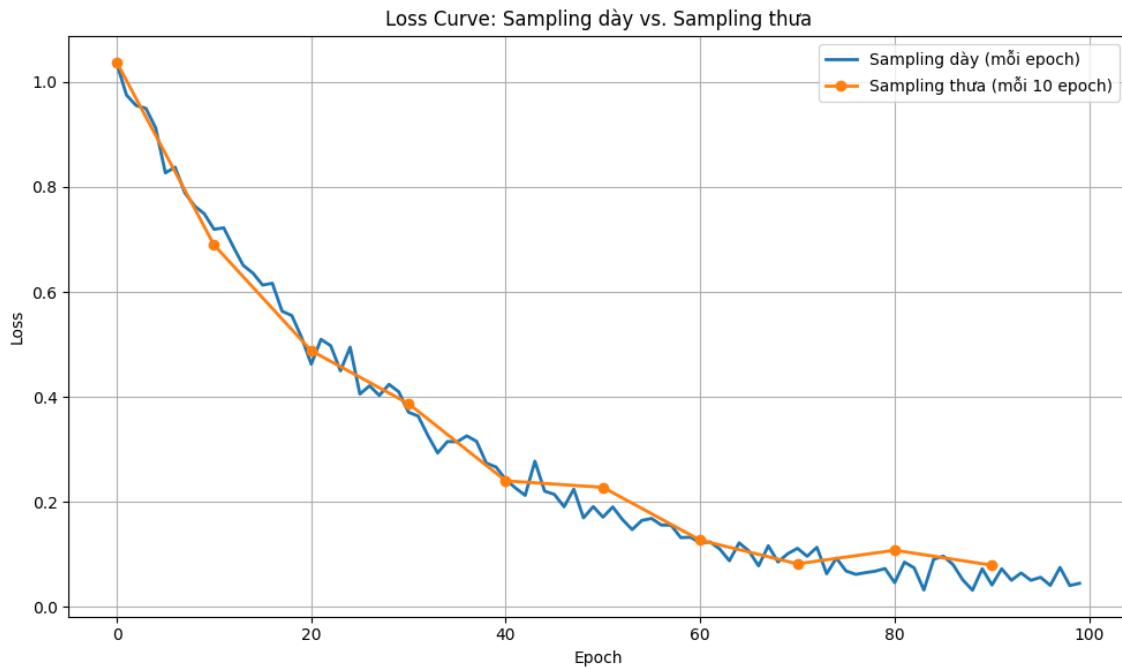
Giả sử chúng ta đang train một mô hình neural network. Nếu chỉ vẽ loss mỗi 10 epoch, sampling thưa:

```
1 epochs = range(0, 100, 10)
```

→ Đường loss trông như đang nhảy loạn. Ta có thể tưởng là mô hình đang học tệ và dừng sớm. Nhưng nếu vẽ từng epoch, sampling dày hơn:

```
1 epochs = range(0, 100, 1)
```

→ Ta sẽ thấy loss giảm đều đặn → mô hình đang học rất ổn.



Loss Curve: Sampling thưa vs. Sampling dày.

### Nhận xét:

- Sampling thưa (mỗi 10 epoch) khiến đường loss bị giật cục, có thể hiểu sai rằng mô hình học không ổn định.
- Sampling dày (mỗi epoch) thể hiện rõ mô hình đang học tốt với loss giảm đều theo thời gian.

### Ví dụ 2: Biên phân lớp (Decision Boundary)

Giả sử chúng ta dùng SVM hoặc MLP để phân loại dữ liệu 2 chiều. Để minh họa ranh giới phân lớp, ta cần tạo lưới điểm để predict. Nếu tạo lưới quá thưa:

```
1 xx, yy = np.meshgrid(np.arange(-5, 5, 1),
2                         np.arange(-5, 5, 1)) # sparse grid
```

→ Đường ranh giới sẽ răng cưa, sai lệch, thậm chí mất kết nối.

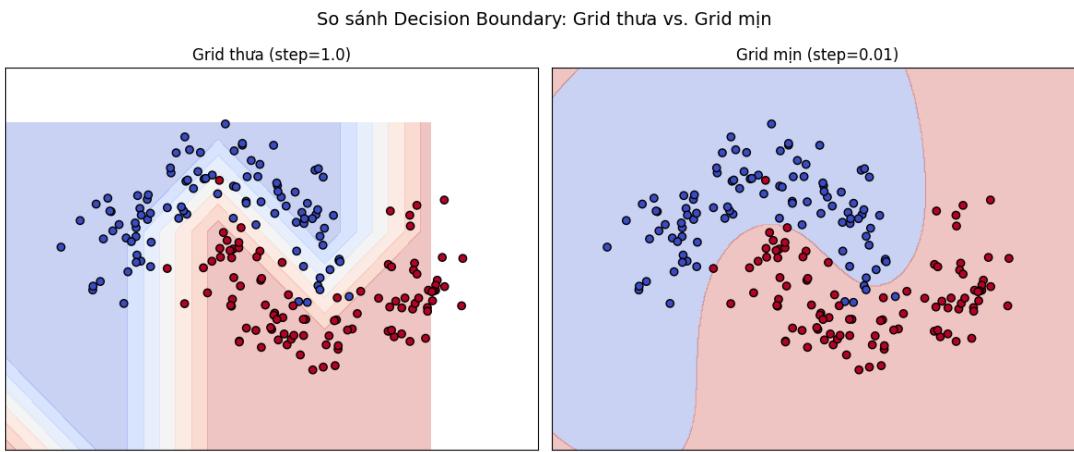
Nếu làm mượt:

```
1 xx, yy = np.meshgrid(np.arange(-5, 5, 0.01),
2                         np.arange(-5, 5, 0.01)) # smooth grid
```

→ Biên phân lớp hiện rõ, chúng ta hiểu cách mô hình "suy nghĩ" như thế nào :v

### Nhận xét:

- Trái:* Grid thưa (step = 1.0) khiến đường ranh giới bị răng cưa, mất chi tiết.
- Phải:* Grid mịn (step = 0.01) cho thấy biên phân lớp mượt mà, giúp ta hiểu rõ cách mô hình phân biệt hai lớp.



Biên phân lớp với grid thưa và grid mịn

**Ví dụ 3: Hàm sigmoid bị hiểu nhầm**

Hàm sigmoid:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Nếu chúng ta vẽ chỉ với 5 điểm:

```
1 x = np.linspace(-5, 5, 5)
2 y = 1 / (1 + np.exp(-x))
```

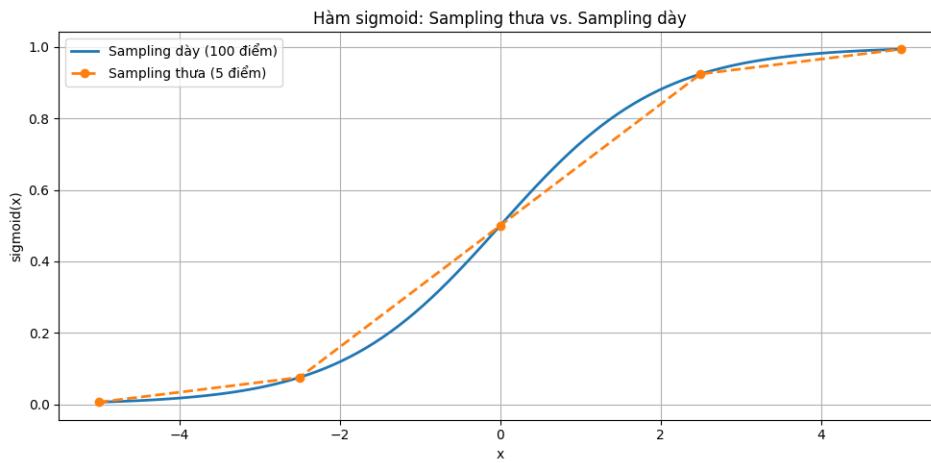
→ Đường cong trông gần như tuyến tính!

Nếu vẽ 100 điểm:

```
1 x = np.linspace(-5, 5, 100)
```

→ Chúng ta mới thấy được:

- Vùng tuyến tính ở giữa
- Vùng bao hoà hai bên



Hàm sigmoid: Sampling thưa vs. Sampling dày

### Nhận xét:

- Sampling thừa (5 điểm) khiến đường cong trông gần như tuyến tính → dễ hiểu nhầm bản chất hàm sigmoid.
- Sampling dày (100 điểm) thể hiện rõ vùng tuyến tính ở giữa và vùng bao hòa hai bên.

### Nguyên tắc

*Đồ thị là tiếng nói của mô hình. Nếu bạn không sampling đủ dày, bạn đang bịt miệng nó.*

### Tóm lại:

- Làm mượt đồ thị không chỉ giúp đồ thị "đẹp", mà là một bước **thiết yếu** trong phân tích dữ liệu hiện đại.
- Nhờ `np.arange()`, ta có thể sampling với độ phân giải cao, từ đó nhìn ra những điều mà list và `range()` không thể.
- Đây là lý do vì sao bất cứ ai làm AI, khoa học dữ liệu, mô phỏng vật lý, v.v. đều xem `np.arange()` như vũ khí đầu tay.

## 1.4. Tạo mảng dựa trên mảng khác

Khi muốn tạo mảng giống `shape` và `dtype` của một mảng đã có:

- `np.zeros_like(array)`, `np.ones_like(array)`
- `np.full_like(array, fill_value)`

### Code minh họa:

```

1 a = np.array([[1, 2, 3], [4, 5, 6]])
2
3 np.zeros_like(a)      # [[0, 0, 0], [0, 0, 0]]
4 np.full_like(a, -1)   # [[-1, -1, -1], [-1, -1, -1]]
```

### Ứng dụng trong xử lý ảnh

Trong xử lý ảnh, một tác vụ rất thường gặp là tạo một **mặt nạ (mask)** — thường là mảng 0–1 có cùng `shape` với ảnh gốc — để đánh dấu các vùng cần xử lý (ví dụ: vùng sáng, vật thể, biên cảnh...).

### Khởi tạo mask cùng shape với ảnh

- `np.zeros_like(image)` — tạo mặt nạ toàn 0
- `np.ones_like(image)` — tạo mặt nạ toàn 1
- `np.full_like(image, value)` — tạo mặt nạ với giá trị tùy ý

### Ví dụ: Tạo mask vùng sáng trong ảnh grayscale

```

1 import numpy as np
2 import cv2
3
4 # grayscale image
5 image = cv2.imread('/content/
    NewBackground.jpg', 0)
6
7 # Tao mask: vung sang (pixel > 180)
8 mask = np.zeros_like(image)
9 mask[image > 180] = 1
10
11 # Ap dung mask: giam do sang vung sang di
    50 don vi
12 output = image.copy()
13 output[mask == 1] = \
14 np.clip(output[mask == 1] - 50, 0, 255)
15
16 print(mask.shape == image.shape)
17 print(mask)

```

===== Output =====

```

True
[[0 0 0 ... 0 0 0]
 [0 0 0 ... 0 0 0]
 [0 0 0 ... 0 0 0]
 ...
 [0 0 0 ... 0 0 0]
 [0 0 0 ... 1 0 0]
 [0 0 0 ... 0 0 0]]

```

- Bây giờ mask là ma trận 0–1 có cùng kích thước với ảnh gốc.
- Có thể dùng để tô vùng sáng, đếm pixel, làm attention mask, hoặc tách foreground (đối tượng).



Minh họa ba bước xử lý ảnh:

(1) ảnh gốc, (2) tạo mask vùng sáng (pixel > 180), và (3) làm tối vùng sáng bằng mask.

#### Cách làm này thường dùng trong:

- Làm mờ hậu cảnh, làm nổi bật foreground (đối tượng).
- Data augmentation trong segmentation.
- Xử lý ảnh y tế hoặc ảnh vệ tinh RGB.

#### Tóm lại:

Tính năng	Ứng dụng cụ thể
np.zeros_like(image)	Tạo mask nhanh
Dùng trong	Segment ảnh, xử lý vùng sáng, masking trong CNN
Ưu điểm	Ngắn gọn, đúng kiểu dữ liệu, không cần chỉ định shape

## 1.5. Tạo array bằng hàm sinh nội dung

- `np.fromiter(iterable, dtype)` – tạo array từ iterable.
- `np.fromfunction(func, shape)` – sinh array từ hàm nhận index (i,j,...).

Code minh họa:

```

1 arr1 = np.fromiter((i**2 for i in range
2   (5)), dtype=int)
3 print('arr1: ', arr1)
4 arr2 = np.fromfunction(lambda i, j: i + j
5   , (3, 3), dtype=int)
6 print('arr2: \n', arr2)

```

```

=====
Output =====
arr1: [ 0  1  4  9 16]
arr2:
[[0 1 2]
 [1 2 3]
 [2 3 4]]

```

## 1.6. Tạo mảng ngẫu nhiên với `np.random`

NumPy cung cấp một module mạnh mẽ là `np.random` để sinh mảng ngẫu nhiên theo nhiều phân phối khác nhau: đồng đều, chuẩn (Gaussian), rời rạc (int), nhị phân... Việc sinh mảng ngẫu nhiên đặc biệt hữu ích trong:

- Sinh dữ liệu giả để test mô hình.
- Khởi tạo trọng số ban đầu cho mô hình AI.
- Mô phỏng xác suất – thống kê.

### 1.6.1. Sinh mảng phân phối đều

- `np.random.rand(d0, d1, ...)` → sinh các số thực phân phối đều trên [0, 1], dạng float.
- `np.random.uniform(low, high, size)` → sinh số thực trong đoạn [low, high].

Code minh họa:

```

1 np.random.rand(2, 3)           # [[0.54, 0.71, 0.60], ...]
2 np.random.uniform(10, 20, 5)    # [11.23, 17.88, 15.12, ...]

```

### 1.6.2. Sinh mảng phân phối chuẩn (Gaussian)

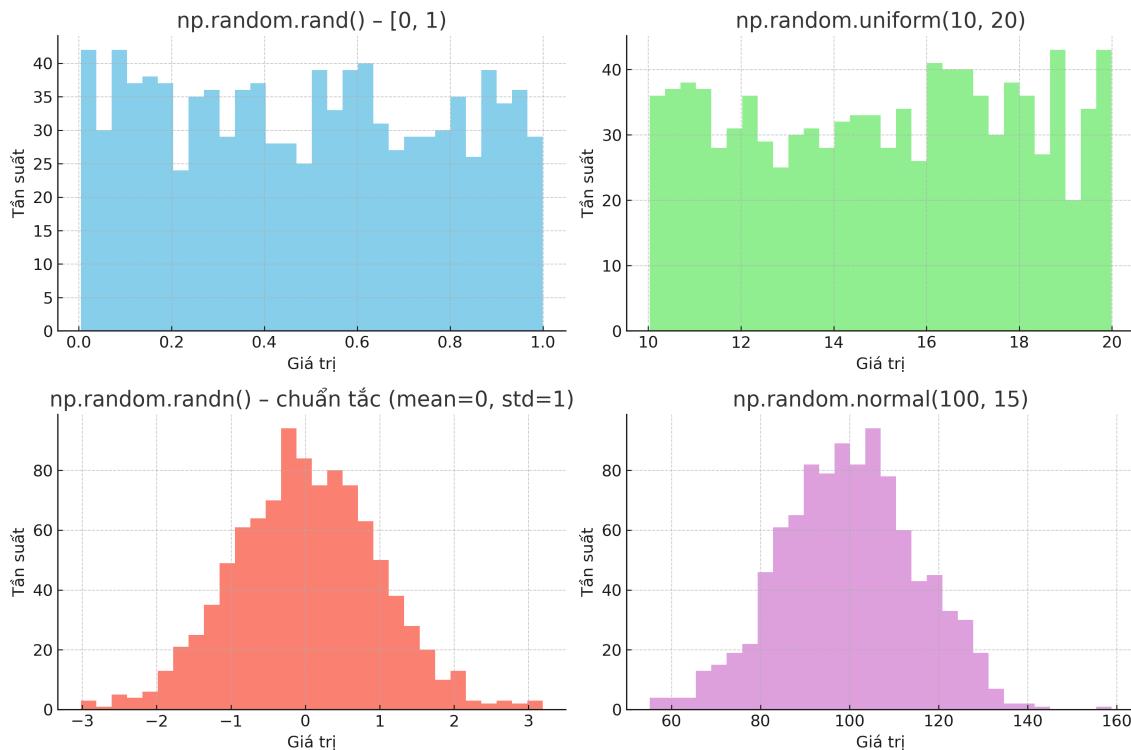
- `np.random.randn(d0, d1, ...)` → phân phối chuẩn chuẩn tắc (mean = 0, std = 1).
- `np.random.normal(loc, scale, size)` → phân phối chuẩn tổng quát.

Code minh họa:

```

1 np.random.randn(3)             # [ 0.21, -0.89, 1.45]
2 np.random.normal(loc=100, scale=15, size=(2, 2))
3 # [[92.1, 108.4], [103.5, 96.7]]

```



Hàng trên: Mô phỏng phân phối đều, dữ liệu có dạng hình chữ nhật

Hàng dưới: Mô phỏng phân phối chuẩn, dữ liệu có dạng hình chuông

### 1.6.3. Sinh số ngẫu nhiên

`np.random.randint(low, high, size)` → Sinh số ngẫu nhiên rời rạc từ `low` đến `high-1`.

Code minh họa:

```

1 np.random.randint(0, 10, size=(3, 3))
2 # [[6, 2, 8],
3 #  [1, 9, 5],
4 #  [0, 4, 3]]
```

### 1.6.4. Sinh mảng nhị phân, chọn ngẫu nhiên

- `np.random.choice(a, size)` – lấy mẫu ngẫu nhiên từ 1D array `a`.
- `np.random.binomial(n, p, size)` – mô phỏng phân phối nhị phân (Bernoulli trials).

Code minh họa:

```

1 np.random.choice([10, 20, 30], size=5)
2 # [30, 10, 10, 20, 30]
3
4 np.random.binomial(n=10, p=0.5, size=5)
5 # [4, 5, 6, 3, 7]
```

### 1.6.5. Thiết lập seed để tái lập kết quả

Khi làm việc với số ngẫu nhiên, nếu muốn kết quả có thể lặp lại ở các lần chạy khác nhau (ví dụ để debug), chúng ta nên đặt “hạt giống” (seed):

**Code minh họa:**

```
1 np.random.seed(42)
2 np.random.rand(3)      # Always return the same result
```

**Ghi chú:**

- Kể từ NumPy 1.17, có thể dùng Generator mới: `np.random.default_rng(seed)` — ưu tiên dùng trong ứng dụng nghiêm túc.
- Ví dụ:

```
1 rng = np.random.default_rng(seed=123)
2 rng.integers(0, 10, size=4)      # Thay cho np.random.randint
```

**Tổng kết:**

Hàm	Mục đích
<code>rand, uniform</code>	Số thực đồng đều
<code>randn, normal</code>	Số thực chuẩn
<code>randint, integers</code>	Số nguyên
<code>choice, binomial</code>	Lấy mẫu, mô phỏng
<code>seed, default_rng</code>	Điều khiển tính ngẫu nhiên

### 1.6.6. Ứng dụng thường gặp:

- Sinh dữ liệu test cho thuật toán.
- Sinh trọng số ban đầu trong mạng nơ-ron.
- Mô phỏng rút thăm, xác suất, thống kê Monte Carlo.

Tiếp theo là phần thú vị nhất của mục này, chúng ta sẽ cùng đi qua một số ví dụ áp dụng những lý thuyết khá lâng nhàng ở trên.

#### Ví dụ 1: Sinh dữ liệu giả để kiểm thử mô hình phân loại ung thư

Giả sử ta đang phát triển một mô hình học máy phân loại ung thư tuyến vú (benign vs. malignant), nhưng chưa có dữ liệu thật. Ta có thể sử dụng `np.random` để mô phỏng dữ liệu đầu vào và nhãn mục tiêu.

**Tạo dữ liệu giả cho 100 bệnh nhân, mỗi người có 2 đặc trưng (feature):**

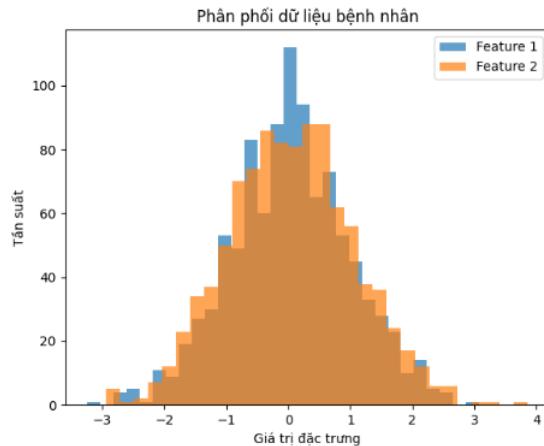
```
1 X = np.random.normal(loc=0, scale=1, size=(100, 2))  # Input Data
2 y = np.random.randint(0, 2, size=100)                 # Label
```

Trong đó:

- `X` là mảng  $(100, 2)$  mô phỏng đặc trưng chuẩn hóa (ví dụ: kích thước khối u, mật độ mô).

- $y$  là mảng nhän nhị phân, cho biết mỗi bệnh nhân là lành hay ác tính: 0 = lành tính, 1 = ác tính.

Mô hình học máy (như Logistic Regression hoặc SVM) có thể được huấn luyện trên dữ liệu này để kiểm tra pipeline, debugging, hoặc đánh giá thuật toán trước khi áp dụng vào dữ liệu thật.



Hình 1: Phân phối dữ liệu bệnh nhân: hai đặc trưng mô phỏng theo phân phối chuẩn

### Ví dụ 2: Khởi tạo trọng số ban đầu cho mô hình mạng nơ-ron chẩn đoán võng mạc

Trong deep learning, việc khởi tạo trọng số ban đầu có ảnh hưởng rất lớn đến khả năng hội tụ của mô hình. Ví dụ dưới đây mô phỏng việc khởi tạo trọng số cho một lớp fully-connected trong mô hình phát hiện bệnh võng mạc tiểu đường từ ảnh mắt.

```

1 # Dense layer: 512 input (from image) → 128 output neurons
2 W = np.random.normal(loc=0.0, scale=0.01, size=(512, 128))    # Initial weight
3 b = np.zeros(128)                                              # Bias initialized to 0

```

Trong đó:

- $W$  là ma trận trọng số với các giá trị nhỏ quanh 0 (theo phân phối chuẩn), giúp tránh gradient quá lớn/nhỏ.
- $b$  là vector bias khởi tạo bằng 0, một cách làm phổ biến.

Các trọng số này sẽ được tối ưu trong quá trình huấn luyện để mô hình học cách phân biệt bệnh – không bệnh dựa trên đặc trưng hình ảnh.

### Ví dụ 3: Mô phỏng hiệu quả vaccine bằng thống kê Monte Carlo

Trong dịch tễ học, ta thường mô phỏng hiệu quả vaccine thông qua phương pháp thống kê. Ví dụ: nếu một loại vaccine có hiệu quả 70%, thì mỗi người có 70% cơ hội được bảo vệ.

Ta có thể mô phỏng kết quả tiêm cho 10.000 người như sau:

```

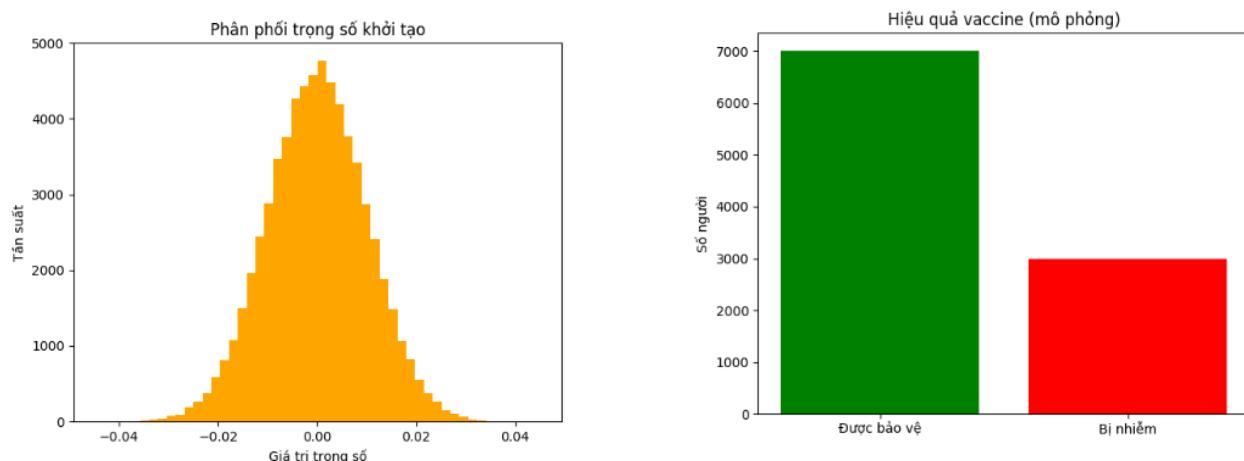
1 # 1 = not infected after vaccination, 0 = still infected
2 outcome = np.random.binomial(n=1, p=0.7, size=10_000)
3
4 # Calculate the actual protection rate
5 protection_rate = np.mean(outcome)
6 print(f"Protection rate: {protection_rate:.2%}")

```

Giải thích:

- `np.random.binomial(n=1, p=0.7)` mô phỏng 1 thử nghiệm Bernoulli: 70% khả năng thành công.
- Lặp lại 10.000 lần sẽ cho phân phối kết quả tiêm thực tế.
- Lấy trung bình để ước lượng hiệu quả vaccine trên quy mô lớn.

Phương pháp này gọi là **Monte Carlo simulation** và được dùng rộng rãi trong thống kê, khoa học dữ liệu và nghiên cứu chính sách y tế.



Trái: Phân phối trọng số mạng nơ-ron: trọng số khởi tạo nhỏ quanh 0

Phải: Mô phỏng hiệu quả vaccine: gần 70% người được bảo vệ theo giả định

#### 6.6.7. Tổng kết:

Hàm	Mô tả ngắn
<code>np.array</code>	Tạo từ list / tuple
<code>np.zeros</code>	Mảng toàn 0
<code>np.ones</code>	Mảng toàn 1
<code>np.full</code>	Mảng toàn giá trị bất kỳ
<code>np.arange</code>	Dãy cách đều, bước tùy ý
<code>np.linspace</code>	Dãy chia đều số lượng phần tử
<code>np.empty</code>	Cấp phát nhưng không khởi tạo
<code>np.eye</code>	Ma trận đơn vị
<code>np.fromiter</code>	Từ iterable
<code>np.fromfunction</code>	Sinh từ chỉ số hàm
<code>*_like()</code>	Khởi tạo theo mảng đã có

**Ghi chú:** Việc dùng đúng hàm tạo phù hợp không chỉ giúp viết code “Pythonic” mà còn đảm bảo hiệu suất xử lý tốt nhất khi làm việc với dữ liệu lớn.

## 2. Read

Trong bất kỳ thao tác xử lý dữ liệu nào, sau khi tạo và lưu trữ mảng (Create), bước tiếp theo tự nhiên là đọc và truy xuất dữ liệu từ đó. Ở NumPy, việc “đọc” không đơn thuần là in ra một giá trị — mà là cả một hệ thống kỹ thuật mạnh mẽ giúp ta lấy ra phần tử, lát cắt, hoặc cấu trúc con trong mảng nhiều chiều. Việc truy xuất dữ liệu hiệu quả sẽ quyết định độ mượt của toàn bộ pipeline xử lý.

Phần này sẽ trình bày chi tiết về cách **Read – truy xuất dữ liệu** trong ndarray, mở đầu với một kỹ thuật cực kỳ quan trọng: **Indexing**.

### 2.1. Kỹ thuật Indexing

Khi muốn lấy ra một phần dữ liệu trong mảng — dù là một số, một dòng, một cột hay cả một khối 3D — ta phải biết cách “**chỉ tay vào chỗ cần thiết**”.

Đó chính là nhiệm vụ của **Indexing**.

Hiểu đơn giản, Indexing là **ngôn ngữ để truy cập dữ liệu trong ndarray**, giống như cách ta dùng địa chỉ để tìm đến một ngôi nhà.

Trong phần này, ta sẽ đi sâu vào **các dạng Indexing** trong NumPy – được chia thành 3 nhánh chính:

- Scalar
- Basic Slicing
  - Dấu `:`
  - None / np.newaxis
  - Số nguyên đơn
- Advanced / Fancy Indexing
  - int-array
  - boolean-mask

#### I. Scalar Indexing

##### Định nghĩa

**Scalar indexing** là kỹ thuật truy xuất một phần tử đơn lẻ trong mảng NumPy bằng cách sử dụng các **chỉ số nguyên đơn** (int) ứng với từng chiều của mảng.

- Với mảng 1 chiều: chỉ cần 1 chỉ số.
- Với mảng 2 chiều trở lên: cần **1 chỉ số cho mỗi chiều**.

### Cú pháp

- `arr[i]`: Truy xuất phần tử thứ i của mảng 1D
- `arr[i, j]`: Truy xuất phần tử tại dòng i, cột j của mảng 2D
- `arr[i, j, k]`: Truy xuất phần tử tại (i, j, k) trong mảng 3D

### Giải thích:

- `arr[3]` với mảng 1 chiều là truy xuất phần tử tại chỉ số 3.
- `arr[1, 2]` với mảng 2 chiều là truy xuất phần tử dòng 1, cột 2.
- Các chỉ số bắt đầu từ 0, như trong Python nói chung.

### Đặc điểm:

- Trả về một bản **sao chép (copy)** của phần tử, không phải view.
- Việc gán lại giá trị cho biến sau khi scalar indexing **không ảnh hưởng đến mảng gốc**.
- Truy xuất rất nhanh, hiệu quả trong các phép toán đơn giản.

### Ví dụ minh họa:

```

1 import numpy as np
=====
2
3 a = np.array([[1, 2, 3],
4               [4, 5, 6]])
5 print('a before:\n', a)
6
7 # Get element at row 0, column 1 → x = 2
8 x = a[0, 1]
9 # Reassign x value, does not affect 'a'
10 x = 100
11
12 # Array a remains the same
13 print('a after:\n', a)
===== Output =====
a before:
[[1 2 3]
 [4 5 6]]
a after:
[[1 2 3]
 [4 5 6]]
```

### Giải thích:

- Biến `a` là một mảng NumPy 2 chiều, kích thước (2, 3).
- Lệnh `a[0, 1]` truy xuất phần tử tại dòng 0, cột 1, tức là giá trị 2.
- Biến `x` nhận bản sao (copy) của phần tử đó. Khi viết `x = 100`, chỉ có `x` thay đổi, còn mảng `a` hoàn toàn không bị ảnh hưởng.
- Việc này chứng minh rằng **scalar indexing trả về copy**, không phải là view liên kết với mảng gốc.

Nếu chỉ cần lấy một phần tử cụ thể từ mảng mà không muốn ảnh hưởng đến mảng gốc, scalar indexing là lựa chọn đơn giản và hiệu quả nhất.

## II. Basic Slicing – Truy xuất lát cắt

Slicing trong NumPy là một trong những kỹ thuật cơ bản nhưng vô cùng mạnh mẽ giúp ta truy xuất từng phần trong mảng (array) theo nhiều chiều. Nó không chỉ hỗ trợ thao tác lấy dòng/cột, mà còn cho phép tạo ra **view** linh hoạt, giúp thay đổi dữ liệu gốc một cách hiệu quả.

### a) Cú pháp chung

#### Cú pháp Basic Slicing

```
arr[start:stop:step]
```

Ý nghĩa các tham số:

- **start** – Chỉ số bắt đầu (mặc định = 0).
- **stop** – Chỉ số kết thúc **không bao gồm chính nó** (mặc định = chiều dài mảng).
- **step** – Bước nhảy (mặc định = 1, có thể âm để đi ngược).

Các dạng phổ biến:

- `:` – Lấy toàn bộ theo chiều đó (`start=0, stop=len, step=1`).
- `a:b` – Lấy từ chỉ số `a` đến `b-1`.
- `::step` – Lấy toàn bộ nhưng theo bước nhảy (ví dụ: `[:-1]` để đảo ngược).
- Có thể áp dụng cho nhiều chiều cùng lúc:  
`arr[row_start:row_stop, col_start:col_stop]`.

Ví dụ:

```
1 import numpy as np
2 a = np.array([0, 1, 2, 3, 4, 5])
3
4 print(a[:])          # Toan bo
5 print(a[1:4])        # Tu index 1 den 3
6 print(a[::2])         # Cach 2 buoc
7 print(a[::-1])        # Dao nguoc
```

```
=====
Output =====
[0 1 2 3 4 5]
[1 2 3]
[0 2 4]
[5 4 3 2 1 0]
```

### b) View hay Copy? Mutable hay Immutable?

#### View hay Copy?

**Basic Slicing trả về VIEW:**

- Không tạo bản sao (copy), chỉ tạo một "cửa sổ nhìn" vào mảng gốc.
- Thay đổi dữ liệu trong slice sẽ làm thay đổi mảng gốc vì chúng chia sẻ cùng vùng nhớ.

**Fancy Indexing hoặc Masking trả về COPY:**

- Tạo ra một mảng mới độc lập.
- Thay đổi mảng con không ảnh hưởng mảng gốc.

### Ví dụ minh họa View:

```

1 a_arr = np.array([[1,2,3],
2                  [5,6,7]])
3
4 # Lay cot 1 va 2 (slicing)
5 b_arr = a_arr[:, 1:3]
6
7 b_arr[0,0] = 99      # Thay doi phan tu
8   trong b_arr
8 print(a_arr)

```

```
=====
Output =====
[[ 1 99  3]
 [ 5  6  7]]
```

### Giải thích:

`b_arr` chỉ là **view**, trỏ tới cùng vùng nhớ với `a_arr`. Vì vậy, thay đổi giá trị trong `b_arr` cũng làm thay đổi `a_arr`.

### Ví dụ minh họa Copy (để so sánh):

```

1 c_arr = a_arr[:, [1,2]]    # Fancy
2   Indexing (int-array)
3 c_arr[0,0] = 555
3 print(a_arr)              # Khong thay
   doi

```

```
=====
Output =====
[[ 1 99  3]
 [ 5  6  7]]
```

### Giải thích:

`c_arr` là **copy**, hoạt động độc lập với mảng gốc.

### c) Dấu ":" (colon)

#### Dấu ":" trong Slicing

Dấu `:` là cú pháp quan trọng nhất trong slicing. Nó cho phép:

- Lấy toàn bộ theo chiều đó: `arr[:]`.
- Chỉ định khoảng: `arr[start:stop]` (từ `start` đến `stop-1`).
- Kết hợp bước nhảy: `arr[start:stop:step]`.
- Có thể dùng `step` âm để đảo ngược thứ tự: `arr[::-1]`.

**Mặc định:** `start = 0, stop = len(arr), step = 1.`

### Ví dụ cơ bản (1 chiều):

```

1 import numpy as np
2 a = np.array([0, 1, 2, 3, 4, 5])
3
4 print(a[:])          # Toan bo mang
5 print(a[1:4])        # Tu index 1 den 3
6 print(a[::-2])        # Buoc nhay 2
7 print(a[::-1])        # Dao nguoc

```

```
===== Output =====
[0 1 2 3 4 5]
[1 2 3]
[0 2 4]
[5 4 3 2 1 0]
```

### Ảnh hưởng tới mảng gốc (View):

```

1 b = a[1:4]    # Lay view tu index 1 -> 3
2 b[0] = 100
3 print("a:", a)

```

```
===== Output =====
a: [ 0 100 2 3 4 5]
```

**Giải thích:** b là **view**, thay đổi b sẽ ảnh hưởng trực tiếp đến a.

### Ví dụ nhiều chiều:

```

1 m = np.array([[1, 2, 3],
2                 [4, 5, 6],
3                 [7, 8, 9]])
4
5 print(m[:2, 1:])    # Lay 2 dong dau, tu
                      cot 1 tro di

```

```
===== Output =====
[[2 3]
 [5 6]]
```

### d) Số nguyên đơn (giảm chiều)

Số nguyên đơn trong Slicing

Khi dùng số nguyên đơn (thay vì dấu :) trên một chiều:

- Chiều đó sẽ bị **co lại** (mất 1 chiều trong shape).
- Trả về trực tiếp phần tử (nếu tất cả các chiều đều là số nguyên đơn).

**Lưu ý:** Nếu muốn giữ nguyên số chiều (2D, 3D...), nên dùng slicing với dấu :.

### Ví dụ cơ bản:

```

1 a = np.array([[10, 20, 30],
2                 [40, 50, 60]])
3
4 print(a[1])      # Dong 1: co lai thanh
                      vector 1D
5 print(a[1, 2])   # Phan tu dong 1, cot 2

```

```
===== Output =====
[40 50 60]
60
```

### Giữ nguyên số chiều:

```

1 row_2d = a[1:2, :] # Giữ nguyên dạng ma
        tran 2D
2 print(row_2d, "| shape:", row_2d.shape)

```

```
===== Output =====
[[40 50 60]] | shape: (1, 3)
```

Bảng so sánh nhanh:

Cú pháp	Kết quả	Shape
a[1]	Vector 1D (co chiều)	(3,)
a[1:2, :]	Ma trận 2D (giữ nguyên)	(1, 3)

### e) None hoặc np.newaxis – Thêm chiều mới

Thêm chiều mới với None / np.newaxis

#### Mục đích:

- Biến đổi shape của mảng bằng cách chèn thêm một chiều có kích thước = 1.
- Rất hữu ích trong Machine Learning khi cần:
  - Chuyển vector 1D thành ma trận cột ( $n, 1$ ) hoặc ma trận hàng ( $1, n$ ).
  - Thêm chiều batch cho dữ liệu (ví dụ: ( $H, W$ )  $\rightarrow (1, H, W)$ ).

#### Cách sử dụng:

- np.newaxis và None hoạt động như nhau.
- Cú pháp: arr[:, np.newaxis] hoặc arr[np.newaxis, :] tùy muốn thêm chiều ở đâu.

#### Ví dụ minh họa:

```

1 import numpy as np
2
3 a = np.array([1, 2, 3])
4 print("Original shape:", a.shape)
5
6 # Them chieu moi thanh ma tran cot
7 a_col = a[:, np.newaxis]
8 print("Column shape:", a_col.shape)
9 print(a_col)
10
11 # Them chieu moi thanh ma tran hang
12 a_row = a[np.newaxis, :]
13 print("Row shape:", a_row.shape)
14 print(a_row)

```

```
===== Output =====
Original shape: (3,)
Column shape: (3, 1)
[[1]
 [2]
 [3]]
Row shape: (1, 3)
[[1 2 3]]
```

#### Giải thích:

- a[:, np.newaxis]  $\rightarrow$  Thêm chiều mới ở **cuối**, biến vector thành ma trận cột.

- `a[np.newaxis, :]` → Thêm chiều mới ở **đầu**, biến vector thành ma trận hàng.
- Đây chỉ là **view**, không tốn thêm bộ nhớ.

### Ứng dụng thực tế trong ML:

- **Thêm chiều kênh (channel):** Ảnh grayscale thường có shape (H, W), nhưng các CNN yêu cầu có thêm chiều kênh (H, W, 1).
- **Thêm chiều batch:** Một mô hình ML thường nhận batch dữ liệu, kể cả khi chỉ có 1 ảnh. Ta thêm chiều batch thành (1, H, W, 1).

```

1 import numpy as np
2
3 # Simulate 4x4 grayscale image (H, W)
4 img = np.array([[ 10,   20,   30,   40],
5                 [ 50,   60,   70,   80],
6                 [ 90,  100,  110,  120],
7                 [130,  140,  150,  160]])
8
9 print("Original shape:", img.shape)
10
11 # 1) Add channel dimension (H, W, 1)
12 img_channel = img[:, :, np.newaxis]
13 print("After adding channel:", img_channel.shape)
14 print(img_channel)
15
16 # 2) Add batch dimension (1, H, W, 1)
17 img_batch = img_channel[np.newaxis, :, :, :]
18 print("After adding batch:", img_batch.shape)

```

===== Output =====

Original shape: (4, 4)

After adding channel: (4, 4, 1)

[[[ 10]	[ 20]	[ 30]	[ 40]]
[[ 50]	[ 60]	[ 70]	[ 80]]
[[ 90]	[100]	[110]	[120]]
[[130]	[140]	[150]	[160]]]

After adding batch: (1, 4, 4, 1)

### Giải thích:

- `img[:, :, np.newaxis]` – Thêm chiều thứ 3 làm kênh ảnh (channel).
- `img_channel[np.newaxis, :, :, :]` – Thêm chiều thứ nhất làm batch (batch size = 1).

### f) Truy xuất dòng/cột: Vector vs Matrix

Vector vs Matrix khi truy xuất dòng/cột

#### Mục đích:

- NumPy có 2 cách lấy dòng/cột:
  - **Dạng vector (mắt chiều):** Dễ tính toán nhanh.
  - **Dạng matrix (giữ nguyên chiều):** Giữ shape chuẩn (hữu ích trong ML).
- Phân biệt rõ giúp tránh lỗi khi reshape hoặc concatenate.

**Quy tắc:**

- `arr[i, :]` hoặc `arr[:, j]` → Trả về **vector 1D**, mất 1 chiều.
- `arr[i:i+1, :]` hoặc `arr[:, j:j+1]` → Trả về **matrix 2D**, giữ nguyên số chiều.

**Ví dụ minh họa:**

```

1 arr = np.array([[1,2,3],
2                 [5,6,7],
3                 [9,10,11]])
4
5 # Vector vs Matrix - dong
6 row_vec = arr[1, :]      # Vector 1D
7 row_mat = arr[1:2, :]    # Matrix 2D
8
9 # Vector vs Matrix - cot
10 col_vec = arr[:, 1]     # Vector 1D
11 col_mat = arr[:, 1:2]   # Matrix 2D
12
13 print("row_vec shape:", row_vec.shape)
14 print("row_mat shape:", row_mat.shape)
15 print("col_vec shape:", col_vec.shape)
16 print("col_mat shape:", col_mat.shape)

```

```

=====
Output =====
row_vec shape: (3,)
row_mat shape: (1, 3)
col_vec shape: (3,)
col_mat shape: (3, 1)

```

**Bảng so sánh nhanh:**

Cú pháp	Kết quả	Shape
<code>arr[i, :]</code>	Vector dòng 1D (mất chiều)	(n,)
<code>arr[i:i+1, :]</code>	Ma trận dòng 2D (giữ nguyên)	(1, n)
<code>arr[:, j]</code>	Vector cột 1D (mất chiều)	(m,)
<code>arr[:, j:j+1]</code>	Ma trận cột 2D (giữ nguyên)	(m, 1)

**Khi nào cần giữ nguyên 2D?**

- Khi cần nối (concatenate) các dòng/cột với nhau: `np.hstack`, `np.vstack`.
- Khi làm việc với mô hình ML yêu cầu input shape cố định (ví dụ: luôn cần (`batch`, `features`)).

### III. Advanced (Fancy) Indexing – Truy xuất nâng cao

#### a) Integer Array Indexing

Integer Array Indexing – Chỉ số nguyên

**Mục đích:**

- Cho phép chọn các phần tử tại **những vị trí cụ thể** trong mảng bằng mảng chỉ số (list hoặc ndarray).
- Hỗ trợ truy xuất phức tạp: lấy nhiều dòng/cột không liên tiếp, lấy lặp lại phần tử.

**Đặc điểm:**

- Luôn trả về **copy**, không phải view (thay đổi mảng con không ảnh hưởng mảng gốc).
- Có thể sử dụng cho cả mảng 1D và 2D.

**Ví dụ cơ bản (mảng 2D):**

```

1 import numpy as np
2
3 a = np.array([[1, 2],
4               [3, 4],
5               [5, 6]])
6
7 # Lay phan tu tai cac vi tri cu the
8 out1 = a[[0, 2], [1, 0]] # (0,1) va
9   (2,0)
9 print("Selected:", out1)
10
11 # Thay doi truc tiep cac phan tu duoc
12   chon
12 a[[0, 2], [1, 0]] = [100, 200]
13 print("After change:\n", a)
```

```
=====
Output =====
Selected: [2 5]
After change:
[[100  2]
 [ 3   4]
 [200  6]]
```

**Giải thích:**

- $a[[0, 2], [1, 0]]$ :
  - Lấy phần tử ở dòng 0, cột 1  $\rightarrow$  giá trị 2.
  - Lấy phần tử ở dòng 2, cột 0  $\rightarrow$  giá trị 5.
- Gán giá trị mới: phần tử tại (0,1) được gán thành 100, phần tử tại (2,0) thành 200.

**Ví dụ lặp lại phần tử:**

```

1 b = a[[0, 0], [1, 1]] # Lay lap lai
2   (0,1)
2 print(b)
```

```
=====
Output =====
[100 100]
```

## b) Boolean Mask (Filtering)

Boolean Mask (Filtering) – Lọc theo điều kiện

### Mục đích:

- Lọc các phần tử thỏa mãn điều kiện logic.
- Ứng dụng phổ biến trong tiền xử lý dữ liệu: loại bỏ outlier, chọn mẫu theo điều kiện.

### Đặc điểm:

- Tạo một mảng Boolean (True/False) có cùng kích thước với mảng gốc.
- Luôn trả về **copy**, không phải view.

### Ví dụ cơ bản:

```

1 a = np.array([5, 10, 15, 20, 25])
2
3 # Tao mask cho cac phan tu >15
4 mask = a > 15
5 print("Mask:", mask)
6
7 # Loc cac phan tu True
8 filtered = a[mask]
9 print("Filtered:", filtered)

```

```
=====
Output =====
Mask: [False False False  True  True]
Filtered: [20 25]
```

### Giải thích:

- $a > 15$  tạo ra mảng Boolean: [F, F, F, T, T].
- $a[mask]$  chỉ lấy các phần tử có giá trị True.

### Gộp điều kiện logic:

```

1 ## Loc cac phan tu nam trong khoang (10,
   25)
2 mask2 = (a > 10) & (a < 25)
3 print(a[mask2])

```

```
=====
Output =====
[15 20]
```

### Ứng dụng thực tế trong ML:

- Lọc các mẫu ảnh có nhãn cụ thể: `images[labels == 1]`.
- Loại bỏ giá trị bất thường: `data[(data > mean-2*std) & (data < mean+2*std)]`.

## Ghi nhớ

- **Basic Slicing** → Trả về **view**, thay đổi ảnh hưởng mảng gốc.
- **Fancy Indexing (int-array, boolean mask)** → Luôn trả về **copy**, hoạt động độc lập.

## IV. View vs Copy – So sánh nhanh

Loại	Cú pháp tiêu biểu	View hay Copy
Scalar Indexing	<code>arr[1, 2]</code>	Copy
Basic Slicing	<code>arr[1:4], arr[:, 1]</code>	View
<code>np.newaxis</code>	<code>arr[:, None]</code>	View
Fancy Indexing (int-array)	<code>arr[[1, 3]]</code>	Copy
Boolean Mask	<code>arr[arr &gt; 5]</code>	Copy

## V. Tổng kết

- **Basic Slicing** → Trả về view, tiết kiệm bộ nhớ nhưng thay đổi sẽ ảnh hưởng mảng gốc.
- **Fancy Indexing** → Linh hoạt, hỗ trợ truy xuất phức tạp, nhưng luôn tạo copy.
- Dùng `1:2` hoặc `1:2, :` để giữ nguyên shape 2D khi cắt lát.
- Mask Boolean rất hữu ích để lọc dữ liệu trong Machine Learning.

## Tóm tắt nhanh

**Indexing và Slicing** là những kỹ thuật cốt lõi để truy xuất, thay đổi và thao tác dữ liệu trong NumPy. Có 2 nhóm chính:

- **Basic Slicing** – Truy xuất cơ bản bằng dấu `:`, số nguyên đơn hoặc thêm chiều bằng `np.newaxis`.
- **Advanced / Fancy Indexing** – Truy xuất nâng cao bằng mảng chỉ số (int-array) hoặc mask Boolean.

## Quan trọng:

- **Basic Slicing** thường trả về **view** (chung vùng nhớ với mảng gốc).
- **Fancy Indexing** luôn trả về **copy**.

## 3. Update

Update trong ndarray nghĩa là thay đổi giá trị tại một vị trí cụ thể. Do NumPy mảng có chỉ số, ta có thể cập nhật dễ dàng bằng cách truy cập đúng chỉ mục và sử dụng phép gán trực tiếp.

```

1 import numpy as np
2
3 a = np.array([
4     [1, 2, 3],
5     [4, 5, 6]])
6
7 # assign new value
8 a[1,2] = 9999
9
10 print(a)

```

Một tính năng tuyệt vời của NumPy là khả năng cập nhật giá trị có điều kiện bằng cách sử dụng Boolean Indexing . Boolean Indexing cho phép bạn chọn các phần tử từ một mảng dựa trên các điều kiện. Để thực hiện như vậy, trước tiên bạn phải tạo một mảng Boolean bằng cách áp dụng điều kiện cho một mảng NumPy.

```

1 import numpy as np
2
3 a = np.array([
4     [1, 2, 3],
5     [4, 5, 6]
6 ])
7
8 # create boolean array
9 bool_arr = a < 5
10
11 print(bool_arr)

```

Như bạn có thể thấy, chúng ta có được một mảng Boolean có cùng hình dạng với mảng ban đầu. Sau đó, bạn sử dụng mảng Boolean này để lập chỉ mục cho mảng gốc. Chỉ các phần tử có mảng Boolean True mới được chọn. Theo cách này, bạn có thể lọc các phần tử từ một mảng:

```

1 import numpy as np
2
3 a = np.array([
4     [1, 2, 3],
5     [4, 5, 6]
6 ])
7
8 # create boolean array
9 bool_arr = a < 5
10
11 # index 'a' using boolean array
12 print(a[bool_arr])

```

Và tất nhiên, bạn cũng có thể gán các giá trị mới cho các phần tử có điều kiện True. Hãy cập nhật tất cả các giá trị nhỏ hơn 5:

```

1 import numpy as np
2
3 a = np.array([
4     [1, 2, 3],
5     [4, 5, 6]
6 ])
7
8 # create boolean array
9 bool_arr = a < 5
10
11 # update values
12 a[bool_arr] = 9999

```

```
13
14 print(a)
```

Tóm gọn lại, Thay vì thực hiện theo 2 bước, chúng ta có thể lập chỉ mục và áp dụng điều kiện cùng lúc:

```
1 import numpy as np
2
3 a = np.array([
4     [1, 2, 3],
5     [4, 5, 6]
6 ])
7
8 # conditionally update 'a'
9 a[a < 5] = 9999
10
11 print(a)
```

Một cách khác để cập nhật nhiều phần tử trong mảng NumPy là sử dụng slicing. Ví dụ, ở đây chúng ta cập nhật toàn bộ hàng đầu tiên bằng cách cắt lát:

```
1 import numpy as np
2
3 a = np.array([
4     [1, 2, 3],
5     [4, 5, 6]
6 ])
7
8 # update first row
9 a[0, :] = [100, 200, 300]
10
11 print(a)
12 # [[100 200 300] [4 5 6]]
```

Hoặc cập nhập 2 hàng đầu tiên và 2 cột đầu tiên:

```
1 import numpy as np
2
3 a = np.array([
4     [1, 2, 3],
5     [4, 5, 6]
6 ])
7
8 # update first 2 rows and first 2 cols
9 a[:2, :2] = [[9999, 9999], [9999, 9999]]
10
11 print(a)
```

Lưu ý: Đảm bảo rằng hình dạng của mảng bạn gán khớp với hình dạng của lát cắt đã chọn, nếu không, bạn sẽ gặp lỗi ValueError: could not broadcast input array from shape (...) into shape (...).

**Kết luận:** Thay đổi giá trị giữa hai giá trị cụ thể trong một mảng Numpy là một tác vụ phổ biến trong quá trình xử lý trước dữ liệu. Bằng cách sử dụng chỉ mục Boolean, bạn có thể thực hiện việc này một cách hiệu quả và theo cách dễ hiểu. Hãy nhớ luôn cẩn thận khi thay đổi giá trị trong một mảng, vì nó có thể thay đổi dữ liệu của bạn theo những cách mà có thể không nhận thấy ngay lập tức.

## 4. Delete

Hàm numpy.delete() trong Python là một công cụ quan trọng để thao tác mảng. Nó cho phép bạn dễ dàng xóa các phần tử khỏi ndarray, đặc biệt hữu ích trong quá trình xử lý dữ liệu trước, khi bạn có thể cần bỏ qua các điểm dữ liệu hoặc điều chỉnh kích thước tập dữ liệu để tương thích với phân tích.

### **numpy.delete() với Mảng một chiều**

- Xóa các phần tử cụ thể theo chỉ mục

```
1 import numpy as np
2 array_1d = np.array([1, 2, 3, 4, 5])
3 result = np.delete(array_1d, 2)
4 print(result) #3
```

- Xóa nhiều chỉ mục

```
1 array_md = np.array([0, 1, 2, 3, 4, 5, 6])
2 result = np.delete(array_md, [1, 3, 5])
3 print(result) #0,2,4,6
```

### **numpy.delete() với Mảng đa chiều**

- Xóa toàn bộ một hàng hoặc một cột

```
1 array_2d = np.array([[1, 2], [3, 4], [5, 6]])
2 result_row = np.delete(array_2d, 1, axis=0)
3 result_column = np.delete(array_2d, 0, axis=1)
4 print("After deleting row:", result_row)
5 print("After deleting column:", result_column)
```

Trong ví dụ này, hàng 1 và cột 0 được xóa khỏi mảng 2D array\_2d. Hàm này sửa đổi cấu trúc mảng theo trực tiếp được chỉ định.

- Xóa tuần tự từ nhiều trực

```
1 array_3d = np.array([[[1, 2], [3, 4]], [[5, 6], [7, 8]], [[9, 10], [11, 12]]])
2 step1 = np.delete(array_3d, 0, axis=0) # Deletes the first block of 2D array
3 result = np.delete(step1, 1, axis=1) # Deletes the second column from each 2D
   block
4 print(result)
```

Trong đoạn mã này, việc xóa diễn ra tuần tự trên các trực khác nhau trong một mảng 3D. Ban đầu, toàn bộ mảng con 2D đầu tiên bị xóa, sau đó là cột thứ hai của mảng con còn lại.

Hàm numpy.delete() trong Python có thể ảnh hưởng sâu sắc đến cách bạn thao tác và xử lý các tập dữ liệu, đặc biệt là với các mảng numpy. Bằng cách làm theo các ví dụ được đề cập ở trên, việc xóa một hoặc nhiều phần tử, cũng như toàn bộ các hàng hoặc cột khỏi các mảng có nhiều chiều khác nhau trở thành một quy trình hợp lý. Sử dụng các chiến lược này để nâng cao khả năng xử lý dữ liệu của bạn trong các dự án máy tính khoa học và học máy, đảm bảo các tập dữ liệu của bạn được điều chỉnh hoàn hảo theo yêu cầu phân tích của bạn.

## Phần 4: Array Transformations

Trong NumPy, thao tác với mảng không chỉ dừng lại ở việc truy xuất hay tính toán — mà còn bao gồm cả việc **biến đổi hình dạng, kết cấu và cấu trúc dữ liệu**. Những biến đổi này được gọi chung là **Array Transformations**, và chúng đóng vai trò then chốt trong:

- Tái định dạng dữ liệu (`reshape`),
- Nối, xếp, lặp mảng (`concatenate`, `stack`, `repeat`, `tile`),
- Chuẩn hoá đầu vào cho mô hình Deep Learning,
- Sắp xếp và lọc dữ liệu theo điều kiện.

**Lưu ý:** Đặc biệt trong lĩnh vực Trí tuệ Nhân tạo (AI), việc **hiểu rõ cách biến đổi mảng** là điều kiện tiên quyết để xây dựng pipeline hiệu quả, tránh lỗi `shape` và tối ưu hiệu suất tính toán.

Trong phần này, chúng ta sẽ lần lượt khám phá các thao tác biến đổi mảng quan trọng trong NumPy:

- **Reshape:** tái định hình mảng
- **Flatten:** làm phẳng toàn bộ dữ liệu
- **Transpose:** hoán đổi trực
- **Repeat, Tile, Stack, Concatenate**
- **Sorting & Aggregation:** sắp xếp và thống kê
- **Filtering bằng mask logic**

### 4.1. Reshape

#### 4.1.1. Đặt vấn đề: Khi nào ta cần `reshape()`?

Trong quá trình làm việc với dữ liệu (đặc biệt là ảnh, âm thanh, văn bản...), bạn sẽ không tránh khỏi tình huống:

*“Mảng dữ liệu có kích thước không giống như mô hình yêu cầu.”*

Lúc này, ta cần một công cụ giúp **biến đổi kích thước mảng mà vẫn giữ nguyên dữ liệu gốc**. Đó chính là hàm `reshape()` của NumPy.

#### Tại sao phải `reshape`?

Hãy tưởng tượng chúng ta có một bức ảnh trắng đen  $28 \times 28$  pixel. Máy tính sẽ lưu nó dưới dạng một mảng 1 chiều gồm 784 phần tử. Nhưng nếu ta muốn xử lý nó như một bức ảnh 2D, thì phải “gấp lại” nó về dạng  $28 \times 28$ . Đó chính là `reshape`!

### Một vài tình huống thường gặp

Bài toán	Dạng dữ liệu ban đầu	Cần reshape thành
Ảnh 1D	[784]	[28, 28]
Chuỗi 100 từ 5 ảnh $28 \times 28 \times 1$	[100, 300] (embedding) [5, 784]	[1, 100, 300] (thêm chiều batch) [5, 28, 28, 1]

### Một vài mô hình AI yêu cầu dữ liệu như sau

- **CNN (Mạng tích chập):**  
 shape = (batch, height, width, channel)  
 ⇒ Dùng cho xử lý ảnh.
- **RNN (Mạng hồi tiếp):**  
 shape = (batch, time steps, features)  
 ⇒ Dùng cho xử lý chuỗi thời gian, văn bản.
- **Transformer (Mạng attention):**  
 shape = (batch, seq\_len, embedding\_dim)  
 ⇒ Dùng cho NLP và cả thị giác máy tính.

Nói tóm lại, chúng ta có thể hiểu qua một chút về tác dụng của `reshape`

- `reshape()` giúp biến đổi hình dạng mảng, rất hữu ích khi xử lý dữ liệu thực tế.
- Nó không làm thay đổi nội dung, chỉ thay đổi cách ta “nhìn” và “chia khối” dữ liệu.

#### 4.1.2. Cú pháp

`reshape` là một hàm được sử dụng để thay đổi hình dạng của một mảng mà không làm thay đổi dữ liệu bên trong nó. Kích thước mảng mới được chỉ định thông qua tham số của hàm `reshape`

##### Cú pháp 1 – hàm của NumPy

```
1 np.reshape (input, newshape)
```

##### Cú pháp 2 – phương thức của ndarray

```
1 arr.reshape(newshape, order='C')
```

Trong đó:

- input: là mảng đầu vào.
- newshape là hình dạng mới ta muốn chuyển đổi, là một tuple thể hiện kích thước mới (ví dụ: (3, 4)).
- order: chọn cách duyệt bộ nhớ:

- 'C' (mặc định): đọc theo hàng (row-major),
- 'F': đọc theo cột (column-major).

**Ví dụ:**

```

1 import numpy as np
2
3 a = np.arange(6)
4 a_reshaped = a.reshape((2, 3))
5 print('a reshape:\n', a_reshaped)

```

```
=====
Output =====
a reshape:
[[0 1 2]
 [3 4 5]]
```

**Minh họa:**

$$\text{Vector: } [0, 1, 2, 3, 4, 5] \xrightarrow{\text{reshape}(2,3)} \begin{bmatrix} 0 & 1 & 2 \\ 3 & 4 & 5 \end{bmatrix}$$

**Giải thích:** Mảng ban đầu có shape (6,), sau khi reshape thành (2, 3) thì:

- Dữ liệu không đổi.
- Cách chia khối (2 hàng, 3 cột) được cập nhật lại.

**Nguyên tắc quan trọng khi reshape**

### 1. Tổng số phần tử phải giữ nguyên:

```

1 np.arange(12).reshape(3, 4) # OK
2 np.arange(12).reshape(2, 5) # ValueError!
3

```

Nếu chúng ta reshape sang kích thước khác số phần tử ban đầu, NumPy sẽ báo lỗi.

### 2. Dùng -1 để tự động suy ra chiều còn lại

```

1 a = np.arange(12)
2 print(a.reshape(3, -1))    # → (3, 4)
3 print(a.reshape(-1, 6))    # → (2, 6)

```

```
=====
Output =====
[ 4  5  6  7]
[ 8  9 10 11]

[[ 0  1  2  3  4  5]
 [ 6  7  8  9 10 11]]
```

**Chỉ được dùng một -1 mỗi lần reshape** — nếu không, NumPy sẽ không biết chiều nào cần suy luận.

### Lưu ý

Chỉ được dùng **một** -1 trong mỗi lệnh `reshape()`. Dùng nhiều hơn sẽ gây lỗi vì không thể xác định chiều nào cần tính.

### 4.1.3. Kiểu C-like vs Fortran-like

Khi ta `reshape` hoặc `flatten` mảng nhiều chiều, NumPy cần biết nên ưu tiên duyệt dữ liệu theo chiều nào: **hàng trước** hay **cột trước**. Đây được gọi là cách *truy xuất bộ nhớ*:

- **C-like (row-major)** – theo ngôn ngữ C.
- **Fortran-like (column-major)** – theo ngôn ngữ Fortran.

**Ví dụ:**

Giả sử ta có một mảng 1 chiều gồm 8 phần tử:

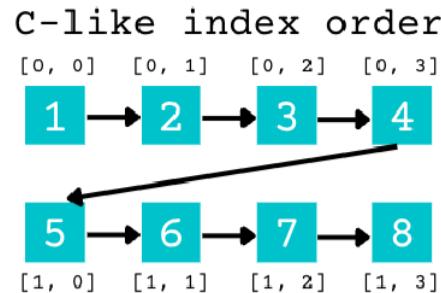
```
1 import numpy as np
2 numbers = np.array([1, 2, 3, 4, 5, 6, 7, 8])
```

- `numbers.shape` (8,)
- `numbers.ndim` 1 (1 chiều)

Giờ ta `reshape` nó thành mảng (2, 4) theo hai cách truy xuất bộ nhớ:

**C-style (row-major) — hàng trước**

```
1 numbers.reshape((2, 4), order='C')
```



Reshape theo order='C'

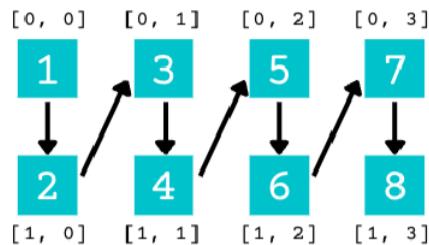
**Giải thích:**

- NumPy duyệt dữ liệu gốc từ trái sang phải.
- Mỗi dòng (row) được lấp đầy lần lượt:
  - Dòng 1: 1, 2, 3, 4
  - Dòng 2: 5, 6, 7, 8

**Fortran-style (column-major) — cột trước**

```
1 numbers.reshape((2, 4), order='F')
```

## Fortran-like index order



Reshape theo order='F'

Giải thích:

- NumPy duyệt dữ liệu theo từng cột (column).
- Mỗi cột được lấp đầy từ trên xuống dưới:
  - Cột 1: 1, 2
  - Cột 2: 3, 4
  - Cột 3: 5, 6
  - Cột 4: 7, 8

## Ảnh hưởng đến hiệu suất

Cách truy xuất bộ nhớ phù hợp sẽ giúp:

- Tăng tốc độ xử lý dữ liệu lớn, vì CPU truy cập vùng nhớ liên tục hơn.
- Tránh lỗi shape ngầm khi tương tác với thư viện khác (như MATLAB dùng kiểu Fortran).

### 4.1.4. Các dạng reshape phổ biến

Khi mới học NumPy, chúng ta sẽ gặp nhiều tình huống cần thay đổi hình dạng mảng (số chiều, số phần tử trên mỗi chiều). Dưới đây là 6 dạng `reshape()` phổ biến, dễ nhớ và hay dùng nhất.

#### 1. Flat → 2D (tạo mảng 2 chiều từ 1 chiều)

Cú pháp

```
1 a.reshape(1, -1)
```

Dùng khi: Ta có 1 dãy số (1 chiều), muốn biến nó thành 1 hàng 2 chiều.

```
1 a = np.arange(10)
2 a_2d = a.reshape(1, -1)
3 print(a_2d.shape)
```

```
===== Output =====
(1, 10)
```

Mảng (10,) đã biến thành (1, 10) — tức là 1 hàng, 10 cột.

## 2. 2D → Flat (làm phẳng mảng 2 chiều)

### Cú pháp

```
1 a.reshape(-1)
```

**Dùng khi:** Ta muốn đưa mảng 2D về 1 chiều.

```
1 a = np.array([[1, 2], [3, 4]])
2 print(a.reshape(-1))
```

```
===== Output =====
[1 2 3 4]
```

Đây là cách "nén" toàn bộ mảng về dạng 1 dãy duy nhất.

## 3. Thêm trực (từ (n,) → (n, 1))

### Cú pháp

```
1 a.reshape(-1, 1)
```

**Dùng khi:** Ta có mảng 1 chiều và muốn biến nó thành nhiều dòng, 1 cột.

```
1 a = np.array([1, 2, 3])
2 print(a.reshape(-1, 1))
```

```
===== Output =====
[[1]
 [2]
 [3]]
```

Dạng này hay dùng khi cần mảng dọc (vector cột).

## 4. Thêm chiều đầu (từ (n,) → (1, n))

### Cú pháp

```
1 a[np.newaxis, :]
```

hoặc:

```
1 a.reshape(1, -1)
```

**Dùng khi:** Ta có 1 dãy số, muốn biến thành 1 hàng trong mảng 2D.

```
1 a = np.arange(8)
2 b = a[np.newaxis, :]
3 print(b.shape)
```

```
===== Output =====
(1, 8)
```

Cách này giống ví dụ 1, nhưng dùng thêm `np.newaxis`.

## 5. Biến ảnh từ 1D → 2D (giống ảnh 28x28)

### Cú pháp

```
1 a.reshape(28, 28)
```

**Dùng khi:** Mảng có 784 phần tử (flatten), muốn đưa về ma trận 28x28.

```
1 a = np.random.rand(784)
2 img = a.reshape(28, 28)
3 print(img.shape)
```

```
===== Output =====
(28, 28)
```

Thường gặp khi học với dữ liệu ảnh trắng đen nhỏ (MNIST).

## 6. Chia dữ liệu theo số đặc trưng (feature)

### Cú pháp

```
1 a.reshape(-1, feature\_dim)
```

**Dùng khi:** Ta có 1 dãy dài, muốn chia thành nhiều dòng có số cột bằng `feature_dim`.

```
1 a = np.random.rand(1000)
2 x = a.reshape(-1, 100)
3 print(x.shape)
```

```
===== Output =====
(10, 100)
```

Ví dụ trên: chia mảng 1000 phần tử thành 10 dòng, mỗi dòng 100 phần tử.

### Bảng tổng hợp các dạng reshape

Tên gọi	Cú pháp	Ý nghĩa
Flat → 2D	a.reshape(1, -1)	Biến mảng 1 chiều thành 1 hàng
2D → Flat	a.reshape(-1)	Làm phẳng toàn bộ mảng
Thêm trực cột	a.reshape(-1, 1)	Biến vector thành cột dọc
Thêm chiều hàng	a[np.newaxis, :]	Thêm 1 chiều ở trên cùng
Flatten ảnh	a.reshape(28, 28)	Đưa ảnh 784 phần tử về ma trận 2D
Chia theo cột cố định	a.reshape(-1, 100)	Tự động chia dòng nếu biết số cột

- `reshape()` không thay đổi dữ liệu, chỉ thay đổi cách tổ chức mảng.
- Dùng `-1` để NumPy tự tính chiều còn lại.
- Bạn nên in `.shape` sau mỗi `reshape` để kiểm tra kết quả.

## 1.5. Ứng dụng trong AI

Trong thực tế, dữ liệu đầu vào của mô hình học sâu không phải lúc nào cũng có đúng `shape` như mô hình yêu cầu. Vì vậy, việc sử dụng `reshape()` là điều **bắt buộc phải thành thạo** khi làm việc với AI.

Dưới đây là các ứng dụng thường gặp:

### 1. Chuẩn hóa ảnh đầu vào cho CNN (Convolutional Neural Network)

Bạn có một ảnh trắng đen kích thước  $28 \times 28$  pixels, nhưng CNN yêu cầu đầu vào có dạng:

`(batch_size, height, width, channel)`

```
1 import numpy as np
2
3 img = np.random.rand(28, 28) # ảnh trắng đen
4 img_batch = img.reshape(1, 28, 28, 1) # 1 ảnh, 1 channel
5 print(img_batch.shape)
```

Shape ban đầu:  $(28, 28)$

$\Rightarrow$  Sau `reshape`:  $(1, 28, 28, 1)$

Đây là điều kiện bắt buộc khi đưa ảnh vào CNN như LeNet, VGG, ResNet...

### 2. Định dạng chuỗi embedding cho NLP

Trong NLP, mỗi từ thường được mã hoá thành một vector (embedding). Ví dụ: bạn có 100 từ, mỗi từ là vector 300 chiều, tạo thành ma trận  $100 \times 300$ .

Tuy nhiên, model yêu cầu đầu vào có shape:

`(batch_size, sequence_length, embedding_dim)`

```
1 embedding = np.random.rand(100, 300) # 100 tu, moi tu 300 chieu
2 input_tensor = embedding.reshape(1, 100, 300)
3 print(input_tensor.shape)
```

Sau `reshape`:  $(1, 100, 300)$

Áp dụng cho mô hình như LSTM, GRU, Transformer...

### 3. Tự động chia batch từ vector lớn

Bạn có 5000 giá trị đầu vào, mỗi mẫu có 100 đặc trưng (feature). Không cần biết số mẫu, chỉ cần:

```
1 features = np.random.rand(5000)
2 input_batch = features.reshape(-1, 100)
3 print(input_batch.shape)
```

$\Rightarrow$  Kết quả:  $(50, 100)$  nghĩa là 50 mẫu, mỗi mẫu 100 đặc trưng.

Cách này thường dùng trong bước tiền xử lý dữ liệu trước khi đưa vào model.

### 4. Dữ liệu thời gian — reshape cho RNN

Ví dụ: bạn có chuỗi dữ liệu cảm biến gồm 60 thời điểm, mỗi thời điểm có 6 đặc trưng. Đầu vào RNN cần dạng:

`(batch_size, time_steps, features)`

```

1 signal = np.random.rand(60 * 6) # du lieu phang
2 rnn_input = signal.reshape(1, 60, 6) # batch = 1

```

Áp dụng trong bài toán: dự đoán chuỗi thời gian, nhận dạng chữ viết tay, phân tích âm thanh...

### Tóm lại

Tình huống	Trước reshape	Sau reshape
Ảnh trắng đen	(28, 28)	(1, 28, 28, 1)
Chuỗi 100 từ (300-dim)	(100, 300)	(1, 100, 300)
5000 giá trị → batch	(5000,)	(50, 100)
Chuỗi thời gian 60×6	(360,)	(1, 60, 6)

## 4.2. Flatten – Làm phẳng mảng nhiều chiều thành 1 chiều

### 4.2.1. Tại sao cần flatten?

Trong nhiều bài toán, đặc biệt là **AI, học sâu**, ta sẽ cần:

- Biến mảng nhiều chiều (2D, 3D) thành **mảng 1 chiều (vector)**.
- Vì nhiều hàm hoặc mô hình chỉ chấp nhận **mảng 1 chiều** làm đầu vào.

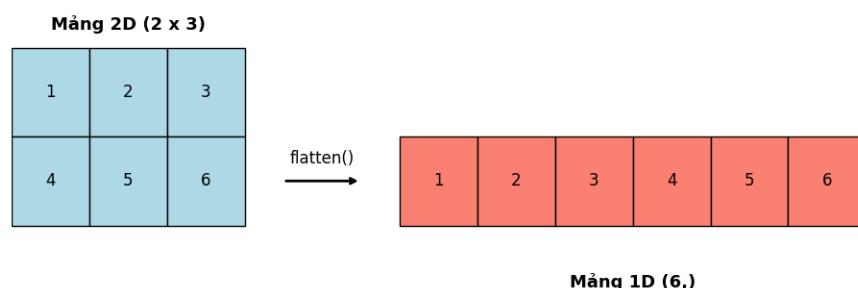
Việc này gọi là **flatten – làm phẳng mảng**.

Ví dụ:

```

1 a = np.array([[1, 2, 3],
2                 [4, 5, 6]])
3 print('a =', a)
=====
===== Output =====
a = [1, 2, 3, 4, 5, 6]

```



Hình 1: Minh họa quá trình flatten mảng 2D thành mảng 1D

#### 4.2.2. Cách làm phẳng mảng (flatten)

NumPy có 2 cách chính để flatten:

Cách dùng	Ý nghĩa
<code>a.flatten()</code>	Luôn trả về mảng <b>mới</b> , tách biệt hoàn toàn với gốc.
<code>a.ravel()</code>	Trả về <b>view</b> nếu có thể (nhanh hơn, chia sẻ bộ nhớ).

Ví dụ:

```

1 import numpy as np
2
3 a = np.array([[1, 2],
4               [3, 4]])
5
6 print('a flatten:', a.flatten())
7 print('a ravel:', a.ravel())

```

```
=====
Output =====
a flatten: [1 2 3 4]
a ravel: [1 2 3 4]
```

Kết quả giống nhau, nhưng bên trong hoạt động khác nhau.

#### 4.2.3. `flatten()` có ảnh hưởng mảng gốc không?

```

1 a = np.array([[1, 2],
2               [3, 4]])
3
4 b = a.flatten()
5 b[0] = 999
6
7 print("a:\n", a) # a khong doi
8 print("b:", b)   # b thay doi

```

```
=====
Output =====
a:
[[1 2]
 [3 4]]
b: [999 2 3 4]
```

Vì `flatten()` tạo bản sao  $\Rightarrow$  mảng `a` không bị thay đổi.

#### 4.2.4. `ravel()` thì sao?

```

1 a = np.array([[1, 2],
2               [3, 4]])
3
4 b = a.ravel()
5 b[0] = 999
6
7 print("a:\n", a) # a bi thay doi
8 print("b:", b)

```

```
=====
Output =====
a:
[[999 2]
 [3 4]]
b: [999 2 3 4]
```

Vì `ravel()` trả về **view** (chung vùng nhớ) nên thay đổi `b` cũng làm thay đổi `a`.

#### 4.2.5. Duyệt theo hàng hay theo cột?

ta có thể chọn cách NumPy "đọc" dữ liệu:

Kiểu đọc	Dùng gì	Ý nghĩa
Theo hàng (C-style)	order='C'	Duyệt từng hàng trước (mặc định).
Theo cột (F-style)	order='F'	Duyệt từng cột trước (ít dùng hơn).

Ví dụ:

```
1 a = np.array([[1, 2],
               [3, 4]])
2
3
4 print(a.flatten(order='C')) # [1 2 3 4]
5 print(a.flatten(order='F')) # [1 3 2 4]
```

#### 4.2.6. Khi nào dùng flatten trong AI?

Flatten thường được dùng trước khi đưa dữ liệu vào **Dense Layer** trong mạng học sâu (CNN):

- Ảnh đầu vào: (28, 28, 1)
- Sau khi qua Conv2D → (7, 7, 64)
- Cần flatten: (7 × 7 × 64 = 3136,)

```
1 x = np.random.rand(7, 7, 64)
2 x_flat = x.flatten()
3 print(x_flat.shape) # (3136,)
```

### 4.3. Transpose – Hoán vị trực mảng

#### 4.3.1. Đặt vấn đề

Khi xử lý dữ liệu nhiều chiều, ta sẽ cần **hoán vị các trực (axes)** để đưa mảng về đúng hình dạng mô hình yêu cầu.

Ví dụ:

- Dữ liệu ảnh trong Deep Learning thường ở dạng (N, H, W, C):
    - N – số lượng ảnh (batch size)
    - H – chiều cao ảnh
    - W – chiều rộng ảnh
    - C – số kênh màu (channels)
  - Nhưng PyTorch yêu cầu định dạng: (N, C, H, W)
- ⇒ Lúc này, ta cần dùng **transpose** để đổi thứ tự trực.

#### 4.3.2. Cú pháp

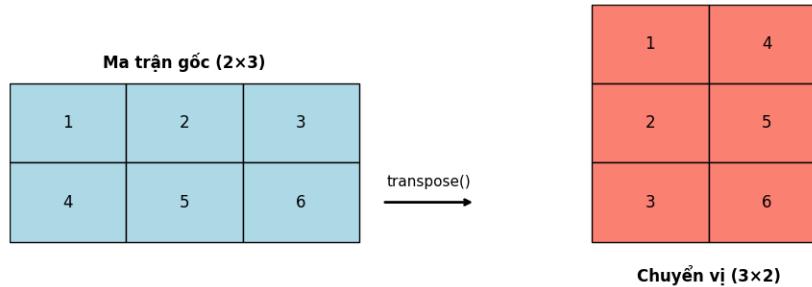
##### Cú pháp

```
1 np.transpose(a, axes)
  • a là mảng nhiều chiều (tensor).
  • axes là một tuple (hoặc list) chứa thứ tự mới của các trực.
```

**Nếu là mảng 2 chiều:** Ta có thể dùng cú pháp ngắn gọn hơn là `a.T` — tương tự chuyển vị trong toán học:

```
1 a = np.array([[1, 2, 3],
2                 [4, 5, 6]])
3
4 print('a.T: \n', a.T)
```

```
===== Output =====
a.T:
[[1 4]
 [2 5]
 [3 6]]
```



Minh họa quá trình transpose (chuyển vị) một ma trận 2D

**Nếu là mảng nhiều chiều ( $\geq 3D$ ):** Khi muốn hoán đổi nhiều trực, hãy liệt kê thứ tự mới theo ý mình:

```
1 a = np.random.rand(10, 28, 28, 3) # (N, H, W, C)
2
3 # Đổi vị (N, C, H, W)
4 a_transposed = np.transpose(a, (0, 3, 1, 2))
```

**Giải thích:** Mảng ban đầu có 4 trực:

$$(0 \rightarrow N, 1 \rightarrow H, 2 \rightarrow W, 3 \rightarrow C)$$

Sau transpose, trực C (3) được đưa lên vị trí thứ 2  $\Rightarrow$  định dạng mới: (N, C, H, W)

## 4.4. Repeat, Tile, Concatenate, Stack

Khi làm việc với dữ liệu nhiều chiều (*tensor*), đôi lúc ta cần:

- **Nhân bản phần tử hoặc cả mảng** – để tạo dữ liệu huấn luyện, broadcasting.
- **Ghép nhiều mảng lại** – kết hợp dữ liệu từ nhiều nguồn, ghép batch, v.v.

### 4.4.1. `np.repeat()` vs `np.tile()`

Hàm	Mục đích	Kiểu lặp
<code>repeat</code>	Lặp từng phần tử theo một chiều	<i>element-wise</i>
<code>tile</code>	Lặp toàn bộ mảng theo pattern	<i>block-wise</i>

### Cú pháp

```
1 np.repeat(a, repeats, axis=None)
2 np.tile(a, reps)
```

Trong đó:

- **a** — Mảng gốc (`np.array`) cần được lặp lại.
- **repeats** — Số lần lặp:
  - Nếu là một `int`, thì tất cả phần tử đều được lặp cùng số lần.
  - Nếu là một mảng (list), có thể chỉ định số lần lặp khác nhau cho từng phần tử (áp dụng theo trực).
- **axis** — Trục để thực hiện lặp:
  - Nếu `None` (mặc định), mảng sẽ được làm phẳng trước rồi mới lặp.
  - Nếu xác định rõ trực (`axis=0, axis=1, ...`), thì lặp theo chiều cụ thể (ví dụ: hàng hoặc cột).

### Ví dụ minh họa:

```
1 a = np.array([1, 2, 3])
2 print('a repeat:', np.repeat(a, 2))
3 print('a tile:', np.tile(a, 2))
```

```
===== Output =====
a repeat: [1 1 2 2 3 3]
a tile: [1 2 3 1 2 3]
```

### Giải thích:

- `repeat`: mỗi phần tử được nhân bản riêng lẻ.
- `tile`: nhân bản toàn bộ mảng theo mẫu.

data	repeat_axis_0
4	4
7	3

repeat_axis_1
4
4
3
3
7
7
1
1

Hình 2: Minh họa repeat theo từng chiều của một Array

#### 4.4.2. Stack và Concatenate

NumPy cung cấp nhiều cách để **ghép các mảng lại với nhau**:

Hàm	Mô tả
np.concatenate	Ghép theo chiều đã có
np.stack	Ghép và tạo thêm chiều mới
np.hstack	Ghép ngang (horizontal), tương đương axis=1
np.vstack	Ghép dọc (vertical), tương đương axis=0

**np.concatenate()** – Ghép theo chiều có sẵn

```
1 a = np.array([[1, 2], [3, 4]])
2 b = np.array([[5, 6]])
3 print('Concatenate:\n', np.concatenate([a, b], axis=0))
```

```
===== Output =====
Concatenate:
[[1 2]
 [3 4]
 [5 6]]
```

**np.stack()** – Ghép và thêm chiều mới

```
1 a = np.array([1, 2, 3])
2 b = np.array([4, 5, 6])
3
4 print('Batch stack:\n', np.stack([a, b], axis=0))
5 print('Column stack:\n', np.stack([a, b], axis=1))
```

```
===== Output =====
Batch stack:
[[1 2 3]
 [4 5 6]]
Column stack:
[[1 4]
 [2 5]
 [3 6]]
```

- concatenate không tạo chiều mới, cần các mảng cùng shape ở chiều không ghép.
- stack tạo thêm chiều mới, phù hợp khi gom mảng thành batch.

#### 4.4.3. vstack, hstack

```
1 a = np.array([1, 2])
2 b = np.array([3, 4])
3
4 print('vstack:\n', np.vstack([a, b]))
5 print('hstack:\n', np.hstack([a, b]))
```

```
===== Output =====
vstack:
[[1 2]
 [3 4]]
hstack:
[1 2 3 4]
```

Tình huống	Hàm nên dùng
Ghép mảng cùng shape theo 1 chiều	concatenate
Ghép mảng và thêm trực mới	stack
Ghép mảng 1D/2D đơn giản	vstack, hstack

## 4.5. Sorting — Sắp xếp dữ liệu trong NumPy

Trong xử lý dữ liệu và học máy (*machine learning*), **sắp xếp** (**sorting**) là một thao tác cực kỳ phổ biến. Ví dụ:

- Sắp xếp điểm số trước khi tính **median** / **percentile**.
- Lọc ra **top-k phần tử quan trọng nhất** trong quá trình chọn đặc trưng (feature selection).
- Sắp xếp **tensor đầu ra** theo xác suất giảm dần để tính **accuracy** / **top-k accuracy**.

NumPy cung cấp công cụ sắp xếp mạnh mẽ, tối ưu cho cả mảng 1 chiều lẫn nhiều chiều.

### 4.5.1. Cú pháp cơ bản

NumPy hỗ trợ 2 cách sắp xếp chính:

#### `np.sort(a)` – Trả về bản sao đã sắp xếp

- Trả về một bản sao đã được sắp xếp.
- Không làm thay đổi mảng gốc.
- Cú pháp: `np.sort(a, axis=-1, kind='quicksort')`

#### Ví dụ:

```
1 import numpy as np
2
3 a = np.array([3, 1, 4, 2])
4 b = np.sort(a)
5
6 print("a:", a)  # [3 1 4 2]
7 print("b:", b)  # [1 2 3 4]
```

#### `a.sort()` – Sắp xếp in-place

- Sắp xếp trực tiếp trên mảng gốc (in-place).
- Không tạo ra bản sao (tiết kiệm bộ nhớ hơn).
- Cú pháp: `a.sort(axis=-1, kind='quicksort')`

#### Ví dụ:

```
1 a = np.array([3, 1, 4, 2])
2 a.sort()
3 print(a)  # [1 2 3 4]
```

#### Ghi nhớ

`np.sort(a)` phù hợp khi bạn cần giữ nguyên mảng gốc.  
`a.sort()` dùng khi muốn tiết kiệm bộ nhớ và không cần giữ lại mảng ban đầu.

#### 4.5.2. Tham số quan trọng

Khi sắp xếp với `np.sort()` hoặc `a.sort()`, NumPy cho phép điều chỉnh hành vi sắp xếp qua 4 tham số quan trọng:

- **axis** – Chọn chiều sắp xếp
  - `axis=-1` (mặc định): sắp xếp theo từng hàng (chiều cuối cùng).
  - `axis=0`: sắp xếp theo từng cột (trên mỗi cột riêng lẻ).
  - `axis=None`: sắp xếp toàn bộ mảng sau khi được **flatten**.
- **kind** – Thuật toán sắp xếp
  - '`'quicksort'` – mặc định, nhanh nhất trong hầu hết trường hợp.  
*Không ổn định*: các phần tử bằng nhau có thể bị đổi chỗ.
  - '`'mergesort'` – ổn định (*stable sort*), phù hợp khi cần giữ nguyên thứ tự tương đối của các phần tử bằng nhau.
  - '`'heapsort'` – sử dụng ít bộ nhớ hơn, nhưng tốc độ chậm nhất.
  - '`'stable'` – alias của thuật toán ổn định (thường là `mergesort`), từ NumPy 1.15.
- **order** – Chỉ dùng cho **structured array**, cho phép sắp xếp theo tên trường cùi chỏ (field name). Ví dụ: `order=['age', 'height']`.
- **sorter** – Mảng chỉ số (index array) được dùng để sắp xếp nhanh hơn nếu đã có sẵn thứ tự một phần (*advanced use*).

#### Ví dụ 1: Sắp xếp theo cột thay vì theo hàng

```

1 import numpy as np
2
3 a = np.array([[3, 1, 4],
4               [2, 5, 0]])
5
6 print(np.sort(a, axis=0))
7 print(np.sort(a, axis=1))
8 print(np.sort(a, axis=None))

```

```
=====
Output =====
[[2 1 0]
 [3 5 4]]

[[1 3 4]
 [0 2 5]]

[0 1 2 3 4 5]
```

#### Ví dụ 2: So sánh các kind

```

1 a = np.array([3, 2, 3, 1])
2
3 print(np.sort(a, kind='quicksort'))
4 print(np.sort(a, kind='mergesort'))
5 print(np.sort(a, kind='heapsort'))
6 print(np.sort(a, kind='stable'))

```

```
=====
Output =====
[1 2 3 3]
[1 2 3 3]
[1 2 3 3]
[1 2 3 3]
```

### Ví dụ 3: Sắp xếp theo trường (order) trong structured array

```

1 person = np.array([(25, 180), (20, 175),
2     (25, 170)], \
3     dtype=[('age', int), ('height', int)])
4 print(np.sort(person, order=['age', 'height']))

```

```
===== Output =====
[(20, 175) (25, 170) (25, 180)]
```

#### Ghi nhớ

- **quicksort**: nhanh nhất – dùng mặc định khi không yêu cầu thứ tự ổn định.
- **mergesort** hoặc **stable**: dùng khi cần sắp xếp ổn định (ML hay dùng khi sắp xếp theo nhiều tiêu chí).
- **heapsort**: chỉ hữu ích trong môi trường hạn chế bộ nhớ.

### 4.5.3. Sắp xếp giảm dần

NumPy không hỗ trợ trực tiếp tham số `reverse=True` như `list.sort()`. Tuy nhiên, ta có thể đảo ngược kết quả sau khi sắp xếp bằng `slicing` hoặc dùng `np.argsort()` để lấy chỉ số theo thứ tự giảm dần.

#### Cách 1: Dùng slicing

```

1 import numpy as np
2
3 a = np.array([3, 1, 4, 2])
4 sorted_desc = np.sort(a)[::-1]
5 print(sorted_desc)

```

```
===== Output =====
[4 3 2 1]
```

#### Cách 2: Sắp xếp giảm dần theo cột/hàng trong mảng 2D

```

1 a = np.array([[3, 1, 4],
2                 [2, 5, 0]])
3
4 # Sap xep giam dan tung hang
5 desc_rows = np.sort(a, axis=1)[:, ::-1]
6 print(desc_rows)
7
8 # Sap xep giam dan tung cot
9 desc_cols = np.sort(a, axis=0)[:, ::-1, :]
10 print(desc_cols)

```

```
===== Output =====
[[4 3 1]
 [5 2 0]]

[[3 5 4]
 [2 1 0]]
```

### Cách 3: Dùng np.argsort() (lấy chỉ số, linh hoạt hơn)

```

1 a = np.array([3, 1, 4, 2])
2
3 # Lay chi so giam dan
4 idx_desc = np.argsort(a)[::-1]
5 print(idx_desc)
6
7 # Lay gia tri giam dan theo chi so
8 print(a[idx_desc])

```

```
===== Output =====
[4 3 2 1]
```

#### 4.5.4. Ứng dụng trong Machine Learning

Sắp xếp là một thao tác cực kỳ quan trọng trong học máy (Machine Learning) và xử lý dữ liệu. Dưới đây là những ứng dụng phổ biến:

##### 1. Top-k selection – Chọn ra k phần tử lớn nhất

**Ví dụ:** Chọn top-2 xác suất cao nhất trong mảng xác suất đầu ra của mô hình.

```

1 probs = np.array([0.1, 0.9, 0.4, 0.7])
2 top_k = probs[np.argsort(probs)
   [:,-1][:2]]
3 print(top_k)

```

```
===== Output =====
[0.9 0.7]
```

##### 2. Chuẩn bị dữ liệu thống kê – Tính median hoặc percentile

```

1 data = np.array([7, 1, 5, 3])
2 sorted_data = np.sort(data)
3
4 median = np.median(sorted_data)
5 percentile_75 = np.percentile(sorted_data
   , 75)
6
7 print("Median:", median)
8 print("75th Percentile:", percentile_75)

```

```
===== Output =====
Median: 4.0
75th Percentile: 6.0
```

##### 3. Feature Selection – Lựa chọn đặc trưng quan trọng nhất

**Ví dụ:** Chọn 3 đặc trưng có trọng số lớn nhất từ mô hình học máy.

```

1 feature_importances = np.array([0.05,
2     0.12, 0.7, 0.3, 0.02])
3 top3_idx = np.argsort(feature_importances
4     )[::-1][:3]
5 print("Top-3 indices:", top3_idx)
6 print("Top-3 importances:",
7     feature_importances[top3_idx])

```

```

===== Output =====
Top-3 indices: [2 3 1]
Top-3 importances: [0.7 0.3 0.12]

```

#### 4. Post-processing – Sắp xếp kết quả dự đoán theo thứ tự giảm dần

**Ví dụ:** Sắp xếp nhãn dự đoán (class labels) theo xác suất giảm dần.

```

1 labels = np.array(["cat", "dog",
2     "bird", "fish"])
3 probs = np.array([0.1, 0.7, 0.05, 0.15])
4
5 sorted_idx = np.argsort(probs)[::-1]
6 print(labels[sorted_idx])

```

```

===== Output =====
['dog' 'fish' 'cat' 'bird']

```

##### 4.5.5. Vì sao không có reverse=True như trong list.sort()?

###### 1. Vì sao list.sort() có reverse=True?

- list.sort() được thiết kế cho **cấu trúc dữ liệu 1D đơn giản** (danh sách Python), nơi đảo ngược chỉ cần **đảo lại thứ tự các phần tử**.
- Ví dụ: [1,3,2].sort(reverse=True) → chỉ đơn giản **lật ngược** kết quả.

###### 2. Vì sao numpy.sort() không có reverse=True?

###### 1. NumPy hướng đến xử lý mảng đa chiều

- NumPy phải làm việc với **ndarray** (**mảng nhiều chiều**), không chỉ 1D như list.
- Khi sắp xếp mảng 2D hoặc 3D, câu hỏi “**reverse theo trục nào?**” rất phức tạp:
  - Theo **hàng (axis=1)** hay **cột (axis=0)?**
  - Nếu 3D thì sao?

Thay vì thêm một tham số reverse=True gây nhầm lẫn, NumPy chọn cách tách bạch:

- Dùng np.sort(a, axis=...) để sắp xếp,
- Dùng slicing [::-1] để đảo ngược theo ý muốn.

###### 2. Tư duy thiết kế ”tách riêng nhiệm vụ”

- NumPy theo triết lý **”mỗi hàm làm một việc duy nhất”** (single-responsibility):

- `np.sort()` → chỉ để **sắp xếp tăng dần**.
- Muốn đảo ngược → dùng **indexing/slicing**, không nhòi nhét vào `sort()`.

Vậy muốn đảo ngược thì làm sao?

### Ý tưởng chung

- **Bước 1:** Dùng `np.sort()` để sắp xếp tăng dần theo trực mong muốn (vì mặc định NumPy chỉ sắp xếp tăng dần).
- **Bước 2:** Dùng **slicing** (`[::-1]`) để đảo ngược:
  - `[::-1, :]` → đảo ngược theo **hàng** (dòng).
  - `[:, ::-1]` → đảo ngược theo **cột**.
  - Với mảng 3D trở lên, có thể đảo ngược theo từng trục tùy chỉnh: `array[::-1, :, :, ::-1]` hoặc `array[:, ::-1, :, :]`.

```

1 import numpy as np
=====
2
3 a = np.array([[3,1,2],
4               [9,7,8]])
5
6 # 1) Sap xep tang dan theo cot (axis=0)
7 sorted_a = np.sort(a, axis=0)
8 print(sorted_a)
9
10 # 2) Dao nguoc theo hang (giam dan theo
11 #      cot)
12 desc_a_row = sorted_a[::-1, :]
13 print(desc_a_row)
14
15 # 3) Dao nguoc theo cot (giam dan theo
16 #      tung hang)
17 desc_a_col = np.sort(a, axis=1)[:, ::-1]
18 print(desc_a_col)
19
20 # 4) Voi 3D: dao nguoc theo truc dau tien
21 b = np.arange(8).reshape(2,2,2)
22 print(b[::-1, :, :, :])
===== Output =====
[[3 1 2]
 [9 7 8]]
[[9 7 8]
 [3 1 2]]
[[3 2 1]
 [9 8 7]]
[[[4 5]
 [6 7]]
 [[0 1]
 [2 3]]]
```

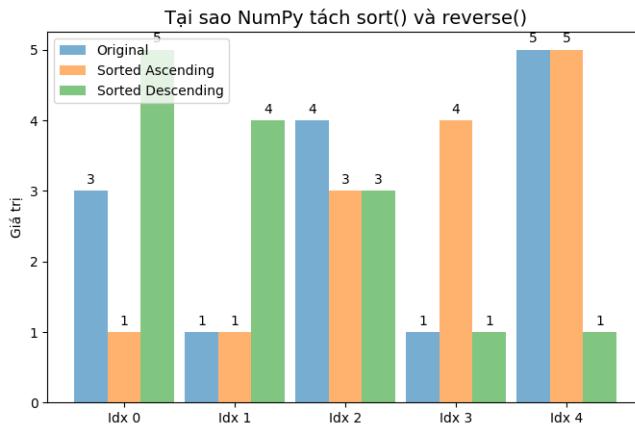
Giải thích:

- `[::-1]` là thao tác **cắt ngược** (reverse slicing): `start:end:step` với `step = -1`.
- `sorted_a[::-1, :]` → đảo thứ tự các hàng (dòng), giữ nguyên cột.
- `[:, ::-1]` → đảo thứ tự các cột, giữ nguyên hàng.

## So sánh nhanh

Python list	NumPy
Chỉ 1D → <code>reverse=True</code> rất tiện Thiết kế cho thao tác nhỏ	Hỗ trợ đa chiều → tách bạch sort & reverse Thiết kế cho tính toán khoa học, tối ưu tốc độ

Minh họa vì sao NumPy phải tách sort và reverse



Giải thích:

- **Cột màu đầu tiên (Original):** Mảng ban đầu.
- **Cột giữa (Sorted Ascending):** Mảng đã được sắp xếp tăng dần.
- **Cột cuối (Sorted Descending):** Muốn có thứ tự giảm dần thì phải **reverse sau khi sort**, chứ không chỉ là một tham số như trong Python list.

**Lý do:** NumPy được thiết kế cho hiệu năng cao. Hàm `np.sort()` được tối ưu để trả về thứ tự tăng dần nhanh nhất có thể, còn `[::-1]` (reverse) chỉ là một **view** (không tốn thêm bộ nhớ, chỉ thay đổi stride).

Tách riêng 2 bước giúp:

1. **Giữ được tính nhất quán & dễ tối ưu hóa:** các kernel sort chỉ cần tập trung vào tăng dần.
2. **Tận dụng view:** Reverse chỉ là đảo stride, gần như  $O(1)$ , không cần sort lại.
3. **Linh hoạt:** Bạn có thể sort một lần rồi reverse nhiều lần mà không phải sắp xếp lại.

### 4.5.6. Tổng kết

Hàm	In-place	Trả bản sao	Đa chiều	Ghi chú
<code>a.sort()</code>	✓		✓	Thay đổi mảng gốc
<code>np.sort(a)</code>		✓	✓	Trả về bản sao đã sắp xếp
<code>[::-1]</code>		✓	✓	Đảo ngược thứ tự sau sort

## 4.6. Aggregation: sum, mean, max, min, argmax, argmin

Trong xử lý dữ liệu và học máy (*machine learning*), **tổng hợp dữ liệu** (**aggregation**) là thao tác quan trọng để rút gọn thông tin từ các mảng số liệu lớn.

**Ví dụ ứng dụng:**

- **sum** – Tính tổng xác suất hoặc tổng giá trị pixel.
- **mean** – Tính trung bình điểm số, giá trị trung bình đặc trưng (*feature average*).
- **max/min** – Tìm giá trị lớn nhất/nhỏ nhất, thường dùng trong **feature scaling**.
- **argmax/argmin** – Tìm vị trí của giá trị lớn nhất/nhỏ nhất, cực kỳ phổ biến trong **dự đoán nhãn lớp** (classification).

### 4.6.1. Tổng quan cú pháp

Tất cả các hàm aggregation trong NumPy đều có cú pháp tương tự:

Cú pháp chung

```
np.function(a, axis=None, keepdims=False)
    • a: Mảng đầu vào (ndarray).
    • axis:
        – None (mặc định): tính trên toàn bộ mảng sau khi flatten.
        – Số nguyên: tính theo từng trực (0 = theo cột, 1 = theo hàng).
    • keepdims:
        – False (mặc định): giảm bớt số chiều sau khi gộp.
        – True: giữ nguyên số chiều bằng cách chèn chiều có kích thước 1.
```

### 4.6.2. sum – Tính tổng

**Ý nghĩa:** Tính tổng tất cả phần tử theo trực hoặc toàn bộ mảng.

```
1 import numpy as np
2
3 a = np.array([[1, 2, 3],
4               [4, 5, 6]])
5
6 print(np.sum(a))          # Tong toan bo
7 print(np.sum(a, axis=0))   # Tong theo
    cot
8 print(np.sum(a, axis=1))   # Tong theo
    hang
```

===== Output =====

```
21
[5 7 9]
[ 6 15]
```

#### 4.6.3. mean – Giá trị trung bình

**Ý nghĩa:** Tính trung bình cộng. Trong ML, **mean** thường dùng để chuẩn hóa dữ liệu hoặc tính **average pooling**.

```

1 print(np.mean(a))          # Trung binh
   toan bo
2 print(np.mean(a, axis=0))   # Trung binh
   theo cot
3 print(np.mean(a, axis=1))   # Trung binh
   theo hang

```

```
===== Output =====
3.5
[2.5 3.5 4.5]
[2.0 5.0]
```

#### 4.6.4. max, min – Giá trị lớn nhất và nhỏ nhất

**Ý nghĩa:** Tìm giá trị lớn nhất/nhỏ nhất theo trực. Ứng dụng trong **feature scaling** (chuẩn hóa dữ liệu theo min-max).

```

1 print(np.max(a))          # Lon nhat
   toan bo
2 print(np.max(a, axis=0))   # Lon nhat
   theo cot
3 print(np.min(a, axis=1))   # Nho nhat
   theo hang

```

```
===== Output =====
6
[4 5 6]
[1 4]
```

#### 4.6.5. argmax, argmin – Vị trí giá trị lớn nhất/nhỏ nhất

**Ý nghĩa:** Trả về chỉ số (index) của giá trị lớn nhất/nhỏ nhất. Cực kỳ phổ biến trong ML: **argmax** được dùng để chọn lớp dự đoán có xác suất cao nhất.

```

1 probs = np.array([[0.1, 0.7, 0.2],
                   [0.8, 0.05, 0.15]])
2
3
4 print(np.argmax(probs))      # Chi
   so lon nhat toan bo (flatten)
5 print(np.argmax(probs, axis=1)) # Lon
   nhat theo hang (du doan tung mau)
6 print(np.argmin(probs, axis=0)) # Nho
   nhat theo cot

```

```
===== Output =====
3
[1 0]
[0 1 1]
```

#### 4.6.6. Ứng dụng trong Machine Learning

Trong Machine Learning, các phép **aggregation** được dùng ở hầu hết các bước: từ xử lý dữ liệu đầu vào, tính toán thống kê đặc trưng, đến đánh giá mô hình. Dưới đây là hai ví dụ tiêu biểu:

##### 1. Tính Accuracy nhanh với argmax

**Mục đích:** Trong các bài toán phân loại (*classification*), mô hình thường trả về **xác suất dự đoán** cho từng lớp. Để tính **độ chính xác** (**accuracy**), ta cần:

1. Chọn lớp có xác suất cao nhất cho từng mẫu  $\Rightarrow$  dùng `np.argmax(..., axis=1)`.
2. So sánh nhãn dự đoán (`pred`) với nhãn thật (`true`).
3. Tính tỷ lệ số mẫu dự đoán đúng trên tổng số mẫu  $\Rightarrow$  dùng `np.mean(pred == true)`.

```

1 import numpy as np
2
3 # Xac suat du doan cua 3 mau (3 class)
4 pred_probs = np.array([[0.1, 0.8, 0.1],
5                      [0.2, 0.3, 0.5],
6                      [0.6, 0.1, 0.3]])
7 true_labels = np.array([1, 2, 0])
8
9 # 1) Chon lop co xac suat cao nhat moi
10 mau
11 pred_labels = np.argmax(pred_probs, axis
12      =1)
13 print("Predicted:", pred_labels)
14
15 # 2) Tinh do chinh xac (so mau dung /
16     tong so mau)
17 accuracy = np.mean(pred_labels ==
18     true_labels)
19 print("Accuracy:", accuracy)

```

===== Output =====

Predicted: [1 2 0]  
Accuracy: 1.0

**Giải thích:**

- `np.argmax(..., axis=1)`: tìm vị trí có xác suất lớn nhất trên từng hàng (tương ứng từng mẫu).
- `pred_labels == true_labels`: trả về mảng [True, True, True] (so sánh từng phần tử).
- `np.mean(...)`: trung bình của các giá trị True/False ( $True = 1, False = 0$ )  $\Rightarrow$  chính là tỷ lệ đúng.

## 2. Chuẩn hóa Min-Max (Feature Scaling)

**Mục đích:** Chuẩn hóa đặc trưng (feature) về khoảng [0,1] giúp:

- Tăng tốc hội tụ của các mô hình học máy (đặc biệt là Gradient Descent).
- Tránh việc các đặc trưng có giá trị lớn lấn át các đặc trưng nhỏ.

**Công thức:**

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

```

1 data = np.array([2, 5, 10, 7])
2
3 # (x - min) / (max - min)
4 scaled = (data - np.min(data)) / (np.max(
    data) - np.min(data))
5 print(scaled)

```

===== Output =====

```
[0.      0.375 1.      0.625]
```

**Giải thích:**

- $\text{np.min}(\text{data}) = 2$ ,  $\text{np.max}(\text{data}) = 10$ .
- Mỗi giá trị được co giãn tuyến tính về khoảng [0,1]: 2 → 0.0, 5 → 0.375, 10 → 1.0, 7 → 0.625.

#### 4.6.7. Tổng kết

Hàm	Giá trị	Chỉ số	Ứng dụng
sum	✓	✗	Tính tổng xác suất, tổng pixel ảnh.
mean	✓	✗	Tính trung bình đặc trưng, chuẩn hóa dữ liệu (pooling).
max / min	✓	✗	Feature scaling, tìm giá trị biên của dữ liệu.
argmax / argmin	✗	✓	Dự đoán nhãn (chọn lớp có xác suất cao nhất), chọn top-k đặc trưng quan trọng.

### 4.7. Filtering bằng mask

**Filtering** (lọc dữ liệu) là thao tác quan trọng trong xử lý dữ liệu và học máy. Thay vì phải duyệt thủ công từng phần tử, NumPy cho phép **lọc nhanh** bằng **mask Boolean**.

Mask Boolean là gì?

- **Mask** = Mảng True/False có cùng kích thước với mảng gốc.
- Khi áp dụng lên mảng, NumPy chỉ giữ lại những phần tử tại vị trí có True.
- **Ví dụ:** `mask = a > 5` ⇒ Chỉ giữ các phần tử lớn hơn 5.

Cú pháp cơ bản

- **Tạo mask:** `mask = a` (toán tử so sánh) `giá_trị` Ví dụ: `mask = a > 5`, `mask = (a == 0)`, `mask = (a != 3)`
- **Lọc dữ liệu bằng mask:** `filtered = a[mask]`
- **Quy tắc:** Mask phải có cùng kích thước với mảng gốc. Chỉ các phần tử tại vị trí True được giữ lại.

#### 4.7.1. Tạo mask cơ bản

```

1 import numpy as np
2
3 a = np.array([3, 7, 1, 9, 5])
4
5 # Tao mask lon hon 5
6 mask = a > 5
7 print("Mask:", mask)
8
9 # Loc du lieu theo mask
10 filtered = a[mask]
11 print("Filtered:", filtered)

```

```

=====
Output =====
Mask: [False  True False  True False]
Filtered: [7 9]

```

Giải thích:

- $a > 5$  tự động trả về mảng Boolean cùng kích thước: [False, True, False, True, False].
- $a[mask]$  lọc ra các phần tử tại vị trí True.

#### 4.7.2. Kết hợp nhiều điều kiện

Mask có thể kết hợp bằng các toán tử logic:

- $\&$  – AND (và): cả hai điều kiện phải đúng.
- $|$  – OR (hoặc): chỉ cần một điều kiện đúng.
- $\sim$  – NOT (phủ định): đảo ngược mask.

```

1 ## Lay cac phan tu lon hon 3 va nho hon 8
2 mask_and = (a > 3) & (a < 8)
3 print(a[mask_and])
4
5 # Lay cac phan tu nho hon 2 hoac lon hon
6 # 7
7 mask_or = (a < 2) | (a > 7)
8 print(a[mask_or])
9
10 # Lay cac phan tu khong lon hon 5
11 mask_not = ~(a > 5)
12 print(a[mask_not])

```

```

=====
Output =====
[7 5]
[1 9]
[3 1 5]

```

#### 4.7.3. Filtering trên mảng 2D

Mask cũng hoạt động tốt trên mảng nhiều chiều.

```

1 b = np.array([[3, 8, 1],
2                 [7, 2, 9]])
3
4 # Lọc phần tử chẵn
5 mask_even = (b % 2 == 0)
6 print("Mask:\n", mask_even)
7 print("Filtered:", b[mask_even])

```

```

===== Output =====
Mask:
[[False  True False]
 [False  True False]]
Filtered: [8 2]

```

#### 4.7.4. Ứng dụng trong Machine Learning

##### 1. Lọc dữ liệu ngoại lai (Outlier Filtering)

**Mục đích:** Trong thực tế, dữ liệu thường có những giá trị bất thường (**outlier**) lệch xa so với các điểm dữ liệu còn lại. Những giá trị này có thể:

- Gây nhiễu cho mô hình học máy.
- Kéo trung bình lệch khỏi giá trị thực tế.

**Ý nghĩa:** Loại bỏ outlier giúp làm sạch dữ liệu (*data cleaning*) trước khi huấn luyện mô hình.

**Cách tiếp cận phổ biến:** Lọc các điểm nằm ngoài khoảng  $\text{mean} \pm k \times \text{std}$ , trong đó:

$$\text{Giữ lại nếu: } (\mu - k\sigma) < x < (\mu + k\sigma)$$

Với:

- $\mu = \text{mean}(\text{data})$ : Giá trị trung bình.
- $\sigma = \text{std}(\text{data})$ : Độ lệch chuẩn.
- $k$ : Hệ số, thường chọn 2 hoặc 3 tùy mức độ nghiêm ngặt.

##### Cú pháp chung:

###### Cú pháp lọc outlier

```

1 mean = np.mean(data)
2 std = np.std(data)
3
4 mask = (data > mean - k*std) & (data < mean + k*std)
5 filtered = data[mask]

```

### Ví dụ minh họa:

```

1 import numpy as np
2
3 data = np.array([10, 12, 9, 200, 11, 8])
4
5 mean = np.mean(data)
6 std = np.std(data)
7
8 # Lọc các điểm nằm trong khoảng mean ± 2*
9 # std
10 mask = (data > mean - 2*std) & (data <
11     mean + 2*std)
12 clean_data = data[mask]
13
14 print("Original:", data)
15 print("Mean:", mean, "| Std:", std)
16 print("Filtered:", clean_data)

```

```

=====
Output =====
Original: [ 10  12   9 200  11   8]
Mean: 41.66666666666666 | Std:
71.00892894685608
Filtered: [10 12   9 11   8]

```

### Giải thích:

- $\mu \approx 41.67$ ,  $\sigma \approx 71.01$ . Khoảng giữ lại  $= [\mu - 2\sigma, \mu + 2\sigma] \approx [-100.35, 183.68]$ .
- Phần tử 200 vượt ngoài khoảng này  $\Rightarrow$  bị loại bỏ.
- Các điểm còn lại (10, 12, 9, 11, 8) được giữ vì nằm trong khoảng an toàn.

## 2. Lựa chọn mẫu theo điều kiện nhãn (Label-based Filtering)

**Mục đích:** Trong các bài toán học máy, dữ liệu thường được gán nhãn (**label**) để mô tả loại đối tượng (class). Khi xử lý dữ liệu, đôi khi ta chỉ muốn trích xuất các mẫu thuộc một (hoặc vài) nhãn cụ thể.

### Ví dụ thực tế:

- Chỉ lấy ảnh mèo từ tập dữ liệu động vật (nhãn mèo = 1).
- Lọc ra các bệnh nhân có kết quả dương tính (label = positive).

### Cú pháp chung:

#### Cú pháp lọc theo nhãn

```

1 mask = (labels == desired_label)
2 filtered_samples = data[mask]

```

#### Trong đó:

- **labels**: mảng nhãn của dữ liệu (cùng số lượng với **data**).
- **desired\_label**: nhãn cần chọn (ví dụ: 1 = mèo, 0 = chó).
- **mask**: mảng Boolean đánh dấu các mẫu có nhãn mong muốn.

### Ví dụ minh họa:

```

1 import numpy as np
2
3 # Tap du lieu anh va nhan tuong ung
4 images = np.array(["img1", "img2", "img3",
5 , "img4"])
6 labels = np.array([1, 0, 1, 0]) # 1 =
7      meo, 0 = cho
8
9 # Loc chi lay anh meo
10 mask_cats = (labels == 1)
11 cat_images = images[mask_cats]
12 print("Mask:", mask_cats)
13 print("Cat images:", cat_images)

```

===== Output =====

Mask: [ True False True False]  
Cat images: ['img1' 'img3']

### Giải thích:

- `labels == 1` tạo mask: [True, False, True, False].
- `images[mask]` chỉ giữ các phần tử tại vị trí True, tương ứng các ảnh có nhãn = 1.
- Kết quả: chỉ còn lại 2 ảnh mèo `img1` và `img3`.

**Mở rộng:** Có thể kết hợp nhiều điều kiện, ví dụ:

- Chỉ chọn mèo **và** có kích thước lớn: `(labels == 1) & (sizes > 200)`.
- Chọn mèo **hoặc** chó: `(labels == 1) | (labels == 0)`.

### 4.7.5. Kết hợp Filtering với Sorting và Aggregation

**Mục đích:** Trong thực tế, thao tác lọc (filtering) thường chỉ là bước đầu. Dữ liệu sau khi được lọc tiếp tục cần:

- **Tính toán thống kê** – ví dụ tính trung bình (`mean`), tổng (`sum`) trên dữ liệu hợp lệ.
- **Sắp xếp** – ví dụ sắp xếp điểm số giảm dần sau khi loại bỏ các giá trị không hợp lệ.

**Ý nghĩa:** Kết hợp **mask** với **sorting** và **aggregation** giúp:

- Làm sạch dữ liệu trước khi tính toán.
- Tiết kiệm thời gian xử lý (chỉ tính toán trên dữ liệu cần thiết).

### Cú pháp chung:

## Cú pháp

```

1 # 1) Loc du lieu hop le
2 valid = data[mask]
3
4 # 2) Tinh toan hoac sap xep
5 result_aggregation = np.mean(valid)           # hoac np.sum(valid)
6 result_sorted = np.sort(valid)[::-1]          # sap xep giam dan

```

## Ví dụ minh họa:

```

1 import numpy as np
2
3 scores = np.array([10, 50, 30, 90, 100,
15])
4
5 # 1) Loc diem >30
6 valid = scores[scores > 30]
7
8 # 2) Tinh trung binh diem hop le
9 mean_valid = np.mean(valid)
10
11 # 3) Sap xep giam dan diem hop le
12 sorted_desc = np.sort(valid)[::-1]
13
14 print("Valid scores:", valid)
15 print("Mean of valid scores:", mean_valid
    )
16 print("Sorted desc:", sorted_desc)

```

```

=====
Output =====
Valid scores: [ 50  90 100]
Mean of valid scores: 80.0
Sorted desc: [100  90  50]

```

## Giải thích:

- `mask = scores > 30` lọc ra các điểm hợp lệ: [50, 90, 100].
- `np.mean(valid)` tính trung bình các điểm hợp lệ  $\Rightarrow 80.0$ .
- `np.sort(valid)[::-1]` sắp xếp giảm dần sau khi lọc.

**Mở rộng:** Có thể kết hợp nhiều thao tác hơn:

- Lọc điểm hợp lệ  $\rightarrow$  Tính **top-k** tổng xác suất (`sum(sorted_desc[:k])`).
- Loại bỏ outlier  $\rightarrow$  Sắp xếp dữ liệu sạch rồi tính median hoặc percentile.

#### 4.7.6. Tổng kết

Kỹ thuật	Ý nghĩa / Ứng dụng
<b>Mask cơ bản</b>	Lọc dữ liệu theo điều kiện đơn giản ( $a > 5$ ).
<b>Kết hợp mask</b>	Lọc phức tạp bằng & (AND),   (OR), ~ (NOT).
<b>Mask 2D/3D</b>	Lọc dữ liệu trên mảng nhiều chiều.
<b>ML: Outlier filtering</b>	Loại bỏ điểm dữ liệu bất thường (mean $\pm k * std$ ).
<b>ML: Chọn mẫu theo nhãn</b>	Lọc tập dữ liệu theo nhãn cụ thể (ví dụ chỉ lấy mèo).
<b>Kết hợp sort &amp; aggregation</b>	Lọc trước rồi mới sắp xếp hoặc tính toán thống kê.

### 4.8. Tổng kết — Array Transformations

#### Tóm tắt nhanh

**Array Transformations** là nhóm thao tác cốt lõi trong NumPy, cho phép:

- **Thay đổi hình dạng (Reshape):** Chuyển đổi cấu trúc mảng mà không làm thay đổi dữ liệu.
- **Thay đổi trục (Transpose):** Đổi vị trí các trục (columns  $\leftrightarrow$  rows).
- **Nhân bản và ghép mảng (Repeat & Concatenation):** Tạo mảng lớn hơn từ các mảng nhỏ.
- **Tóm tắt dữ liệu (Aggregation):** Tính toán thống kê như tổng, trung bình, giá trị lớn nhất/nhỏ nhất.
- **Sắp xếp (Sorting):** Tổ chức lại dữ liệu theo thứ tự tăng hoặc giảm dần.
- **Lọc dữ liệu (Filtering):** Loại bỏ hoặc chọn các phần tử dựa trên điều kiện (mask Boolean).

#### Bảng so sánh nhanh các nhóm thao tác

Nhóm	Chức năng chính	Hàm/Phương thức quan trọng
<b>Reshape</b>	Thay đổi hình dạng mảng mà không đổi dữ liệu.	<code>reshape, flatten, ravel</code>
<b>Transpose</b>	Đổi trục mảng (hàng cột).	<code>.T, np.transpose</code>
<b>Repeat &amp; Concatenation</b>	Lặp, ghép hoặc xếp chồng các mảng.	<code>repeat, tile, concatenate, hstack, vstack</code>
<b>Sorting</b>	Sắp xếp tăng dần hoặc giảm dần theo trục.	<code>np.sort, argsort, slicing [::-1]</code>
<b>Aggregation</b>	Tóm tắt dữ liệu bằng thống kê.	<code>sum, mean, max/min, argmax/argmin</code>
<b>Filtering</b>	Lọc theo điều kiện logic.	Mask Boolean: <code>a[mask]</code> , kết hợp <code>&amp;,  , ~</code>

## Ý nghĩa trong Machine Learning

- Reshape & Transpose:** Chuẩn bị dữ liệu đầu vào (chuyển đổi tensor, batch processing).
- Repeat/Concatenate:** Tạo batch dữ liệu lớn hoặc ghép các feature maps.
- Sorting:** Chọn top-k xác suất cao nhất, sắp xếp đặc trưng quan trọng.
- Aggregation:** Tính accuracy, tính trung bình/percentile để đánh giá mô hình.
- Filtering:** Loại bỏ outlier, chọn mẫu thuộc nhãn cụ thể để huấn luyện hoặc kiểm thử.

### Kết luận

Việc thành thạo các thao tác biến đổi mảng giúp tăng tốc xử lý dữ liệu và tối ưu hóa quy trình học máy. Hầu hết các bước tiền xử lý (*data preprocessing*) đều dựa vào các kỹ thuật này.

## Phần 5: View vs Copy – Hiểu đúng để tránh bug

### Giới thiệu

Trong NumPy, chúng ta có thể dễ dàng viết vài dòng code tưởng vô hại mà vô tình phá nát dữ liệu gốc, dẫn đến lỗi rất khó debug. Lý do? Bạn **nghĩ** mình đang làm việc trên một bản sao, nhưng hóa ra lại là một “cái nhìn” (*view*) tối mảng gốc.

Hiểu **view** và **copy** không chỉ giúp ta tránh được bug rình rập, mà còn tối ưu hóa hiệu suất và tránh cấp phát bộ nhớ không cần thiết.

#### 5.1. View là gì?

**View** là một đối tượng `ndarray` không cấp phát vùng nhớ mới, mà chỉ trỏ (reference) tới vùng nhớ gốc. Mọi thao tác thay đổi giá trị trên view đều ảnh hưởng tới dữ liệu ban đầu.

##### Ở tầng bộ nhớ:

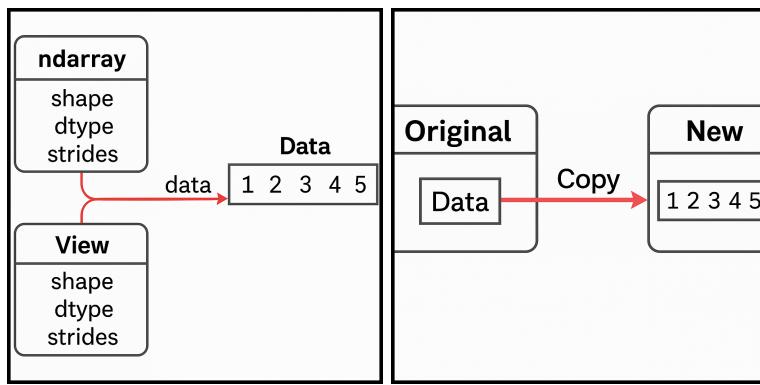
- Mỗi `ndarray` gồm:
  - `data`: con trỏ tới vùng nhớ chứa dữ liệu.
  - `shape`, `dtype`, `strides`: mô tả cách truy cập data.
- Khi tạo view:
  - `data` giữ nguyên.
  - `shape`, `strides` có thể khác (ví dụ: `reshape`, `slicing`).
  - Không copy bất kỳ bit dữ liệu nào.

#### 5.2. Copy là gì?

**Copy** là một mảng mới, có vùng nhớ riêng độc lập. Mọi thay đổi trên bản copy **không ảnh hưởng** đến mảng gốc.

##### Ở tầng bộ nhớ:

- Cấp phát vùng nhớ mới cho `data`.
- Copy từng phần tử từ mảng gốc sang.
- `data` là địa chỉ khác hoàn toàn so với mảng ban đầu.



So sánh giữa **View** (trái) và **Copy** (phải) trong NumPy. View dùng chung vùng nhớ với mảng gốc thông qua cùng con trỏ **data**, trong khi Copy tạo vùng nhớ mới và độc lập.

### 5.3. Khi nào tạo ra View? Khi nào tạo ra Copy?

Trong NumPy, nhiều thao tác tưởng chừng đơn giản lại tạo ra **view**, còn những thao tác khác lại âm thầm tạo ra **copy**. Việc hiểu rõ điều này giúp tránh bug và kiểm soát bộ nhớ hiệu quả hơn.

Cách truy cập	View/Copy	Giải thích chi tiết
<code>a[1:5]</code> (slicing)	View	Tạo ra view vì chỉ thay đổi cách truy cập thông qua <b>strides</b> , không tạo vùng nhớ mới. Rất hiệu quả nhưng dễ gây bug nếu vô tình thay đổi dữ liệu gốc.
<code>a[[1, 2, 3]]</code> (fancy indexing)	Copy	Fancy indexing buộc phải tạo ra một mảng mới chứa dữ liệu được sao chép từ các vị trí chỉ định → là <b>copy</b> . Tốn bộ nhớ hơn nhưng an toàn.
<code>a[a &gt; 0]</code> (boolean masking)	Copy	Cũng là một dạng fancy indexing: chọn các phần tử theo điều kiện logic → NumPy không thể dựa vào <b>strides</b> , nên phải tạo <b>copy</b> .
<code>a.T</code> (transpose)	View	Transpose chỉ thay đổi thứ tự truy cập chiều → thay đổi <b>strides</b> , giữ nguyên <b>data</b> → là <b>view</b> . Nhưng với mảng không liên tục trong bộ nhớ, có thể sẽ bị copy ngầm khi tính toán.
<code>a.reshape(...)</code>	View (nếu được)	Nếu memory layout còn phù hợp (liên tục và đúng <b>strides</b> ) thì trả về <b>view</b> . Nếu không, NumPy sẽ ngầm tạo <b>copy</b> → cần dùng <code>np.shares_memory()</code> để kiểm tra.
<code>a.copy()</code>	Copy	Ép buộc tạo bản sao độc lập hoàn toàn khỏi dữ liệu gốc. Rất hữu ích khi cần chỉnh sửa mà không làm ảnh hưởng array gốc.

Ghi chú:

- Nếu không chắc **view** hay **copy**, hãy dùng: `np.shares_memory(a, b)` để kiểm tra xem hai array có dùng chung vùng nhớ hay không.
- Ngoài ra, ta cũng có thể dùng: `b.base is a`  
Trả về `True` nếu `b` là **view** của `a`.

## 5.4. Một số ví dụ minh họa

### 1. Slicing → View

```

1 import numpy as np
=====
2
3 a = np.array([1, 2, 3, 4, 5])
4 b = a[1:4]
5 b[0] = 999
6
7 print('a:', a)
8 print('b:', b)
===== Output =====
a: [ 1 999 3 4 5]
b: [999 3 4]

```

**Phân tích:** `b` là **view** → dùng chung data với `a`.

### 2. Fancy Indexing → Copy

```

1 a = np.array([1, 2, 3, 4, 5])
2 b = a[[1, 2, 3]]
3 b[0] = 999
4
5 print('a:', a)
6 print('b:', b)
===== Output =====
a: [1 2 3 4 5]
b: [999 3 4]

```

**Giải thích:** `b` sống độc lập, không ảnh hưởng `a` vì là **copy**.

Khi muốn làm việc độc lập với mảng gốc, hãy dùng `.copy()`.

## 5.5. Kiểm tra bằng `np.shares_memory()`

Trong NumPy, việc một mảng là **view** hay **copy** không phải lúc nào cũng dễ phân biệt chỉ bằng mắt thường. Một cách hiệu quả và đáng tin cậy để kiểm tra là dùng hàm `np.shares_memory()`.

**Cú pháp:**

```
1 np.shares_memory(x, y)
```

Hàm này sẽ trả về:

- `True` nếu `x` và `y` dùng chung bộ nhớ (có vùng đè nhau).
- `False` nếu `x` và `y` là hai mảng độc lập (`copy`).

**Ví dụ minh họa:**

```

1 import numpy as np
2
3 a = np.arange(10)
4 b = a[2:5]      # slicing → view
5 c = a[[2, 3, 4]] # fancy indexing → copy
6
7 print(np.shares_memory(a, b)) # True → b is view
8 print(np.shares_memory(a, c)) # False → c is copy

```

**Phân tích:**

- `b = a[2:5]` là slicing → chỉ thay đổi cách truy cập, không cấp phát mới → `np.shares_memory(a, b)` trả về `True`.
- `c = a[[2, 3, 4]]` dùng fancy indexing → NumPy buộc phải cấp phát vùng nhớ mới → `np.shares_memory(a, c)` trả về `False`.

**Lưu ý:**

- `np.shares_memory()` rất hữu ích để kiểm tra trong các thao tác phức tạp như `reshape()`, `transpose()`, slicing nhiều tầng, hoặc các tình huống chúng ta nghi ngờ bị aliasing bộ nhớ.
- Kết quả phụ thuộc vào việc hai mảng có vùng bộ nhớ bị chồng nhau hay không (không nhất thiết phải là cùng toàn bộ).

**Ngoài lề:** Nếu chúng ta chỉ muốn biết một mảng có phải là view của một mảng cụ thể không (thay vì kiểm tra bộ nhớ chung), ta có thể dùng:

```

1 b.base is a
→ Trả về True nếu b là view được tạo từ a.

```

## 5.6. Fancy Indexing – Kẻ thù thầm lặng

**Fancy indexing** (chỉ mục hóa nâng cao) là kỹ thuật truy cập phần tử của mảng bằng một danh sách (array) chỉ số – thay vì một lát cắt (slice). Tuy nhiên, đây cũng là **nguồn gốc của rất nhiều bug âm thầm** trong NumPy, bởi nó tạo ra một **bản sao (copy)** thay vì **view** như slicing.

**Ví dụ:**

```

1 import numpy as np
2
3 a = np.array([10, 20, 30, 40, 50])
4 b = a[[1, 2]]      # Fancy indexing → COPY
5 b[0] = 999
6
7 print('a:', a)
8 print('b:', b)

```

===== Output =====
a: [10 20 30 40 50] KHÔNG đổi!
b: [999 30]

**Giải thích:**

- Dòng `b = a[[1, 2]]` sử dụng **fancy indexing** (chỉ định index bằng mảng).
- Kết quả: NumPy buộc phải **tạo mảng mới** (copy) chứa các giá trị tại chỉ số 1 và 2.

- Vì vậy, b sống độc lập hoàn toàn với a thay đổi b| KHÔNG làm thay đổi a|.
- Nếu ta nhầm tưởng đây là view, ta sẽ rơi vào những bug cực kỳ khó debug trong các đoạn xử lý dữ liệu lớn.

**Cách phát hiện:** Chúng ta có thể kiểm tra bằng cách dùng:

```
1 np.shares_memory(a, b)      # False    copy
```

Fancy indexing luôn trả về copy. Vì vậy, hãy:

- Chỉ dùng khi thật sự cần bản sao độc lập.
- Tránh nhầm lẫn với slicing (view).
- Luôn dùng np.shares\_memory() hoặc .base is ... khi cần chắc chắn.

## 5.7. View để tiết kiệm bộ nhớ

Trong thực tế, các mảng dữ liệu NumPy có thể rất lớn — đặc biệt trong các bài toán xử lý ảnh, AI, dữ liệu tín hiệu, hoặc mô phỏng khoa học. Việc tạo view thay vì copy giúp tiết kiệm một lượng lớn bộ nhớ RAM và tăng hiệu năng đáng kể.

**Ví dụ:**

```
1 import numpy as np
2
3 a = np.random.rand(10000, 10000)  # ~800MB if dtype=float64
4 b = a[:, :100]                  # View on top 100 columns
```

**Phân tích:**

- Biến a là một mảng 100 triệu số thực 64-bit → khoảng 800MB bộ nhớ.
- Khi tạo b = a[:, :100], đây là một **view**:
  - Không có dữ liệu nào được sao chép.
  - b chỉ thay đổi shape và strides để nhìn vào 100 cột đầu của a.
- Kết quả: bộ nhớ không tăng, tốc độ xử lý cao, và rất tiết kiệm tài nguyên.

**Lợi ích của view trong bài toán lớn:**

- **Tiết kiệm RAM:** Không cần nhân đôi dữ liệu khi chỉ cần thao tác một phần nhỏ.
- **Hiệu năng cao:** Truy cập nhanh, không tốn thời gian copy dữ liệu.
- **Thân thiện cache CPU:** Truy cập dữ liệu tuyến tính, tránh cache miss.

**Cẩn trọng khi dùng:**

- Mọi thay đổi trên view sẽ làm thay đổi mảng gốc.
- Nếu mảng gốc bị xóa (hoặc bị thay đổi), view có thể trở nên không hợp lệ.

- Khi cần thao tác độc lập, luôn dùng `.copy()` để tránh bug không rõ ràng.

- Trong các hệ thống xử lý ảnh/video (OpenCV, PyTorch), `view` thường được tận dụng để tăng tốc đáng kể.
- Với mảng lớn, việc lõi tạo copy có thể làm tăng RAM từ vài trăm MB lên hàng GB dễ crash nếu không kiểm soát.

## 5.8. Benchmark: View vs Copy trong thực tế

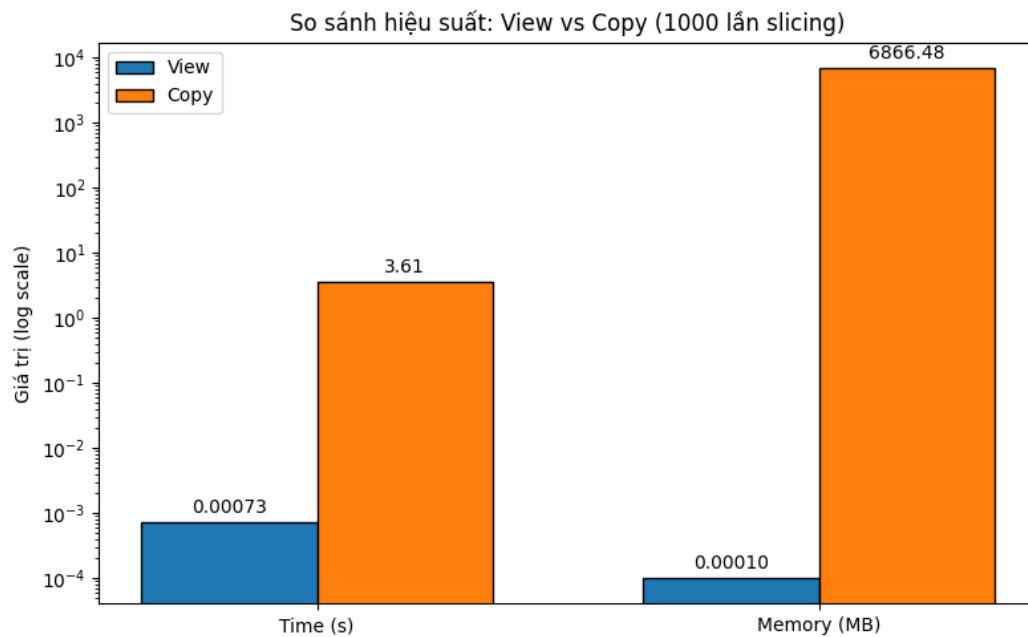
Để đánh giá hiệu suất khi làm việc với mảng lớn trong NumPy, ta thực hiện benchmark với một mảng có kích thước `a.shape = (10000, 10000)`, sau đó lặp lại thao tác slicing **1000 lần** theo hai cách:

- View:** `a[:, :100]` — tạo view (không sao chép dữ liệu)
- Copy:** `a[:, :100].copy()` — tạo bản sao độc lập (copy toàn bộ slice)

Sau mỗi thao tác, ta đo thời gian thực thi (tính bằng giây) và mức tiêu thụ bộ nhớ (tính bằng MB). Kết quả như sau:

- View:** mất 0.00073s, tăng thêm chỉ 0.0001 MB RAM
- Copy:** mất tới 3.61s, tăng đến 6866.48 MB RAM

**Biểu đồ log-scale dưới đây cho thấy chênh lệch rõ rệt về hiệu suất giữa View và Copy:**



**Nhận xét:**

- View nhanh hơn **gần 5000 lần** và tiết kiệm gần như toàn bộ bộ nhớ.
- Copy tiêu tốn tài nguyên khủng khiếp khi xử lý lượng lớn slice.
- Nếu bạn vô tình dùng **fancy indexing** hay quên dùng `.copy()` đúng lúc, hệ thống của bạn có thể bị nghẽn tài nguyên hoặc chạy cực kỳ chậm.

Khi làm việc với dữ liệu lớn (hình ảnh, tín hiệu, mảng số liệu,...), hãy ưu tiên View để tránh nhân đôi dữ liệu. Chỉ sử dụng Copy khi thực sự cần thao tác độc lập và có kiểm soát.

**Tóm lại, chúng ta có:**

Trường hợp	View	Copy	Ghi chú
Slicing	✓		Khi muốn độc lập → <code>.copy()</code>
Fancy indexing		✓	Luôn tạo bản sao
Reshape	✓(tùy)	Có thể	Phụ thuộc layout
Transpose	✓		Không cần copy
<code>.copy()</code>		✓	Ép tạo bản sao

## Phần 6: Vectorization & Broadcasting

### 6.1. Broadcasting

Thuật ngữ broadcasting mô tả cách NumPy xử lý các mảng có hình dạng khác nhau trong các phép toán số học. Dưới một số điều kiện nhất định, mảng nhỏ hơn sẽ được “broadcast” qua mảng lớn hơn để chúng có hình dạng tương thích. Broadcasting cung cấp một phương thức để vector hóa các phép toán trên mảng, giúp bạn “bớt viết vòng lặp” hơn, từ đó tối ưu code và giảm bớt bug.

Trong trường hợp đơn giản nhất, hai mảng phải có cùng kích thước để thực hiện phép toán với các phần tử của mảng:

```

1 import numpy as np
2
3 a = np.array([1.0, 2.0, 3.0])
4 b = np.array([2.0, 2.0, 2.0])
5 result = a * b

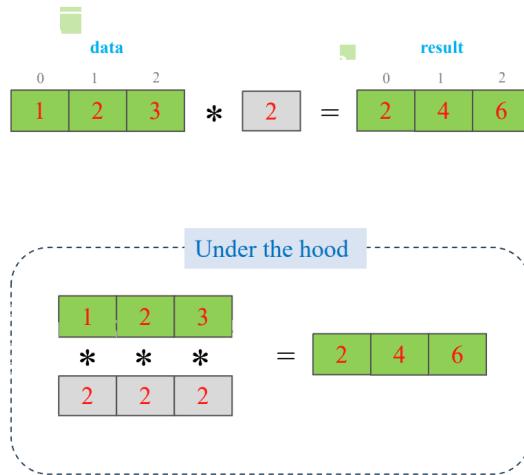
```

Broadcasting cũng cho phép tính toán từng phần tử giữa các mảng và các giá trị vô hướng (*Giải thích kỹ ở phần quy tắc phía sau*). Các giá trị vô hướng được tự động mở rộng để phù hợp với kích thước của mảng. Ví dụ:

```

1 import numpy as np
2 a = np.array([1, 2, 3])
3 b = 2
4 a * b
5 # output [2 4 6]

```



#### Quy tắc broadcasting tổng quát

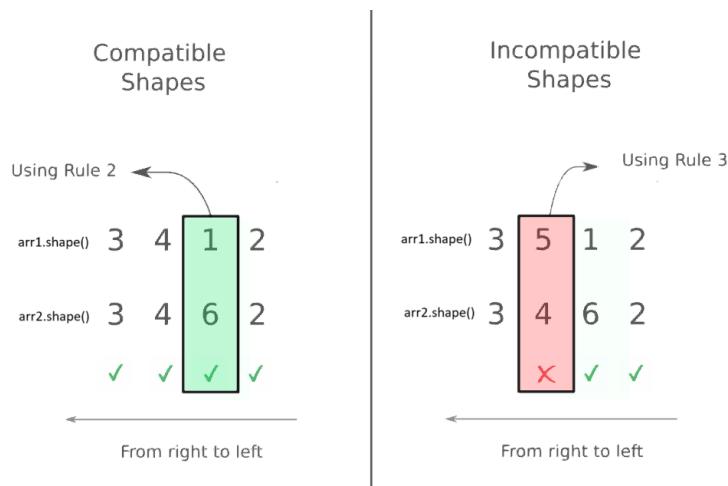
Trước khi bắt đầu, một định nghĩa quan trọng mà chúng ta cần phải biết đó là thứ hạng(rank) của mảng trong numpy. Thứ hạng(rank) là tổng số chiều mà một mảng Numpy có, ví dụ:  $b.shape()$  là  $(1, 6)$  có rank là 2,  $b.shape()$  là  $(3, 4, 3)$  có rank là 3.

Để xác định hai mảng nào phù hợp cho các phép toán, NumPy so sánh hình dạng của hai mảng theo từng chiều bắt đầu từ các chiều sau của mảng theo hướng **tiền về phía trước**. (từ phải sang trái):

- Nếu hai chiều có cùng kích thước, thì chúng tương thích.
- Một trong hai chiều có kích thước bằng 1, chúng cũng tương thích.
- Nếu cả hai chiều không bằng nhau và không có chiều nào bằng 1 thì NumPy sẽ báo lỗi và dừng lại.

### Mảng có thứ hạng bằng nhau

Với 2 mảng có thứ hạng bằng nhau, chúng ta thực hiện xét từ phải qua trái và thực hiện so sánh các chiều của chúng. Ở phía bên trái, Numpy so sánh số chiều từ phải qua trái của 2 mảng và thấy rằng chúng thỏa mãn quy tắc 1 và  $2 \Rightarrow \text{arr1}$  và  $\text{arr2}$  tương thích, và có thể thực hiện tính toán. Ở phía bên phải, Numpy cũng thực hiện so sánh tương tự, nhưng phát hiện ra rằng đã vi phạm quy tắc số 3  $\Rightarrow \text{arr1}$  và  $\text{arr2}$  không tương thích, khi thực hiện phép toán sẽ cho ra lỗi ValueError.



- Quy tắc 1

```

1 import numpy as np
2
3 a = np.array([[1, 2, 3],
4                 [4, 5, 6]])      # shape (2, 3)
5 b = np.array([[10, 20, 30],
6                 [40, 50, 60]]) # shape (2, 3)
7
8 result = a + b
9 print(result)

```

- Quy tắc 2

```

1 a = np.array([[1, 2, 3],
2                 [4, 5, 6]])      # shape (2, 3)
3 b = np.array([[10], 
4                 [20]])        # shape (2, 1)
5
6 result = a + b
7 print(result)

```

- Quy tắc 3

```

1 a = np.array([[1, 2, 3],
2                 [4, 5, 6]])      # shape (2, 3)
3 b = np.array([[10, 20],
4                 [30, 40]])      # shape (2, 2)
5
6 result = a + b    #ValueError

```

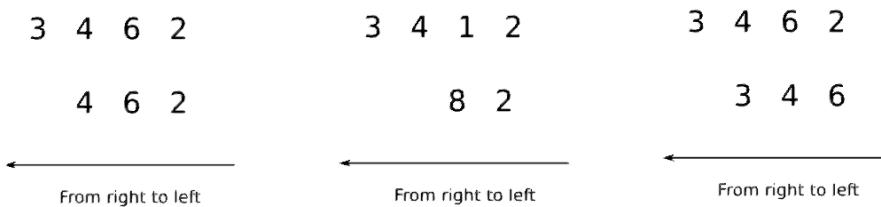
### Mảng khác thứ hạng

Các mảng có thứ hạng không bằng nhau cũng có thể được vận hành theo một số điều kiện nhất định. Một lần nữa, Numpy áp dụng quy tắc di chuyển từ **phải sang trái** và so sánh hai mảng. Broadcasting chỉ xảy ra *nếu và chỉ nếu* từng chiều tương ứng thỏa mãn một trong hai điều kiện sau:

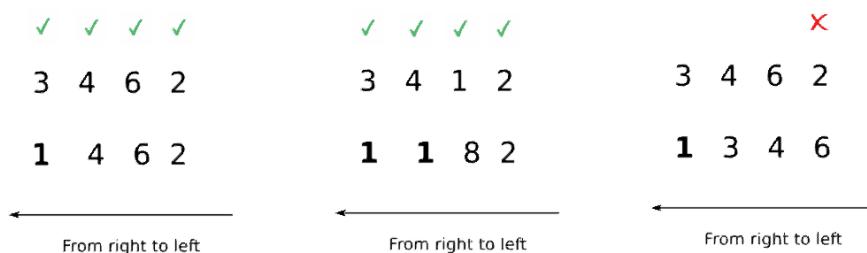
- Hai kích thước bằng nhau, hoặc
  - Một trong hai chiều có kích thước bằng 1
- Nếu **bất kì chiều nào** không thỏa, toàn bộ phép toán sẽ lỗi.

Điều này cũng tương tự như việc so sánh mảng có thứ hạng bằng nhau, chỉ khác ở chỗ Numpy tự thêm chiều 1 vào đầu mảng có shape ngắn hơn.

Hãy xem xét các ví dụ sau:



Trong hình ảnh đầu tiên, mảng đầu tiên có thứ hạng 4, trong khi mảng thứ 2 có thứ hạng 3. Để so sánh hai mảng như vậy, Numpy sẽ thêm các chiều có kích thước 1 vào mảng có shape ngắn hơn để thực hiện tính toán. Khi đó, nó được hiểu như thế này : Ở từng chiều được so sánh từ phải qua trái, cả hình 1 và hình 2, các chiều đều thỏa mãn một trong hai điều kiện trên. Tuy nhiên, đối với hình 3, các chiều đều không thỏa mãn, sinh ra lỗi. (Lưu ý rằng tôi sử dụng chữ đậm để thêm vào vì đây chỉ là cách để hình dung NumPy đang làm gì. Về mặt nội bộ, không có thêm vào)



**Lưu ý:** Quá trình này **không sinh ra mảng mới** đầy đủ trong RAM — NumPy chỉ trả về một view “ảo” trỏ đến dữ liệu gốc, giữ hiệu năng cao.

Giờ thì chắc hẳn bạn đã hiểu rõ vì sao numpy có thể thực hiện tính toán giữa mảng và scalar một cách mượt mà như vậy rồi đúng không?

```

1 import numpy as np
2 a = np.array([1, 2, 3])
3 b = 2
4 a * b
5 # output [2 4 6]

```

## Một số ví dụ thực tế

*Thêm màu vào một hình ảnh*

giả sử bạn có một bức ảnh màu với 3 kênh (R,G,B). Bạn muốn với mỗi pixel tăng giá trị màu đỏ lên 10, màu xanh lá cây lên 5 và màu xanh lam lên 15. Điều này có thể dễ dàng thực hiện bằng broadcasting.

Như đã biết, một hình ảnh màu được biểu diễn dưới dạng ma trận (H,W, C) nếu chúng ta đọc chúng bằng opencv.

```

1 import numpy as np
2 import cv2
3
4 img = cv2.imread("image1.jpeg")
5 print(img.shape)
6 #output -> (768,1024,3)

```

Tiếp theo, chúng ta sẽ lần lượt thêm các màu vào các kênh màu tương ứng

```

1
2 add_color = np.array([10, 5, 15], dtype=np.uint8)
3 result = img + add_color

```

*Hình dung các vòng lặp như một mảng*

Giả sử ta có hai mảng [1,2,3] và [4,5]. Ta muốn lấy tổng của tích mọi phần tử của 2 mảng. Nếu không biết về broadcast, chúng ta nghĩ ngay đến vòng lặp đúng không nào?

```

1 import numpy as np
2
3 arr1 = np.array([1,2,3])
4 arr2 = np.array([4,5])
5
6 sum = 0
7 for i in arr1:
8     for j in arr2:
9         sum += i*j
10 print(sum)

```

Cũng không khó lắm đúng không? Nhưng đây là một vòng lặp lồng nhau và thử nghĩ xem, nếu kích thước của các mảng này trở lên quá lớn thì thời gian duyệt vòng lặp cũng tăng lên. Đó là khi broadcast phát huy tác dụng.

```

1 import numpy as np
2
3 arr1 = np.array([1,2,3])
4 arr2 = np.array([4,5])
5
6 result = arr1*arr2
7 sum = np.sum(result)
8 print(sum)

```

## 6.2. Vectorization

Vectorization là kỹ thuật “thao tác” toàn bộ mảng cùng lúc thay vì lặp qua từng phần tử bằng vòng lặp Python

Thay vì viết:

```
1 import numpy as np
2 def myfunc(a, b):
3     "Return a-b if a>b, otherwise return a+b"
4     if a > b:
5         return a - b
6     else:
7         return a + b
8
9 a_list = [1, 2, 3, 4]
10 b_value = 2
11
12 result = []
13 for a in a_list:
14     result.append(myfunc(a, b_value))
15
16 result = np.array(result)
17 print(result) # [3 4 1 2]
```

bạn dùng ngay:

```
1 import numpy as np
2 def myfunc(a, b):
3     "Return a-b if a>b, otherwise return a+b"
4     if a > b:
5         return a - b
6     else:
7         return a + b
8 vfunc = np.vectorize(myfunc)
9 vfunc([1, 2, 3, 4], 2)
10 print(vfunc) # [3,4,1,2]
```

**Lưu ý:** Hàm `np.vectorize()` chủ yếu được cung cấp để tiện sử dụng, chứ không nhằm mục đích tăng hiệu suất. Về bản chất, việc thực thi vẫn là một vòng lặp `for`

## Phần 7: AI Applications

### 1. OpenCV và NumPy

Trong các ứng dụng **Trí tuệ nhân tạo (AI)**, đặc biệt là **Thị giác máy tính (Computer Vision)**, việc xử lý và biến đổi ảnh là bước tiền đề cực kỳ quan trọng.

**NumPy** đóng vai trò là công cụ xử lý dữ liệu nền tảng, giúp thao tác nhanh chóng trên ma trận ảnh (vốn chỉ là các mảng số). Trong khi đó, **OpenCV** là thư viện chuyên dụng, hỗ trợ đọc, lưu, hiển thị và thực hiện các thao tác xử lý ảnh ở mức độ cao hơn.

Phần này sẽ trình bày cách kết hợp NumPy và OpenCV thông qua các thao tác cơ bản:

- Hiểu cách biểu diễn ảnh dưới dạng ma trận (mức xám và ảnh màu).
- Đọc, lưu, và kiểm tra thông tin ảnh bằng OpenCV.
- Chuyển đổi giữa các không gian màu để hiển thị chính xác trên các thư viện như Matplotlib.

*Đây chính là bước khởi đầu quan trọng để tiến tới các bài toán AI phức tạp hơn như nhận diện khuôn mặt, phân loại ảnh, hoặc phát hiện đối tượng.*

#### 1.1. Ảnh mức xám (Grayscale)

##### Khái niệm

- Ảnh mức xám là loại ảnh chỉ chứa **1 kênh (channel)** duy nhất, mô tả **độ sáng (intensity)** của từng điểm ảnh (pixel).
- Mỗi pixel được biểu diễn bằng một giá trị số nguyên trong khoảng **0 – 255**:
  - 0** → Đen hoàn toàn (cường độ sáng thấp nhất).
  - 255** → Trắng hoàn toàn (cường độ sáng cao nhất).
  - Giá trị trung gian** (ví dụ 128) → Tông xám với mức độ sáng tương ứng.
- Mắt người cảm nhận các mức độ sáng khác nhau nên ảnh grayscale phù hợp cho nhiều tác vụ thị giác máy tính.

##### Đặc điểm

- Dữ liệu ảnh được lưu dưới dạng **ma trận 2 chiều** (NumPy array):  
Kích thước (shape) = (Chiều cao (Height), Chiều rộng (Width))
- Mỗi phần tử trong ma trận** = 1 giá trị pixel (0–255).
- Độ phân giải (Resolution)** = Tổng số pixel = Height × Width.
- Thường dùng trong:
  - Xử lý ảnh cơ bản (lọc, làm mờ, phát hiện biên).
  - Tiền xử lý trong nhận dạng khuôn mặt, OCR, thị giác máy tính.

### Minh họa trực quan:

- Mỗi điểm ảnh (pixel) trong ảnh grayscale tương ứng với một giá trị  $p = \text{scalar}$ .
- Ví dụ: Một vùng nhỏ của ảnh mắt người có ma trận giá trị pixel như sau:



### Giải thích:

- Hình bên trái:** Ảnh gốc mức xám.
- Giữa:** Phóng to một vùng ảnh, mỗi ô vuông đại diện một pixel.
- Bên phải:** Ma trận số thể hiện giá trị cường độ sáng của từng pixel.

## 1.2. Ảnh màu (Color Image)

### Khái niệm

- Ảnh màu thường được biểu diễn theo **không gian màu RGB**, là cách phổ biến nhất trong xử lý ảnh số:
  - R (Red)** = Kênh màu đỏ.
  - G (Green)** = Kênh màu xanh lục.
  - B (Blue)** = Kênh màu xanh lam.
- Mỗi điểm ảnh (pixel) được mô tả bằng một bộ ba giá trị  $(R, G, B)$ , mỗi giá trị nằm trong khoảng **0 – 255**:
  - 0** → cường độ màu thấp nhất (tắt kênh màu đó).
  - 255** → cường độ màu cao nhất.
  - Sự kết hợp ba kênh này tạo nên mọi màu sắc hiển thị trên ảnh.

### Đặc điểm

- Dữ liệu ảnh được lưu dưới dạng **ma trận 3 chiều**:

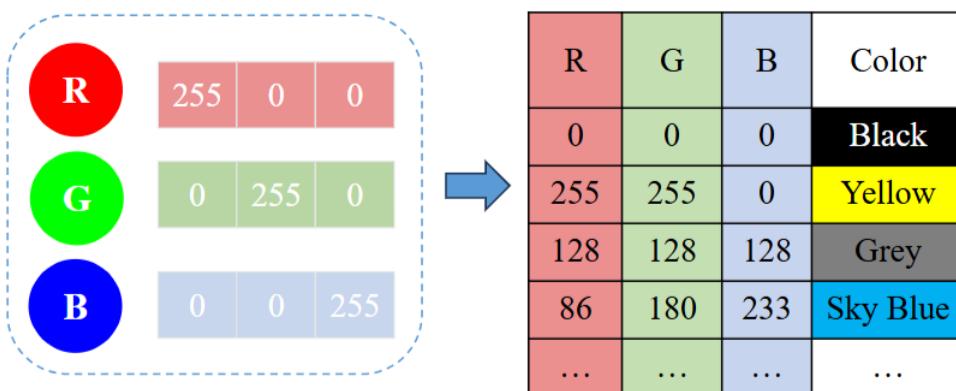
Kích thước (shape) = (Chiều cao (Height), Chiều rộng (Width), 3)

- Mỗi kênh **R, G, B** thực chất là một **ảnh mức xám riêng**, mô tả cường độ màu tương ứng.
- Độ phân giải (Resolution)** = Tổng số điểm ảnh = Height  $\times$  Width.

### Ví dụ minh họa:

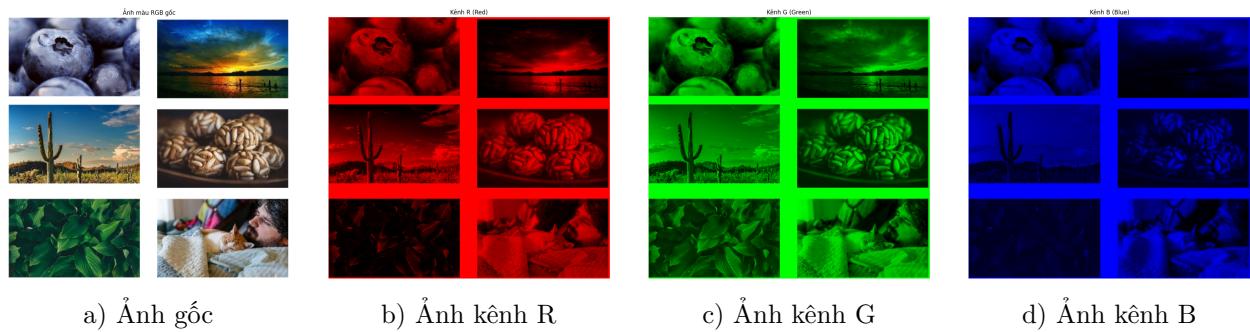
- Cấu trúc RGB:** Một số ví dụ về giá trị  $(R, G, B)$  và màu tương ứng:

R	G	B	Màu sắc và giải thích
0	0	0	<b>Đen (Black):</b> Cả ba kênh đều tắt hoàn toàn $\rightarrow$ không có ánh sáng, nên ta thấy màu đen.
255	255	0	<b>Vàng (Yellow):</b> Kênh Đỏ và Xanh lục sáng tối đa, kênh Xanh lam tắt $\rightarrow$ sự pha trộn giữa Đỏ + Xanh lục tạo ra màu vàng.
128	128	128	<b>Xám (Grey):</b> Ba kênh sáng đều ở mức trung bình $\rightarrow$ ánh sáng cân bằng, tạo tông xám trung tính.
86	180	233	<b>Xanh da trời (Sky Blue):</b> Kênh Xanh lam sáng mạnh nhất, kênh Xanh lục sáng vừa phải, kênh Đỏ yếu $\rightarrow$ cho ra màu xanh nhạt giống bầu trời.

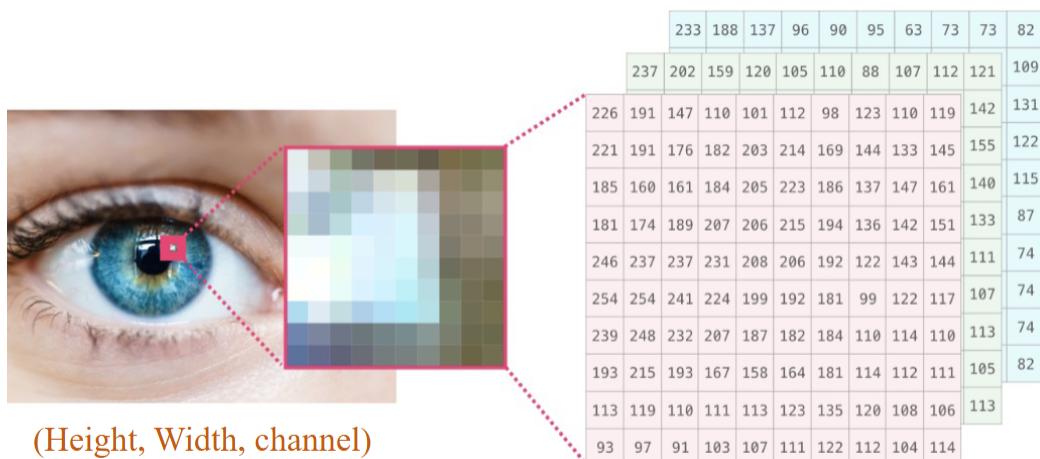


Bảng chuyển đổi giá trị RGB sang màu sắc tương ứng

- Ảnh màu thông thường:** Một ảnh màu có thể được tách thành ba kênh R, G, B như hình minh họa:

**Giải thích:**

- Bên trái (a): Ảnh màu RGB gốc.
- Bên phải (b, c, d): Ba kênh riêng biệt:
  - Kênh R (b) – vùng sáng thể hiện nơi có cường độ màu đỏ cao.
  - Kênh G (c) – vùng sáng thể hiện nơi có cường độ màu xanh lục cao.
  - Kênh B (d) – vùng sáng thể hiện nơi có cường độ màu xanh lam cao.

**Cấu trúc ma trận của ảnh RGB****Giải thích:**

- Mỗi điểm ảnh ( $r, g, b$ ) được lưu ở ba lớp (layer) tương ứng.
- Dữ liệu thực chất là một khối 3D: **(Height, Width, Channel)**.

### 1.3. Đọc ảnh bằng thư viện OpenCV

#### Khái niệm

- **OpenCV** (Open Source Computer Vision Library) là thư viện mã nguồn mở mạnh mẽ, hỗ trợ xử lý ảnh và thị giác máy tính.
- Trong OpenCV, **hàm cv2.imread()** được dùng để đọc ảnh từ tệp, với chế độ đọc ảnh (màu hoặc mức xám) được chỉ định bằng tham số thứ 2.

#### Cú pháp

```

1 import cv2
2
3 # Doc anh muc xam (Grayscale)
4 img_gray = cv2.imread("ten_anh.png", 0)
5
6 # Doc anh mau (Color)
7 img_color = cv2.imread("ten_anh.png", 1)

```

#### Giải thích tham số:

- 0: Ảnh được đọc ở dạng **Grayscale** – chỉ 1 kênh, mỗi pixel có giá trị từ 0 đến 255 (mức độ sáng).
- 1: Ảnh được đọc ở dạng **màu BGR** (Blue, Green, Red) – mặc định của OpenCV.
- (Tùy chọn) -1: Đọc đầy đủ cả kênh alpha (nếu có).

#### Kiểm tra kích thước (shape)

```

1 print(img_gray.shape)    # (H, W) - anh muc xam
2 print(img_color.shape)  # (H, W, 3) - anh mau (BGR)

```

#### Giải thích:

- **(H, W)**: chiều cao và chiều rộng ảnh mức xám.
- **(H, W, 3)**: ảnh màu có 3 kênh (B, G, R).

#### Ví dụ minh họa

```

1 import cv2
2
3 # Doc anh mau
4 image_color = cv2.imread("image1.png", 1)
5 print("Color image shape:", image_color.
      shape)
6
7 # Doc anh muc xam
8 image_gray = cv2.imread("image2.png", 0)
9 print("Gray image shape:", image_gray.
      shape)

```

```

=====
Output =====
Color image shape: (162, 311, 3)
Gray image shape: (162, 311)

```

#### Giải thích:

- Ảnh màu (BGR): hiển thị đúng màu sắc.
- Ảnh mức xám: chỉ còn 1 kênh, các mức sáng thể hiện bằng giá trị 0 – 255.



Ảnh màu (BGR)



Ảnh mức xám

### Lưu ý

- OpenCV sử dụng kênh màu **BGR** thay vì RGB như thông thường.
- Khi hiển thị bằng **Matplotlib** (`plt.imshow`), cần chuyển BGR → RGB để tránh sai lệch màu:

```

1 import matplotlib.pyplot as plt
2
3 img_rgb = cv2.cvtColor(image_color, cv2.COLOR_BGR2RGB)
4 plt.imshow(img_rgb)
5 plt.show()

```

### 1.4. Vì sao ảnh hiển thị sai màu trong Matplotlib?

#### Nguyên nhân

- OpenCV đọc ảnh màu theo thứ tự **BGR** (Blue – Green – Red).
- Matplotlib mặc định hiển thị theo thứ tự **RGB** (Red – Green – Blue).
- ⇒ Màu sắc bị đảo ngược, ví dụ: vùng màu đỏ có thể hiển thị thành xanh dương.

#### Cách khắc phục

```

1 import cv2
2 import matplotlib.pyplot as plt
3
4 img = cv2.imread("ten_anh.png")
5
6 # Cách 1: Dao thu cong (chi dinh thu tu kenh)
7 img_rgb = img[:, :, [2, 1, 0]]

```

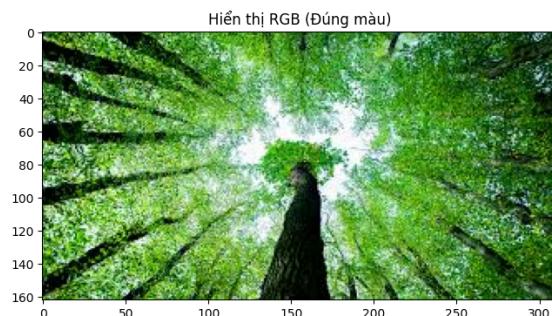
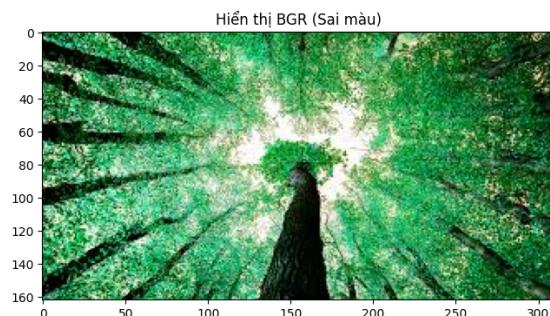
```

8
9 # Cách 2: Sử dụng slicing ngắn gọn
10 img_rgb = img[:, :, ::-1]
11
12 # Cách 3: Dùng hàm chuyển đổi chuẩn nhất
13 img_rgb = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)
14
15 plt.imshow(img_rgb)
16 plt.show()

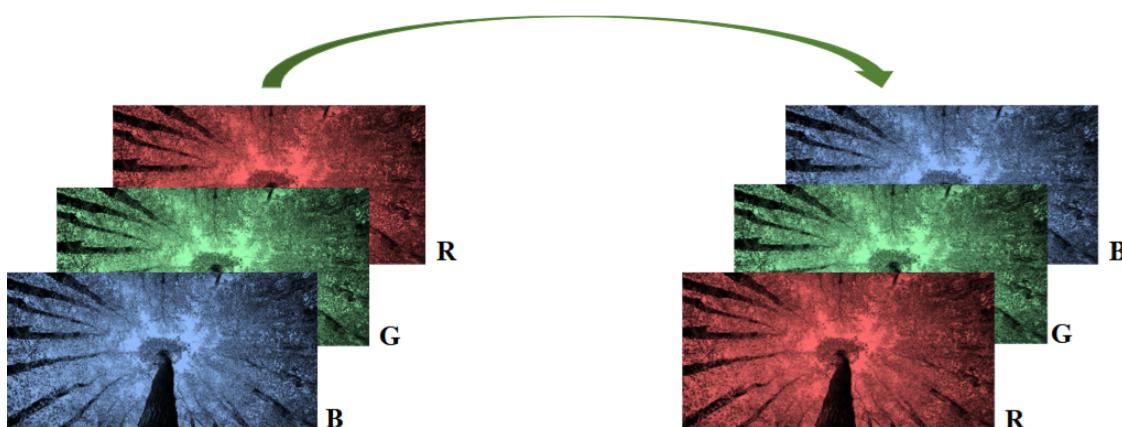
```

**Giải thích:**

- Hai cách đầu tiên thực chất chỉ tráo đổi thứ tự kênh.
- Cách 3 được khuyến nghị vì rõ ràng và an toàn hơn trong các xử lý phức tạp.



Trái: Ảnh gốc đọc bằng OpenCV (BGR) – hiển thị sai màu trong Matplotlib  
Phải: Sau khi chuyển đổi BGR → RGB – màu sắc hiển thị đúng



Minh họa quá trình hoán đổi kênh: BGR  $\Rightarrow$  RGB

## 1.5. Tải và lưu ảnh (Load & Save)

### 1) Khái niệm

Trong OpenCV, việc tải và lưu ảnh được thực hiện thông qua 2 hàm chính:

- `cv2.imread(path, flag)`: Tải ảnh từ tệp với chế độ đọc được chỉ định.
- `cv2.imwrite(path, image)`: Lưu ảnh vào tệp theo định dạng mong muốn (PNG, JPG...).

Hàm này hỗ trợ cả ảnh màu và ảnh mức xám.

## 2) Cú pháp tải ảnh

```

1 import cv2
2
3 # Doc anh muc xam (Grayscale)
4 img_gray = cv2.imread("ten_anh.png", 0)
5
6 # Doc anh mau (Color)
7 img_color = cv2.imread("ten_anh.png", 1)

```

Giải thích tham số flag:

Giá trị	Ý nghĩa
0	Đọc ảnh mức xám – chỉ 1 kênh, mỗi pixel có giá trị 0–255.
1 (mặc định)	Đọc ảnh màu BGR – 3 kênh (Blue, Green, Red).
-1	Đọc đầy đủ (bao gồm kênh alpha nếu có).

## 3) Cú pháp lưu ảnh

```

1 # Luu anh muc xam
2 cv2.imwrite("gray_luu.png", img_gray)
3
4 # Luu anh mau
5 cv2.imwrite("color_luu.png", img_color)

```

Lưu ý: Ảnh sẽ được lưu ở định dạng được chỉ định qua phần mở rộng tên tệp (.png, .jpg, .bmp,...). OpenCV tự động chuyển đổi dữ liệu ảnh sang định dạng phù hợp.

## 4) Kiểm tra kích thước ảnh

```

1 print(img_gray.shape)    # (H, W) - Anh muc xam
2 print(img_color.shape)  # (H, W, 3) - Anh mau (3 kenh B, G, R)

```

Giải thích:

- **(H, W)**: chiều cao và chiều rộng ảnh mức xám.
- **(H, W, 3)**: ảnh màu có 3 kênh (B, G, R).

## 5) Ví dụ minh họa

### a) Ảnh mức xám

```
1 import cv2
2
3 # Doc va luu anh muc xam
4 img = cv2.imread("nature.jpg", 0)
5 cv2.imwrite("processed_image_gray.jpg",
6             img)
7
8 # Kiem tra kich thuoc
9 print("Gray image shape:", img.shape)
```

```
===== Output =====
Gray image shape: (500, 1200)
```



Ảnh mức xám: Kích thước (Height, Width)

### b) Ảnh màu

```
1 import cv2
2
3 # Doc va luu anh mau
4 img = cv2.imread("nature.jpg", 1)
5 cv2.imwrite("processed_image_color.jpg",
6             img)
7
8 # Kiem tra kich thuoc
9 print("Color image shape:", img.shape)
```

```
===== Output =====
Color image shape: (500, 1200, 3)
```



Ảnh màu: Kích thước (Height, Width, Channel)

## 2. Thay đổi độ sáng ảnh – Brightness Changes

Việc điều chỉnh độ sáng là thao tác cơ bản nhưng rất quan trọng trong xử lý ảnh. Nó thường được dùng trong:

- **Tiền xử lý dữ liệu** cho các bài toán Thị giác máy tính.
- **Cải thiện chất lượng hình ảnh**, làm rõ chi tiết trước khi trích xuất đặc trưng.
- **Tạo hiệu ứng thẩm mỹ** trong chỉnh sửa ảnh.

### 2.1. Kiểu dữ liệu của ảnh (Data type)

Trong NumPy, ảnh số (**grayscale** hoặc **color**) được lưu trữ dưới dạng **ma trận 2D hoặc 3D** với kiểu dữ liệu (**dtype**) đặc trưng. Kiểu được sử dụng phổ biến nhất là **np.uint8**.

#### Giải thích chi tiết về np.uint8

- **u – Unsigned:** chỉ chứa giá trị dương, không có số âm.
- **int – Integer:** mọi giá trị đều là số nguyên (không có số thập phân).
- **8 – 8-bit:** mỗi pixel được lưu bằng 8 bit (1 byte), tức là có thể biểu diễn  $2^8 = 256$  giá trị rời rạc trong khoảng  $[0, 255]$ :

$$0 \leq A \leq 255$$

#### Ý nghĩa giá trị pixel:

- $0 \rightarrow$  Đen hoàn toàn.
- $255 \rightarrow$  Trắng hoàn toàn.
- Các giá trị ở giữa  $\rightarrow$  Các mức xám (đối với ảnh mức xám) hoặc cường độ màu trong từng kênh (đối với ảnh màu).

Nhắc lại cấu trúc lưu trữ ảnh:

- **Ảnh mức xám (grayscale):** ma trận 2D có kích thước  $(H, W)$ .
- **Ảnh màu (RGB hoặc BGR):** ma trận 3D có kích thước  $(H, W, 3)$ , với 3 kênh màu.

#### Ví dụ minh họa

```

1 import numpy as np
=====
2
3 # Tao mot anh grayscale 2x2
4 img = np.array([[100, 150],
5                 [200, 250]], dtype=np.
6                 uint8)
7
8 print("Kieu du lieu:", img.dtype)
9 print("Kich thuoc:", img.shape)
===== Output =====
Kieu du lieu: uint8
Kich thuoc: (2, 2)

```

Ảnh này tương đương với 4 pixel:

$$\begin{bmatrix} 100 & 150 \\ 200 & 250 \end{bmatrix}$$

### Ép kiểu dữ liệu trong NumPy

Trong nhiều trường hợp, ta cần **chuyển đổi kiểu dữ liệu** (ví dụ: từ float sang uint8 hoặc ngược lại) để phù hợp với các thao tác xử lý.

```
1 img_float = img.astype(np.float64)      # Ép sang float để tranh tranh so
2 img_uint8 = img_float.astype(np.uint8)    # Ép nguoc lai sau khi xu
```

## 2.2. Vấn đề vượt ngưỡng (Out of Range / Overflow)

Trong xử lý ảnh bằng NumPy, do ảnh thường được lưu dưới dạng **uint8** (giá trị pixel nằm trong [0, 255]), nên các phép cộng/trừ vượt giới hạn này sẽ gây ra hiện tượng **tràn số (overflow)**.

### Cơ chế hoạt động

- Khi một phép toán vượt ngưỡng, **NumPy không báo lỗi**.
- Thay vào đó, giá trị sẽ **quay vòng như đồng hồ** (theo modulo 256):

$$\text{giá trị mới} = (\text{giá trị cũ} + \text{thay đổi}) \bmod 256$$

- Điều này khác với cách chúng ta nghĩ (khi mong đợi giá trị bị chặn ở mức 0 hoặc 255).

### Ví dụ 1: Ép kiểu từ float sang uint8

```
1 import numpy as np
2
3 data = np.array([1, 2.5])
4 print("Truoc khi ép kieu:", data.dtype,
      data)
5
6 data = data.astype(np.uint8)
7 print("Sau khi ép kieu:", data.dtype,
      data)
```

===== Output =====

```
Truoc khi ép kieu: float64 [1. 2.5]
Sau khi ép kieu: uint8 [1 2]
```

**Giải thích:** Khi ép kiểu sang uint8, phần thập phân bị cắt bỏ (**floor**), không làm tròn.

## Ví dụ 2: Tràn số khi cộng / trừ

```

1 import numpy as np
2
3 val1 = np.uint8(250) + 10
4 val2 = np.uint8(5) - 10
5
6 print(val1)
7 print(val2)

```

```

=====
Output =====
4
251

```

### Giải thích:

- $250 + 10 = 260$ , nhưng  $260 \bmod 256 = 4$ .
- $5 - 10 = -5$ , nhưng trong `uint8`:  $-5 \bmod 256 = 251$ .

### Minh họa trực quan

Bình thường, chúng ta thường **nghĩ đơn giản** rằng:

- Nếu giá trị vượt quá 255  $\Rightarrow$  tự động bị chặn ở 255.
- Nếu giá trị nhỏ hơn 0  $\Rightarrow$  tự động bị chặn ở 0.



**Chúng ta thường nghĩ:** Giá trị chỉ chạy trong khoảng  $0 \rightarrow 255$  và bị chặn lại.

Tuy nhiên, **NumPy không hoạt động như vậy!** Với ảnh dạng `uint8`, mọi phép toán được thực hiện theo cơ chế:

$$\text{giá trị mới} = (\text{giá trị cũ} + \text{thay đổi}) \bmod 256$$

Điều này có nghĩa là:

- $250 + 10 \rightarrow 260 \bmod 256 = 4$
- $5 - 10 \rightarrow -5 \bmod 256 = 251$



**Thực tế trong NumPy:** Giá trị chạy vòng như đồng hồ — sau 255 quay lại 0.

Do đó, **mọi thao tác thay đổi độ sáng ảnh (brightness changes)** đều cần xử lý an toàn bằng cách:

- Ép kiểu sang `float` hoặc `int16` trước khi cộng/trừ.
- Dùng `np.clip()` hoặc `np.where()` để đảm bảo giá trị nằm trong  $[0, 255]$ .

### 2.3. Hàm `clip()` và `where()` trong NumPy

Trong xử lý ảnh (đặc biệt khi thay đổi độ sáng), việc tránh **tràn số (overflow)** là bắt buộc. NumPy cung cấp hai công cụ hữu ích:

#### 1) Hàm `np.clip(): Giữ giá trị trong khoảng an toàn`

**Chức năng:** Ép mọi phần tử của mảng về một khoảng  $[a_{\min}, a_{\max}]$ :

- Nếu phần tử  $< a_{\min}$ : bị gán bằng  $a_{\min}$ .
- Nếu phần tử  $> a_{\max}$ : bị gán bằng  $a_{\max}$ .
- Ngược lại: giữ nguyên.

**Ví dụ minh họa:**

```

1 import numpy as np
2
3 data = np.array([1, 2, 3, 4, 5, 6, 7, 8])
4
5 # element < 3 se gan bang 3
6 # element > 6 se gan bang 6
7 result = np.clip(data, a_min=3, a_max=6)
8 print("data:", data)
9 print("result:", result)

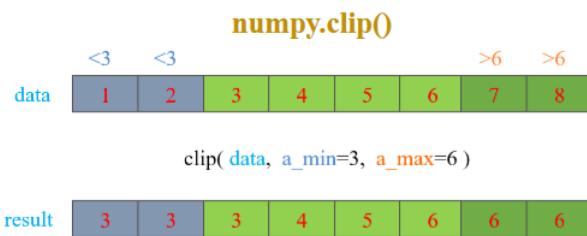
```

===== Output =====

```

data: [1 2 3 4 5 6 7 8]
result: [3 3 3 4 5 6 6 6]

```



Hình 4: Minh họa cách hoạt động của `np.clip()`

**Ứng dụng trong ảnh:** Khi tăng sáng, mọi pixel được chặn lại ở giá trị tối đa 255, tránh vượt ngưỡng gây tràn số.

#### 2) Hàm `np.where(): Thay thế có điều kiện`

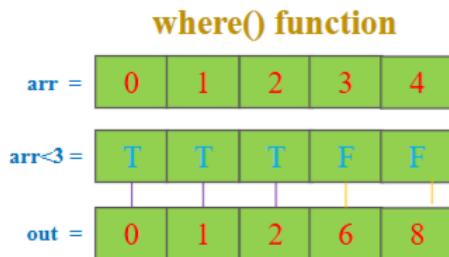
**Chức năng:** Thay thế giá trị trong mảng theo một điều kiện logic. Cú pháp:

```
np.where(condition, value_if_True, value_if_False)
```

Ví dụ minh họa:

```
1 import numpy as np
2
3 arr = np.arange(5)
4 print("arr:", arr)
5
6 # Điều kiện: phần tử < 3 giữ nguyên,
7 # ngược lại nhân đôi
8 condition = arr < 3
9 out = np.where(condition, arr, arr * 2)
10 print("condition:", condition)
11 print("out:", out)
```

```
=====
Output =====
arr: [0 1 2 3 4]
condition: [ True  True  True False False]
out: [0 1 2 6 8]
```



Hình 5: Minh họa cách hoạt động của np.where()

Ứng dụng trong ảnh:

- Chỉ làm sáng những pixel tối hơn một ngưỡng cho trước.
- Điều chỉnh linh hoạt từng vùng ảnh, không áp dụng toàn bộ như clip().

So sánh nhanh

So sánh clip() và where()

Tiêu chí	np.clip()	np.where()
<b>Tác dụng</b>	Giữ giá trị trong khoảng cố định	Thay thế giá trị có điều kiện
<b>Tính linh hoạt</b>	Thấp (áp dụng toàn bộ mảng)	Cao (điều chỉnh từng vùng riêng lẻ)
<b>Dễ sử dụng</b>	Rất dễ	Cần viết thêm điều kiện

## 2.4. Tăng và giảm độ sáng ảnh (Brightness Adjustment)

Trong xử lý ảnh, việc làm sáng hoặc làm tối là thao tác cực kỳ phổ biến, ví dụ: tăng sáng ảnh chân dung, xử lý ảnh y tế hoặc cải thiện chất lượng dữ liệu huấn luyện AI.

### 1) Ý tưởng cơ bản

Mỗi pixel là một giá trị số trong khoảng [0, 255] (đối với ảnh 8-bit). Việc tăng/giảm sáng chỉ đơn giản là cộng hoặc trừ một giá trị  $v$  cho mỗi pixel:

$$I_{\text{new}} = I_{\text{old}} + v \quad (\text{tăng sáng})$$

$$I_{\text{new}} = I_{\text{old}} - v \quad (\text{giảm sáng})$$

### 2) Vì sao ảnh bị lỗi màu?

Khi cộng trực tiếp vào ảnh màu dạng `uint8`, giá trị vượt ngưỡng sẽ quay vòng → gây sai màu nghiêm trọng.

```

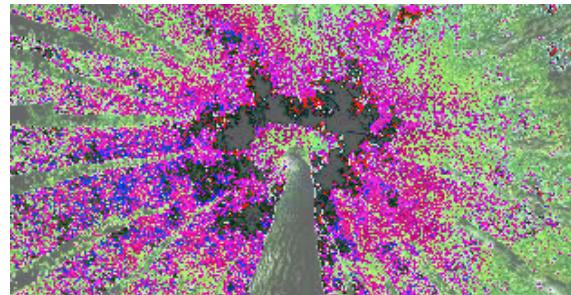
1 import cv2
2
3 image = cv2.imread('image1.png', 1)
4 image = image + 100
5
6 cv2.imwrite('output1.png', image)

```

**Kết quả:** Ảnh xuất hiện nhiều chấm tím, xanh loang lổ do tràn số (overflow) làm sai lệch kênh màu (xem hình dưới).



a) Ảnh gốc



b) Ảnh bị lỗi màu

### 3) Cách xử lý an toàn

**Mục tiêu:** Giữ mọi giá trị trong khoảng hợp lệ [0, 255].

Có 3 cách phổ biến:

**Cách 1: Ép kiểu sang float hoặc int16 rồi dùng clip()**

```

1 import cv2
2 import numpy as np
3
4 image = cv2.imread('image1.png', 1)
5 image = image.astype(float)
6

```

```

7 image = image + 100
8 image = np.clip(image, 0, 255)
9 image = image.astype(np.uint8)
10
11 cv2.imwrite('output_safe1.png', image)

```



a) Ảnh ban đầu



b) Ảnh sau khi xử lý

### Nhận xét:

- Ảnh sau khi tăng/giảm sáng **rất mượt, không bị lỗi màu hay chấm tím**.
- Các vùng sáng gần giá trị 255 sẽ được giữ nguyên (255), không quay vòng về 0.
- *Ảnh trông tự nhiên hơn.*

### Ưu điểm

- Đơn giản, dễ triển khai (chỉ cần ép kiểu + `clip`).
- Đảm bảo tuyệt đối không tràn số.
- Phù hợp cho mọi loại ảnh (grayscale hoặc màu).

### Nhược điểm

- Cần thêm bước ép kiểu sang `float` hoặc `int16`, sau đó ép lại về `uint8`.
- Tốn RAM hơn nếu ảnh rất lớn (vì `float` chiếm 4–8 byte/pixel thay vì 1 byte như `uint8`).

### Cách 2: Dùng `np.where()`

```

1 import cv2
2 import numpy as np
3
4 image = cv2.imread('/content/image1.png', 1)
5 image = image.astype(float)
6 image = np.where(image + 100 > 255, 255, image + 100)
7 image = image.astype(np.uint8)
8
9 cv2.imwrite('output_safe2.png', image)

```



a) Ảnh ban đầu



b) Ảnh sau khi xử lý

### Nhận xét:

- Ảnh sáng lên hoặc tối đi **an toàn như cách 1**, không lỗi màu.
- Thêm nữa, ta có thể tùy chỉnh từng vùng (ví dụ: chỉ tăng sáng các vùng tối hơn 100), nên kết quả có thể được tối ưu cho từng kịch bản.

#### Ưu điểm

- Linh hoạt, dễ tùy chỉnh từng vùng ảnh bằng cách thay đổi điều kiện trong `np.where()`.
- Nhanh và gọn, vì `np.where()` được tối ưu vector hóa.

#### Nhược điểm

- Cần viết điều kiện cẩn thận, nếu sai điều kiện dễ ra kết quả không mong muốn.
- Vẫn cần ép kiểu tạm thời (`astype(float)` hoặc `astype(int16)`) nếu cộng trừ giá trị lớn.

## 2.5. Cách làm ngây thơ (Naive Solution)

Một lỗi cực kỳ phổ biến khi tăng/giảm độ sáng ảnh là **thao tác trực tiếp trên ảnh dạng uint8 mà không xử lý tràn số**.

### 1) Vấn đề

- **Khi cộng trực tiếp:** Giá trị vượt quá 255 sẽ bị **quay vòng (overflow)** theo quy tắc đồng hồ.
- **Ví dụ:**

```

1 import numpy as np
2
3 img = np.array([[200]], dtype=np.uint8)
4 img = img + 100
5 print(img)

```

```
===== Output =====
[[44]] # 200 + 100 = 44 do bị tran (mod
256)
```

### Giải thích:

- $200 + 100 = 300$  nhưng `uint8` chỉ lưu được từ 0 đến 255.
- NumPy sẽ tự động lấy  $300 \bmod 256 = 44$ , dẫn tới kết quả sai.

## 2) Hậu quả thực tế

Ví dụ với ảnh màu:

```

1 import cv2
2 import numpy as np
3
4 # Read image
5 image = cv2.imread('image1.png', 1)
6
7 # Tang sang truc tiep (sai lam)
8 image = image + 100
9
10 cv2.imwrite('output_naive.png', image)

```

**Kết quả:** Ảnh xuất hiện các đốm màu tím, hồng hoặc xanh lá không tự nhiên do **tràn số ở các kênh màu BGR**.

### Ghi nhớ

- Cách làm này nhanh nhưng **không bao giờ nên dùng cho xử lý ảnh thực tế**.
- Cần phải có các phương pháp **an toàn hơn** (như `clip()` hoặc `np.where()`) để tránh lỗi tràn số.

## 3) Tổng kết

Phương pháp	Ưu điểm	Nhược điểm
Ép sang float + clip	Dễ viết, an toàn tuyệt đối	Tốn bộ nhớ do float
<code>np.where</code>	Linh hoạt, áp dụng điều kiện	Cần viết logic cẩn thận
Naive ( <code>uint8</code> )	Nhanh nhất	Dễ tràn số, không chính xác

## 3. Contrast Change – Điều chỉnh độ tương phản ảnh bằng NumPy

Sau khi đã hiểu cách **làm sáng hoặc làm tối ảnh (Brightness Changes)** bằng cách cộng/trừ một giá trị  $v$  cho toàn bộ pixel, ta có thể điều khiển mức độ sáng tối tổng thể của ảnh.

Tuy nhiên, chỉ thay đổi độ sáng thôi là chưa đủ nếu mục tiêu của chúng ta là:

- Làm nổi bật các chi tiết trong vùng sáng và vùng tối.
- Tăng độ sắc nét, rõ ràng của đối tượng trong ảnh.
- Hoặc làm mềm ảnh để giảm nhiễu.

Lúc này, ta cần thao tác trên **độ tương phản (Contrast)** — tức là khoảng chênh lệch **độ sáng giữa các vùng trong ảnh**.

## Ý tưởng chính:

- Brightness = Dịch chuyển toàn bộ pixel lên hoặc xuống cùng một lượng.
- Contrast = Kéo giãn hoặc thu hẹp khoảng cách giữa các giá trị pixel quanh một mức tham chiếu.

Trong các phần tiếp theo, ta sẽ lần lượt tìm hiểu:

1. Khái niệm độ tương phản trong ảnh số.
2. Vấn đề thường gặp khi thay đổi độ tương phản (như mất chi tiết, tràn số).
3. Các cách điều chỉnh tương phản an toàn và trực quan bằng NumPy.

### 3.1. Contrast (Độ tương phản) trong ảnh số là gì?

Trong xử lý ảnh, **Contrast (Độ tương phản)** thể hiện mức độ chênh lệch giữa vùng sáng và vùng tối trong ảnh:

- **Brightness (Độ sáng):** Dịch chuyển toàn bộ giá trị pixel lên cao hơn hoặc thấp hơn cùng một lượng. *Ví dụ:* Mọi pixel đều được cộng thêm 50  $\Rightarrow$  ảnh sáng hơn, nhưng khoảng cách giữa các pixel gần như không đổi.
- **Contrast (Độ tương phản):** Thay đổi khoảng cách giữa các giá trị pixel, làm cho:
  - **Phần sáng càng sáng hơn** (pixel sáng bị đẩy gần về 255).
  - **Phần tối càng tối hơn** (pixel tối bị kéo gần về 0).

#### Tại sao quan trọng?

- Ảnh có **độ tương phản cao**  $\Rightarrow$  chi tiết nổi bật, dễ phân biệt các vùng.
- Ảnh có **độ tương phản thấp**  $\Rightarrow$  nhìn “xám xịt”, mờ nhạt, khó nhận ra ranh giới giữa các vùng.

#### Minh họa trực quan:



a) Ảnh tương phản thấp  
(xám xịt, mờ nhạt)



b) Ảnh tương phản trung bình  
(bình thường)



c) Ảnh tương phản cao  
(sắc nét, chi tiết rõ ràng)

### So sánh Brightness và Contrast:

Brightness vs Contrast		
	Brightness	Contrast
Ý nghĩa	Thay đổi tổng thể độ sáng ảnh	Tăng hoặc giảm khoảng cách giữa vùng sáng và vùng tối
Tác động	Toàn bộ pixel dịch chuyển đều nhau	Pixel sáng càng sáng, pixel tối càng tối
Mục đích	Làm ảnh sáng hoặc tối hơn	Làm nổi bật chi tiết, tăng độ sắc nét

### 3.2. Công thức điều chỉnh độ tương phản (Contrast Adjustment)

Trong xử lý ảnh số, **độ tương phản** thể hiện sự chênh lệch giữa các vùng sáng và vùng tối. Với ảnh grayscale (mức xám từ 0 đến 255), ta thường sử dụng công thức tuyến tính sau để điều chỉnh tương phản:

$$I' = \alpha \cdot (I - 128) + 128$$

#### 1) Giải thích từng thành phần

- **$I$  – Ảnh gốc:** Ma trận giá trị pixel ban đầu, mỗi phần tử có giá trị từ 0 đến 255. Giá trị nhỏ hơn 128 là vùng tối, lớn hơn 128 là vùng sáng.
- **128 – Mức xám trung tính:** 128 là giá trị trung tâm của dải mức xám 8-bit (0–255). Khi ta trừ đi 128 ( $I - 128$ ), ảnh được “dịch” về quanh mức 0:

$$I - 128 = \begin{cases} \text{số âm} & \text{nếu } I < 128 \text{ (pixel tối)} \\ 0 & \text{nếu } I = 128 \text{ (trung tính)} \\ \text{số dương} & \text{nếu } I > 128 \text{ (pixel sáng)} \end{cases}$$

#### • $\alpha$ – Hệ số tương phản:

- $\alpha > 1$  **Tăng tương phản:** Vùng sáng sáng hơn, vùng tối tối hơn (ví dụ:  $\alpha = 1.5$ ).
- $0 < \alpha < 1$  **Giảm tương phản:** Các giá trị bị “nén” về gần 128, ảnh mờ nhạt, xám xịt (ví dụ:  $\alpha = 0.5$ ).
- $\alpha = 1$  Giữ nguyên tương phản.
- **Cộng lại 128:** Sau khi nhân ( $I - 128$ ) với  $\alpha$ , ta cộng lại 128 để dịch các giá trị về đúng dải mức xám gốc.

## 2) Ý nghĩa công thức

$$\text{Pixel tối: } I < 128 \implies I' = \alpha \cdot (\text{số âm}) + 128 \Rightarrow \begin{cases} \text{nhỏ hơn (tối hơn)} & \alpha > 1 \\ \text{lớn hơn (sáng hơn, xám hơn)} & \alpha < 1 \end{cases}$$

$$\text{Pixel sáng: } I > 128 \implies I' = \alpha \cdot (\text{số dương}) + 128 \Rightarrow \begin{cases} \text{lớn hơn (sáng hơn)} & \alpha > 1 \\ \text{nhỏ hơn (tối hơn, xám hơn)} & \alpha < 1 \end{cases}$$

## 3) Ví dụ

- $\alpha = 1.5$  (**tăng tương phản**): Vùng trời sáng hơn, chi tiết mây tối hơn  $\Rightarrow$  ảnh sắc nét, nổi bật.
- $\alpha = 0.5$  (**giảm tương phản**): Các vùng sáng và tối đều bị nén về gần 128  $\Rightarrow$  ảnh mờ nhạt, mất chi tiết.

Code:

```

1 import numpy as np
2
3 def change_contrast(img, alpha):
4     """
5         Adjust contrast of a grayscale image using contrast factor alpha.
6
7     Parameters:
8         img    : ndarray (uint8) - input grayscale image
9         alpha : float - contrast factor (>1: increase, <1: decrease)
10
11    Returns:
12        Adjusted image (uint8)
13    """
14    img = img.astype(np.float32)
15    img = alpha * (img - 128) + 128
16    img = np.clip(img, 0, 255)
17    return img.astype(np.uint8)

```

### 3.3. Vấn đề thường gặp khi thay đổi độ tương phản

Điều chỉnh độ tương phản giúp ảnh sắc nét hơn, nhưng nếu thao tác không đúng cách, ta rất dễ gặp các vấn đề sau:

#### 1) Mất chi tiết (Loss of Details)

- Khi tăng tương phản quá mạnh ( $\alpha \gg 1$ ):
  - Các **vùng sáng** dễ bị **cháy sáng** (pixel vượt 255 bị ép về 255).
  - Các **vùng tối** dễ bị **đen đặc** (pixel nhỏ hơn 0 bị ép về 0).
- Kết quả:

- Ảnh nhìn thì sắc nét, nhưng các chi tiết tinh tế (như bóng mờ, hoa văn nhỏ) bị mất hoàn toàn.
- Các vùng ảnh trông như bị “bệt màu” hoặc “cháy sáng”.

**Minh họa:**



a) Tăng tương phản vừa đủ  
(chi tiết nổi bật, tự nhiên)



b) Tăng tương phản quá mức  
(cháy sáng, mất chi tiết vùng tối)

## 2) Tràn số (Overflow) trong tính toán

**Nguyên nhân:** Ảnh thường được lưu ở định dạng `uint8` (giá trị từ 0–255). Khi thay đổi độ tương phản theo công thức:

$$I' = \alpha \cdot (I - 128) + 128$$

Nếu không ép kiểu đúng cách:

- Giá trị vượt quá 255 sẽ bị **quay vòng** theo quy tắc **mod 256** (giống đồng hồ).
- Ví dụ: `np.uint8(200) * 2 = 144` thay vì 400.

**Ví dụ minh họa:**

```

1 import numpy as np
2
3 I = np.array([50, 200], dtype=np.uint8)
4 I_high_contrast = I * 2 # Tang tuong
    phan (sai cach)
5 print(I_high_contrast)

```

```
=====
Output =====
[100 144] # Dang le phai la [100 400] (
    sau do clip ve 255)
```

**Cách khắc phục:**

- Ép kiểu sang `float` hoặc `int16` trước khi tính toán.
- Dùng `np.clip()` để đảm bảo giá trị nằm trong khoảng [0,255].

Ví dụ (an toàn):

```

1 I = np.array([50, 200], dtype=np.uint8)
2 I_safe = I.astype(float)
3 I_safe = I_safe * 2
4 I_safe = np.clip(I_safe, 0, 255).astype(
    np.uint8)
5 print(I_safe)

```

```
===== Output =====
[100 255]
```

### Ghi chú

- **Không bao giờ** thao tác trực tiếp trên `uint8` nếu có nhân chia hoặc nhân hệ số  $\alpha$ .
- Tăng tương phản quá mạnh dễ làm mất chi tiết vùng sáng và vùng tối.
- Luôn:
  1. Ép kiểu sang `float` hoặc `int16`.
  2. Dùng `clip()` để giới hạn giá trị trong [0,255].
  3. Chọn  $\alpha$  vừa đủ để giữ lại chi tiết tự nhiên.

### 3.4. Các cách điều chỉnh tương phản an toàn và trực quan bằng NumPy

Thay đổi độ tương phản trong ảnh tương đối đơn giản nhưng nếu không xử lý cẩn thận, ảnh có thể bị:

- **Cháy sáng** (sáng quá mức, vùng trắng toát, mất chi tiết).
- **Đen đặc** (tối quá mức, vùng tối bị bệt, mất thông tin).
- **Tràn số** khi làm việc với ảnh `uint8`.

Do đó, ta cần các phương pháp an toàn, đảm bảo giá trị pixel luôn nằm trong khoảng hợp lệ [0,255].

Công thức chung (Linear Contrast Stretching):

$$I' = \alpha \cdot (I - 128) + 128$$

- $I$ : Ảnh gốc.
- $\alpha$ : Hệ số tương phản.
  - $\alpha > 1 \Rightarrow$  Tăng tương phản (sáng sáng hơn, tối tối hơn).
  - $\alpha < 1 \Rightarrow$  Giảm tương phản (ảnh xám xịt, mờ nhạt).
- 128: Mức xám trung tính (trung tâm khoảng 0–255).

Cách 1: Ép kiểu + `clip()` (An toàn nhất)

```

1 import cv2
2 import numpy as np
3
4 def adjust_contrast_clip(img, alpha=1.5):
5     img = img.astype(float)           # Ep kieu tranh tran so
6     new_img = alpha * (img - 128) + 128    # Cong thuc tang tuong phan
7     return np.clip(new_img, 0, 255).astype(np.uint8)
8
9 image = cv2.imread("image1.png", 0)
10 contrast_img = adjust_contrast_clip(image, alpha=1.5)
11 cv2.imwrite("contrast_clip.png", contrast_img)

```



Ảnh sau khi xử lý, dùng np.clip()

#### Nhận xét:

- Ảnh sau khi tăng/giảm sáng **mượt, tự nhiên**, không lỗi màu.
- Các vùng sáng gần 255 được giữ nguyên, không quay vòng về 0.

#### Ưu điểm

- Dễ triển khai, an toàn tuyệt đối.
- Phù hợp cho mọi loại ảnh (grayscale hoặc màu).

#### Nhược điểm

- Cần ép kiểu tạm thời (float hoặc int16).
- Tốn RAM hơn nếu ảnh lớn.

#### Cách 2: Dùng np.where() (Linh hoạt, có điều kiện)

```

1 import cv2
2 import numpy as np
3
4 def adjust_contrast_where(img, alpha=1.5, threshold=200):
5     img = img.astype(float)

```

```

6     new_img = alpha * (img - 128) + 128
7     # Chi tăng tương phản cho vùng có giá trị < threshold
8     new_img = np.where(img < threshold, new_img, img)
9     return np.clip(new_img, 0, 255).astype(np.uint8)
10
11 image = cv2.imread("image1.png", 0)
12 contrast_img_where = adjust_contrast_where(image, alpha=1.5, threshold=200)
13 cv2.imwrite("contrast_where.png", contrast_img_where)

```



Ảnh sau khi xử lý, dùng np.where()

### Nhận xét:

- Linh hoạt hơn cách 1: chỉ thay đổi các vùng cần thiết, giữ nguyên vùng đã đủ sáng.
- Ảnh trông tự nhiên hơn trong nhiều trường hợp (ví dụ: ảnh phong cảnh, ảnh y tế).

#### Ưu điểm

- Linh hoạt, dễ tùy chỉnh điều kiện.
- Nhanh và gọn, tận dụng vector hóa của NumPy.

#### Nhược điểm

- Cần viết điều kiện cẩn thận, dễ gây kết quả không mong muốn.
- Vẫn phải ép kiểu tạm thời để tránh tràn số.

### Tóm lại:

#### Tóm tắt

Phương pháp	Ưu điểm	Nhược điểm
Ép sang float + clip np.where	An toàn, đơn giản Linh hoạt, có điều kiện	Tốn RAM, cần ép kiểu Cần viết điều kiện cẩn thận

### 3.5. Gợi ý hệ số tương phản thường dùng

Hệ số $\alpha$	Ý nghĩa
0.5	Giảm mạnh tương phản
0.8	Giảm nhẹ tương phản
1.0	Không thay đổi
1.2–1.5	Tăng tương phản nhẹ
2.0	Tăng mạnh tương phản

Qua ba phần: **OpenCV cơ bản**, **Brightness Changes**, và **Contrast Changes**, chúng ta không chỉ dừng lại ở việc thao tác ảnh một cách đơn thuần, mà đã làm quen với những **kỹ thuật tiền xử lý quan trọng trong AI**.

Những thao tác tưởng chừng đơn giản này chính là nền tảng để xây dựng các ứng dụng **Computer Vision** thực tế, từ việc chuẩn bị dữ liệu cho đến cải thiện chất lượng đầu vào của mô hình học sâu.

- Các thao tác này **không chỉ là xử lý ảnh cơ bản**, mà còn:
  - **Tiền xử lý dữ liệu** cho mô hình AI (giảm nhiễu, làm rõ chi tiết).
  - **Tăng cường dữ liệu** (Data Augmentation) để mô hình học tốt hơn trong nhiều điều kiện ánh sáng và chất lượng ảnh khác nhau.
- Thành thạo NumPy + OpenCV là bước đầu tiên để tiến tới:
  - **Trích xuất đặc trưng** (feature extraction).
  - **Huấn luyện mô hình Computer Vision** (CNN, YOLO, ...).

# Phần 8: Mở rộng - Numpy in Image Data-Preprocessing

## 1 Giới thiệu

Trong lĩnh vực thị giác máy tính, dữ liệu đầu vào là ảnh đóng vai trò cực kỳ quan trọng. Ảnh y học (CT/MRI) không giống với ảnh RGB thông thường, mà chứa thông tin vật lý, giá trị đo lường và định dạng thể tích (3 chiều). Nếu không tiền xử lý đúng cách, mô hình học sâu có thể gặp lỗi hội tụ, kết quả sai lệch hoặc không học được đặc trưng hữu ích.(Tham khảo: <https://github.com/fitushar/3D-Medical-Imaging-Preprocessing-All-you-need>)

## 2 Đặc điểm riêng biệt của ảnh y học 3D

- Dữ liệu 3D dạng thể tích (Volume):** mỗi ảnh bao gồm nhiều lát cắt (slice), tạo thành khối voxel.
- Giá trị pixel là vật lý (Hounsfield Unit - HU):** phản ánh mật độ mô, không phải màu sắc như ảnh RGB.
- Kích thước voxel không đồng nhất (spacing khác nhau):** ảnh từ các máy chụp khác nhau có thể có độ phân giải không gian khác nhau.
- Nhiều (noise), artifacts:** do chuyển động, kim loại trong cơ thể, lỗi thiết bị.
- Ảnh lớn, bất đối xứng, vùng quan tâm nhỏ (ROI):** thường cần cắt hoặc đệm để đưa về kích thước chuẩn.

## 3 Đọc ảnh NIfTI và chuyển sang NumPy

```

1 import SimpleITK as sitk
2
3 img_sitk = sitk.ReadImage("img0001.nii.gz", sitk.sitkFloat32)
4 image = sitk.GetArrayFromImage(img_sitk)

```

Ảnh CT thường ở định dạng .nii.gz. SimpleITK giúp đọc ảnh và giữ lại metadata như spacing, origin, direction. Sau đó, ta chuyển sang dạng np.ndarray để dễ xử lý.

## 4 Hounsfield Unit (HU) và lý do cần cắt ngưỡng

Trong ảnh CT, mỗi pixel mang một giá trị đo gọi là Hounsfield Unit (HU). Giá trị này phản ánh mức độ hấp thụ tia X của mô:

- Không khí: -1000 HU
- Mỡ: khoảng -100 đến -50 HU
- Mô mềm: 30–60 HU
- Xương: 400 đến > 1000 HU
- Kim loại: > 2000 HU

Các giá trị này có thể trải dài rất rộng, gây khó khăn cho mạng học sâu nếu không xử lý. Do đó, ta dùng hàm `np.clip` để giới hạn ảnh trong một khoảng HU hợp lý.

### Ví dụ: cắt ngưỡng HU từ -1000 đến 800

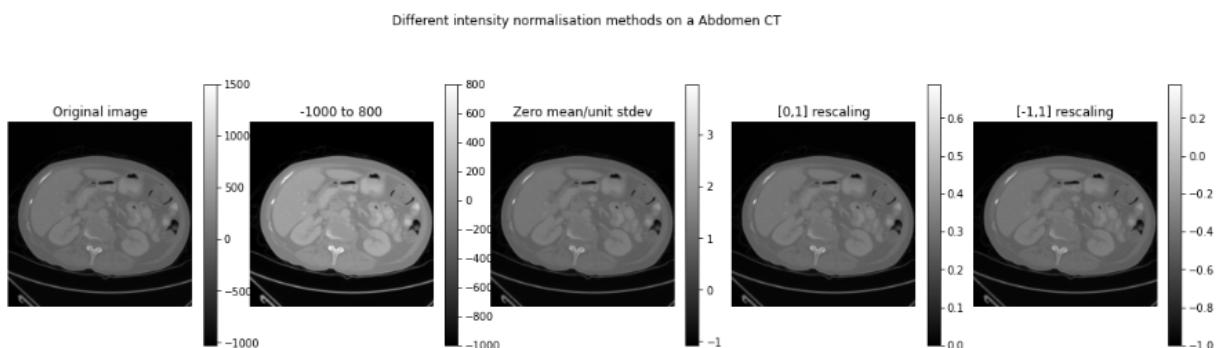
```
1 image = np.clip(image, -1000., 800.).astype(np.float32)
```

Việc cắt ngưỡng giúp loại bỏ các điểm nhiễu (vd: không khí, kim loại) và chỉ giữ lại vùng mô có ý nghĩa lâm sàng. Giá trị cắt có thể thay đổi theo bài toán, ví dụ:

- CT phổi: từ -1000 đến 400 HU
- CT gan: từ -100 đến 250 HU
- CT toàn thân: từ -1000 đến 800 HU

## 5 Chuẩn hoá ảnh

Sau khi cắt ngưỡng, ta cần đưa ảnh về phạm vi giá trị chuẩn để mô hình dễ học.



Hình 1: Ví dụ chuẩn hóa ảnh về từng khoảng

### 1 Chuẩn hoá về khoảng $[0, 1]$ – Min-Max Scaling

```
1 def normalize_zero_one(image):
2     return (image - np.min(image)) / (np.max(image) - np.min(image))
```

#### Lý do sử dụng:

Việc chuẩn hóa ảnh về khoảng  $[0, 1]$  giúp đưa tất cả giá trị pixel về cùng một phạm vi, bất kể ảnh gốc có dải giá trị như thế nào. Cách này đặc biệt quan trọng khi:

- Mô hình sử dụng các hàm kích hoạt như `sigmoid`, vốn có đầu ra nằm trong khoảng  $[0, 1]$ .
- Tránh hiện tượng ảnh quá tối hoặc quá sáng do dải giá trị lớn nhỏ không đồng đều giữa các ảnh.
- Giúp tăng tính nhất quán khi huấn luyện nhiều ảnh từ các nguồn máy chụp khác nhau.

**Ảnh hướng đến gradient:** Nếu không chuẩn hóa, đầu vào quá lớn sẽ gây ra gradient rất nhỏ (vanishing gradient), làm cho mạng học chậm hoặc không học được.

## 2 Chuẩn hoá về khoảng [-1, 1]

```
1 def normalize_one_one(image):
2     return 2.0 * normalize_zero_one(image) - 1.0
```

### Lý do sử dụng:

Khi ta chuẩn hoá ảnh về  $[-1, 1]$ , ta đưa dữ liệu vào trung tâm gốc toạ độ (0), giúp tăng tính đối xứng của phân phối dữ liệu. Điều này rất quan trọng trong các mô hình sử dụng:

- Hàm kích hoạt **tanh**, vốn đầu ra nằm trong khoảng  $[-1, 1]$ .
- Mạng GAN (Generative Adversarial Networks), nơi generator và discriminator thường hoạt động hiệu quả hơn khi input được phân bố xung quanh 0.
- Các bài toán có dữ liệu cân bằng giữa giá trị âm và dương (vd: ảnh đã được cắt ngưỡng HU về  $[-1000, 800]$ ).

**So sánh:** Chuẩn hoá về  $[-1, 1]$  giúp mô hình học được đặc trưng theo cả chiều tăng và giảm của cường độ ảnh, trong khi  $[0, 1]$  chỉ phản ánh độ sáng tương đối.

## 3 Whitening – Chuẩn hoá về Zero Mean, Unit Variance

```
1 def whitening(image):
2     return (image - np.mean(image)) / np.std(image)
```

**Khái niệm:** Đây là dạng chuẩn hoá phổ biến nhất trong học sâu, đưa ảnh về trung bình bằng 0 và độ lệch chuẩn bằng 1.

### Lý do sử dụng:

- Dữ liệu có trung bình quá xa 0 sẽ gây lệch gradient trong quá trình lan truyền ngược (backpropagation).
- Đưa dữ liệu về phân phối chuẩn hoá giúp mạng hội tụ nhanh hơn, đặc biệt với các optimizer như SGD hoặc Adam.
- Tránh hiện tượng "bias" do một số ảnh có độ sáng cao, một số ảnh lại rất tối.
- Được dùng phổ biến trong ResNet, EfficientNet, và hầu hết mô hình SOTA hiện nay.

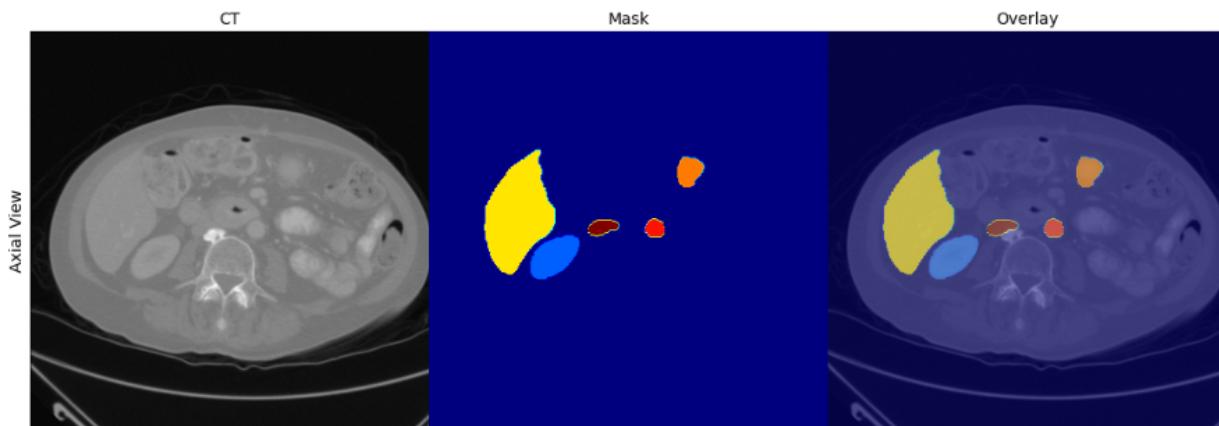
### Lưu ý khi dùng:

- Whitening nên được áp dụng sau khi cắt ngưỡng HU để tránh ảnh hưởng bởi outlier.
- Không áp dụng cho ảnh mask (nhị phân 0/1), vì sẽ mất cấu trúc.

## 6 Resampling ảnh (Chuẩn hoá Spacing Voxel)

Trong ảnh CT hoặc MRI 3D, dữ liệu không chỉ là một ma trận các giá trị, mà còn chứa thông tin về kích thước vật lý của mỗi voxel — gọi là **spacing**.

CT Shape Original=(147, 512, 512), Resampled to 1mm=(441, 342, 342)  
 CT Mask Shape=(147, 512, 512), Resampled to 1mm=(441, 342, 342)



Hình 2: Ví dụ về resampling ảnh

### Spacing là gì?

**Spacing** (hay còn gọi là độ phân giải vật lý) mô tả kích thước thực tế (theo milimet) của mỗi voxel theo ba trục: (`spacing_x`, `spacing_y`, `spacing_z`).

- Một voxel có spacing (0.5, 0.5, 5.0) có nghĩa là:
  - Mỗi pixel trong mặt phẳng  $XY$  có kích thước  $0.5 \times 0.5$  mm
  - Khoảng cách giữa hai lát cắt (slice) theo trục  $Z$  là 5.0 mm
- Một ảnh khác có thể có spacing (1.0, 1.0, 1.0) → voxel là khối lập phương.

**Vấn đề:** Nếu không xử lý, hai ảnh có cùng kích thước số học (vd:  $128 \times 128 \times 64$ ) nhưng spacing khác nhau sẽ có tỷ lệ vật lý khác hoàn toàn — dẫn đến hình dạng cấu trúc giải phẫu bị méo lệch trong mắt mô hình học sâu.

### Ví dụ:

- Cùng là gan, nhưng một ảnh có lát cắt dày 5mm, một ảnh khác dày 1mm → khối gan trong ảnh đầu sẽ “mỏng” hơn trong không gian 3D thật.
- Nếu không resample, mạng CNN 3D có thể học nhầm kích thước và hình dạng thực của mô.

### Giải pháp: Resampling ảnh về spacing chuẩn

Để đồng nhất tỷ lệ vật lý giữa các ảnh, ta cần **nội suy (interpolation)** lại ảnh về cùng một spacing chuẩn — ví dụ: (1.0, 1.0, 1.0) mm hoặc (2.0, 2.0, 2.0) mm.

```

1 def resample_img(itk_image, out_spacing=[2.0, 2.0, 2.0]):
2     original_spacing = itk_image.GetSpacing()
3     original_size = itk_image.GetSize()
4
5     out_size = [
6         int(np.round(original_size[0] * (original_spacing[0] / out_spacing[0]))),
7         int(np.round(original_size[1] * (original_spacing[1] / out_spacing[1]))),

```

```

8     int(np.round(original_size[2] * (original_spacing[2] / out_spacing[2])))
9 ]
10
11 resample = sitk.ResampleImageFilter()
12 resample.SetOutputSpacing(out_spacing)
13 resample.SetSize(out_size)
14 ...
15 return resample.Execute(itk_image)

```

### Ý nghĩa của nội suy lại spacing

- **Đảm bảo đồng bộ vật lý:** Dữ liệu sau nội suy sẽ cùng tỷ lệ voxel, tránh sai lệch về hình học.
- **Tăng tính tổng quát của mô hình:** Mạng học sâu không phải tự điều chỉnh theo từng spacing khác nhau.
- **Tương thích với kiến trúc mạng cố định kích thước (input shape):** ví dụ các mô hình U-Net, DenseVNet cần ảnh đầu vào có kích thước thống nhất.

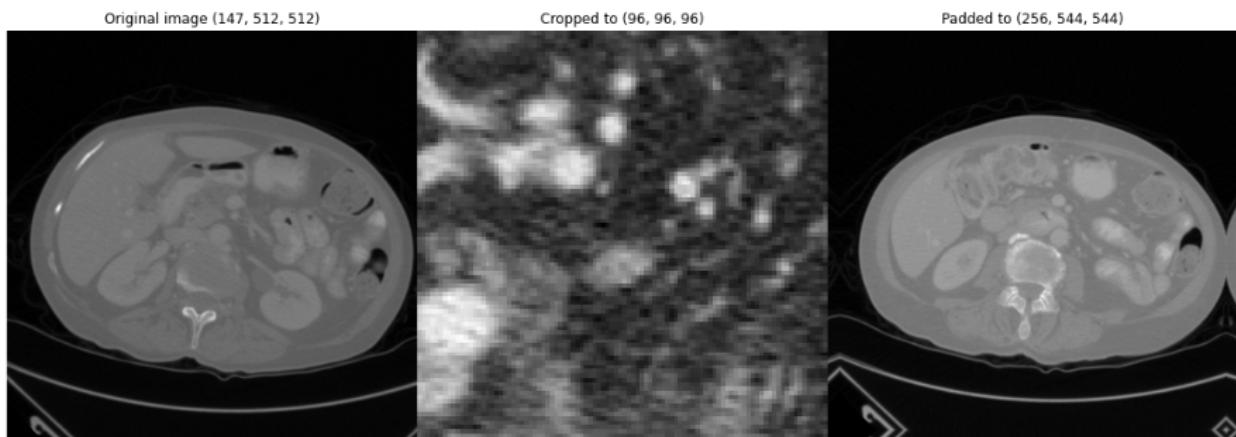
### Chọn spacing bao nhiêu là phù hợp?

- Với ảnh toàn thân hoặc ổ bụng: (2.0, 2.0, 2.0) mm là phổ biến
- Với ảnh não hoặc chi tiết cao: có thể dùng (1.0, 1.0, 1.0) mm hoặc nhỏ hơn
- Spacing nhỏ hơn → độ chi tiết cao hơn → yêu cầu GPU lớn hơn

### Lưu ý:

- `sitkBSpline`: dùng để nội suy ảnh liên tục (CT, MRI).
- `sitkNearestNeighbor`: dùng cho ảnh nhãn (mask segmentation) để tránh mất giá trị nhãn.

## 7 Crop hoặc Pad ảnh về kích thước cố định



Hình 3: Ví dụ về crop và padding ảnh

## Vì sao cần crop/pad ảnh 3D?

Một đặc điểm phổ biến của ảnh y học 3D (CT, MRI) là kích thước không đồng nhất giữa các bệnh nhân:

- **Về kích thước voxel:** ảnh có thể là  $(512 \times 512 \times 50)$  hoặc  $(256 \times 256 \times 200)$
- **Về vùng chụp (FOV - field of view):** có người chụp toàn thân, có người chỉ chụp gan

Tuy nhiên, các mô hình học sâu (như 3D U-Net, VNet) yêu cầu kích thước ảnh **đầu vào cố định** để có thể huấn luyện theo batch hoặc tính toán gradient trên GPU.

Nếu kích thước ảnh thay đổi, mô hình sẽ lỗi ngay từ bước forward hoặc backward do shape không thống nhất.

## Giải pháp: Cắt (Crop) hoặc đệm thêm (Pad)

Ý tưởng là đưa mọi ảnh về cùng kích thước mục tiêu (vd:  $64 \times 64 \times 64$ ):

- Nếu ảnh quá lớn → ta **cắt bớt** phần biên, giữ lại vùng trung tâm chứa ROI (Region of Interest)
- Nếu ảnh quá nhỏ → ta **đệm thêm số 0** (zero-padding) ở các chiều thiêu để đủ kích thước

```

1 def resize_image_with_crop_or_pad(image, img_size=(64, 64, 64), **kwargs):
2     """Image resizing. Resizes image by cropping or padding dimension
3         to fit specified size.
4     Args:
5         image (np.ndarray): image to be resized
6         img_size (list or tuple): new image size
7         kwargs (): additional arguments to be passed to np.pad
8     Returns:
9         np.ndarray: resized image
10    """
11
12    assert isinstance(image, (np.ndarray, np.generic))
13    assert (image.ndim - 1 == len(img_size) or image.ndim == len(img_size)), \
14        'Example size doesnt fit image size'
15
16    # Get the image dimensionality
17    rank = len(img_size)
18
19    # Create placeholders for the new shape
20    from_indices = [[0, image.shape[dim]] for dim in range(rank)]
21    to_padding = [[0, 0] for dim in range(rank)]
22
23    slicer = [slice(None)] * rank
24
25    # For each dimensions find whether it is supposed to be cropped or padded
26    for i in range(rank):
27        if image.shape[i] < img_size[i]:
28            to_padding[i][0] = (img_size[i] - image.shape[i]) // 2
29            to_padding[i][1] = img_size[i] - image.shape[i] - to_padding[i][0]
30        else:
31            from_indices[i][0] = int(np.floor((image.shape[i] - img_size[i]) / 2.))
32            from_indices[i][1] = from_indices[i][0] + img_size[i]
33

```

```

34     # Create slicer object to crop or leave each dimension
35     slicer[i] = slice(from_indices[i][0], from_indices[i][1])
36
37     # Pad the cropped image to extend the missing dimension
38     return np.pad(image[slicer], to_padding, **kwargs)

```

Vì sao cách này hiệu quả?

- **Tập trung vào ROI:** phần lớn thông tin lâm sàng nằm ở trung tâm (gan, phổi, não), nên việc cắt biên không gây mất mát nghiêm trọng.
- **Tăng tốc độ training:** ảnh nhỏ hơn giúp giảm chi phí bộ nhớ và tăng batch size.
- **Tránh lỗi out-of-memory trên GPU:** nếu ảnh lớn quá mà không crop, mô hình dễ bị tràn RAM GPU.
- **Tương thích với DataLoader:** các framework như PyTorch yêu cầu tensor đầu vào có shape đồng nhất.

Một số chiến lược crop/pad phổ biến:

- **Center crop:** cắt từ trung tâm ảnh
- **Random crop:** dùng cho augment, tăng đa dạng dữ liệu
- **Symmetric padding:** đệm đều 2 bên mỗi chiều
- **Asymmetric padding:** tuỳ theo hướng thiều nhiều hay ít

## 8 Maximum Intensity Projection (MIP)

MIP là gì trong thực tế lâm sàng?

**Maximum Intensity Projection (MIP)** là một kỹ thuật dựng ảnh 2D từ ảnh 3D bằng cách chọn giá trị voxel có **cường độ sáng nhất** (intensity lớn nhất) trên mỗi “tia” dọc theo một trục nhất định (thường là trục Z).

Cụ thể:

- Mỗi pixel trong ảnh MIP là giá trị lớn nhất trên cột voxel tương ứng trong không gian 3D.
- Được xem như việc “chiếu tia X ảo” xuyên qua khối 3D và chỉ giữ lại phần “sáng nhất”.

```

1 mip = np.max(image, axis=0) # Chiu theo truc Z

```

### Ứng dụng của MIP trong y học

MIP được sử dụng rộng rãi trong chẩn đoán hình ảnh, đặc biệt trong các trường hợp sau:

- **Chẩn đoán mạch máu (CTA, MRA):** Do lòng mạch được tiêm thuốc cản quang có cường độ rất cao, MIP giúp làm nổi bật cấu trúc mạch máu nhỏ nhất trong khối 3D.
- **Tìm tổn thương có mật độ cao:** như nốt vôi hoá, sỏi, khối u rắn.

- **Hiển thị xương trong CT toàn thân hoặc CT sọ não:** vì xương có HU rất cao ( $> 1000$ ), luôn là điểm sáng nhất trong các lát cắt.
- **Phát hiện di căn xương, vỡ xương, khối u phổi...** qua các lát chiếu toàn vùng.

### Tính chất đặc biệt của ảnh CT/MRI khiếu MIP hữu ích

Ảnh CT/MRI 3D có các đặc điểm:

- **Cấu trúc lồng ghép theo chiều sâu:** Có nhiều mô khác nhau nằm chồng lên nhau trong không gian 3D, khó thấy bằng lát cắt đơn lẻ.
- **ROI nhỏ và mờ:** Tổn thương cần phát hiện thường rất nhỏ và dễ bị bỏ sót trong một lát cắt đơn.
- **Cường độ không đều:** Một số cấu trúc sáng rõ, nhưng cũng có thể bị che khuất nếu xem từng lát.

MIP giúp “tổng hợp” toàn bộ các cấu trúc sáng nhất, làm nổi bật vùng nghi ngờ mà bác sĩ (hoặc mô hình AI) cần chú ý.

### MIP giúp mô hình học sâu như thế nào?

Mặc dù ảnh 3D chứa nhiều thông tin hơn, nhưng có những lý do khiến ta dùng MIP trong mô hình học sâu:

- **Chuyển ảnh 3D thành 2D:** giúp tận dụng các mô hình 2D CNN mạnh mẽ (như ResNet, EfficientNet) mà không cần kiến trúc 3D phức tạp.
- **Tiết kiệm tài nguyên:** mô hình 2D có ít tham số hơn, dễ huấn luyện và phù hợp hơn với máy tính có GPU hạn chế.
- **Tăng độ tương phản vùng ROI:** vì MIP loại bỏ các voxel tối, giúp mô hình tập trung học đặc trưng nổi bật nhất.
- **Tăng tính khái quát hoá (generalization):** mô hình học đặc trưng theo toàn vùng chiếu, thay vì học lệch theo lát cắt cụ thể.
- **Phù hợp với học tự giám sát (self-supervised):** ví dụ dùng MIP làm augment hoặc target trong pretext tasks.

### So sánh với ảnh gốc hoặc slice 2D

Loại ảnh	Ưu điểm	Hạn chế
Ảnh lát cắt (slice)	Đầy đủ thông tin theo lớp	ROI nhỏ dễ bị bỏ sót
Ảnh MIP	ROI sáng rõ, toàn vùng	Mất thông tin chiều sâu
Ảnh 3D gốc	Chính xác vật lý, giàu thông tin	Cần mạng 3D, chi phí lớn